Enquête sur la santé dans les collectivités canadiennes (ESCC)
Documentation sur les poids ménages - 2005

Juillet 2008

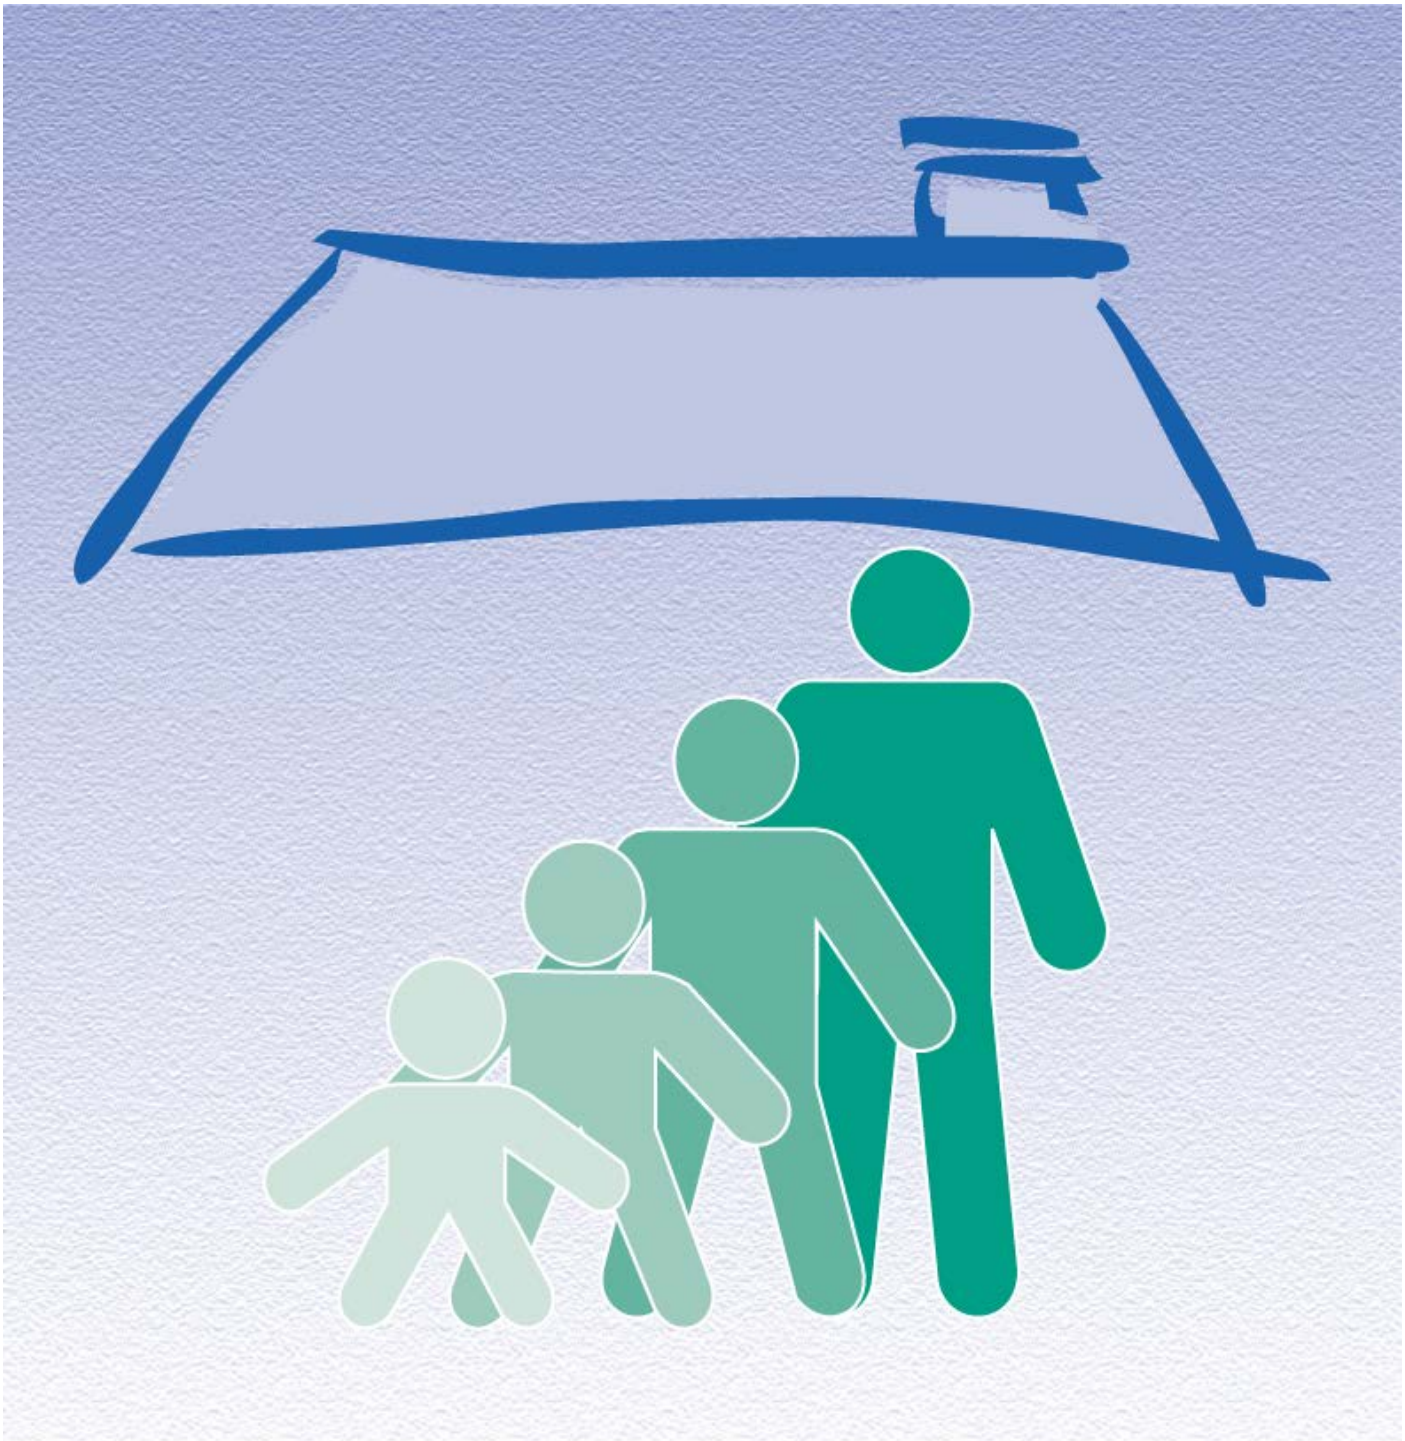

Statistique Canada Statistics Canada

Canada

TABLE DES MATIÈRES

1. INTRODUCTION 1

2. VUE D'ENSEMBLE DE LA PONDÉRATION 3

3. PONDÉRATION DE L'ÉCHANTILLON 4

3.1 PONDÉRATION DE L'ÉCHANTILLON PROVENANT DE LA BASE ARÉOLAIRE 5
3.2 PONDÉRATION DE L'ÉCHANTILLON PROVENANT DE LA BASE TÉLÉPHONIQUE 7
3.3 INTÉGRATION DES BASES ARÉOLAIRE ET TÉLÉPHONIQUE (I1) 11
3.4 EFFET SAISONNIER ET WINSORIZATION (I2) 11
3.5 POST-STRATIFICATION (I3) 12
3.6 PARTICULARITÉS DE LA PONDÉRATION POUR LES TROIS TERRITOIRES 13

1. Introduction

Ce document décrit la stratégie de pondération pour la production du poids ~~des~~ ménages ~~du cycle 3.1~~ de l'Enquête sur la s~~S~~anté dans les c~~C~~ollectivités c~~C~~anadiennes (ESCC) de 2005. En utilisant le poids des ménages, les utilisateurs doivent être conscients que l'enquête a été conçue afin de représenter les individus et non pas les ménages. Le plan de sondage a été établi pour s'assurer que l'échantillon était représentatif de différents groupes démographiques au niveau des personnes. Il est possible que la qualité de la représentativité de l'échantillon par rapport à certains types de ménages soit moindre. De plus, puisque le calage aux marges pour le poids des ménages est effectué au niveau des provinces, il est possible de produire des estimations fiables aux échelles nationale et provinciale seulement. D'autre part, il peut être tentant d'utiliser les réponses des individus à certaines questions comme si elles représentaient le ménage alors que ce n'est pas le cas. Les utilisateurs doivent remarquer que le poids des ménages devrait être utilisé seulement pour les variables où on peut clairement affirmer que les réponses de l'individu représentent le ménage et que la réponse resterait la même si n'importe quel autre individu du ménage avait répondu. Ceci est appuyé par le fait que, tout au long du document, on fait référence aux personnes répondantes. Les utilisateurs doivent donc se souvenir qu'il est sous-entendu que les réponses de la personne sélectionnée représentent le ménage lorsqu'on utilise le poids des ménages.

Les utilisateurs familiers avec l'ESCC remarqueront que les ajustements de poids reliés aux poids des ménages sont similaires aux ajustements des autres poids au niveau de la personne qui étaient créés dans le passé. Une interview de l'ESCC peut être vue comme un processus en deux étapes. D'abord, l'intervieweur effectue le listage des membres du ménage (réponse de ménage). Ensuite, il/elle interviewe la personne sélectionnée dans le ménage (réponse de personne). Dans le calcul du poids des ménages, on utilise les réponses individuelles pour représenter les ménages. Cependant, les ajustements de non-réponse pour les deux étapes sont effectués lors de la production des poids des ménages, comme lors de la production des poids au niveau de la personne, parce que la non-réponse peut survenir à n'importe laquelle des étapes du processus de collecte. Les ajustements de non-réponse du ménage sont donc basés sur les caractéristiques de l'individu répondant. Étant donné que l'enquête est désignée pour recueillir les renseignements de l'individu, les caractéristiques de ce dernier peuvent avoir un effet sur la non-réponse du ménage.
~~Les utilisateurs familiers avec l'ESCC remarqueront que les ajustements de poids reliés aux poids des ménages sont similaires aux ajustements des autres poids au niveau de la personne qui étaient créés dans le passé. Une interview de l'ESCC peut être vue comme un processus en deux étapes. D'abord, l'intervieweur effectue le listage des membres du ménage. Ensuite, il/elle interviewe la personne sélectionnée dans le ménage. La différence clé entre le poids des ménages et le poids au niveau de la personne est qu'il n'y a pas d'ajustement pour la sélection de la personne à la deuxième étape dans le calcul du poids de ménage. Cependant, les ajustements de non-réponse pour les deux étapes sont effectués lors de la production des poids des ménages, comme lors de la production des poids au niveau de la personne, parce que la non-réponse peut survenir à n'importe laquelle des étapes du processus de collecte. L'ajustement qui compense la non-réponse à la deuxième étape de l'interview utilise les renseignements recueillis pendant la première étape du processus. Les ajustements de non-réponse du ménage sont donc basés sur les caracteristiques de l'individu répondant. Étant donné que l'enquête est désignée pour recueillir les renseignements de l'individu, les caracteristiques de ce dernier peuvent avoir un effet sur la non-réponse du ménage.~~

~~En utilisant le poids des ménages, les utilisateurs doivent être conscients que l'enquête a été conçue afin de représenter les individus et non pas les ménages. Le plan de sondage a été établi pour s'assurer que l'échantillon était représentatif de différents groupes démographiques au niveau des personnes. Il est possible que la qualité de la représentativité de l'échantillon par rapport à certains types de ménages soit moindre. De plus, pusique la post-stratification pour le poids des ménages est effectuée au niveau des provinces, il est possible de produire des estimations fiables aux échelles nationale et provinciale seulement. D'autre part, il peut être tentant d'utiliser les réponses des individus à certaines questions comme si elles représentaient le ménage alors que ce n'est pas le cas. Les utilisateurs doivent remarquer que le poids des ménages devrait être utilisé seulement pour les variables où on peut clairement afirmer que les réponses de l'individu représentent le ménage et que la réponse resterait la même si n'importe quel autre individu du ménage avait répondu. Ceci est appuyé par le fait que, tout au long du document, on fait référence aux personnes répondantes. Les utilisateurs doivent donc se souvenir qu'il est sous-entendu que les réponses de la personne sélectionnée représente le ménage losrqu'on utilise le poids des ménages.~~

2. Vue d'ensemble de la pondération

Pour que les estimations produites à partir de données d'enquête soient représentatives de la population couverte, et non pas seulement représentatives de l'échantillon comme tel, l'utilisateur doit incorporer les facteurs de pondération, appelés ici les poids d'enquête, dans ses calculs. Un poids d'enquête est attribué à chaque personne incluse dans l'échantillon final, c'est-à-dire dans l'échantillon de personnes ayant répondu à l'enquête. Ce poids correspond au nombre de ménages représentés par le répondant dans l'ensemble de la population.

L'ESCC de 2005 a eu recours à trois bases de sondage pour la sélection de son échantillon : une base aréolaire de logements agissant comme base principale, puis deux bases formées de numéros de téléphone utilisées pour complémenter la base aréolaire. Puisque seulement quelques différences mineures distinguent les deux bases de numéros de téléphone pour la pondération, elles ont été traitées ensemble. On réfère à celles-ci comme faisant partie de la base téléphonique.

La stratégie de pondération a été développée en traitant séparément la base aréolaire et la base téléphonique. Les poids résultant de ces deux bases sont ensuite combinés en un seul ensemble de poids lors d'une étape appelée « intégration ». Suite à quelques ajustements, ce poids intégré devient le poids final. Noter que dépendamment du besoin, une seule ou deux bases pouvaient être utilisées pour la sélection de l'échantillon dans une région sociosanitaire donnée. La stratégie de pondération s'occupe de cette particularité lors de l'étape d'intégration.

3. Pondération de l'échantillon

Tel que mentionné plus haut, les unités des bases aréolaire et téléphonique sont traitées séparément jusqu'à l'étape d'intégration. La sous-section 3.1 fournit les détails de la stratégie de pondération pour la base aréolaire, puis la sous-section 3.2, ceux pour la base téléphonique. L'intégration des deux bases est traitée en 3.3, puis suivent les deux étapes finales de la pondération, c'est-à-dire l'ajustement pour contrôler la saisonnalité des données puis la post-stratification, sont expliquées dans les sous-sections 3.4 et 3.5 respectivement.

Malgré que les deux bases aient été utilisées pour couvrir les trois territoires, certaines modifications ont dû être faites relativement à leur utilisation. Ces modifications affectent substantiellement la pondération pour ces trois régions, et celles-ci sont rapportées dans la sous-section 3.6.

Le diagramme A présente un sommaire des différents ajustements faisant partie de la stratégie de production des poids des ménages dans l'ordre qu'ils sont appliqués. Un système de numérotation est utilisé pour identifier chaque ajustement apporté au poids et sera utilisé tout au long de la section. Les lettres *A* et *T* sont utilisées comme préfixes pour référer aux ajustements appliqués aux unités des bases *A*réolaire et *T*éléphonique respectivement. Le préfixe *I* est, quant à lui, utilisé pour identifier l'ajustement d'*I*ntégration et ceux qui suivent.

Diagramme A **Sommaire de la stratégie de pondération (Poids des ménages)**

Base aréolaire	**Base téléphonique**
A0 - Poids initial	T0 - Poids initial
A1 - Accroissement de l'échantillon	T1 - Nombre de mois
A2 - Stabilisation	T2 - Retrait des unités hors champ
A3 - Retrait des unités hors champ	T3 - Couverture des bases listes
A4 - Non-réponse ménage	T4 - Combinaison des bases listes
A5 - Non-réponse personne	T5 - Non-réponse ménage
Poids final de la base aréolaire	T6 - Ménages sans téléphone
⤷	T7 - Non-réponse personne
	T8 - Lignes multiples
	Poids final de la base téléphonique
	⤶
I1 – Intégration	
I2 - Effet saisonnier	
I3 – Post-stratification	
Poids ménage final de l' ESCC 2005	

3.1 Pondération de l'échantillon provenant de la base aréolaire

A0 – Poids initial

Puisque le mécanisme utilisé pour sélectionner l'échantillon de la base aréolaire a été celui établi pour l'Enquête sur la Population Active (EPA), le poids initial a dû être calculé selon les particularités de cette enquête. D'abord, à l'intérieur de chacune des strates définies par l'EPA, des grappes (unités primaires) sont sélectionnées avec probabilités proportionnelles au nombre de ménages (selon les comptes du Recensement de 2001). À l'intérieur de chacune des grappes sélectionnées, un échantillon de logements est ensuite choisi à l'aide d'un échantillonnage systématique. Le produit des probabilités de chacune de ces sélections représente la probabilité de sélection globale et son inverse représente le poids initial de l'ESCC de 2005. Pour plus de détails sur le mécanisme de sélection, de même qu'une définition plus complète des strates et des grappes, se référer à Statistique Canada (1998)[1].

A1 – Accroissement de l'échantillon

Certaines modifications ont dû être faites au mécanisme standard de l'EPA lors de la sélection de l'échantillon pour l'ESCC de 2005. Le plan de l'EPA peut fournir un échantillon d'environ 60 200 logements à l'échelle du pays alors que les besoins de l'ESCC de 2005 sont plus grands dans certaines régions. Les modifications apportées afin de pouvoir obtenir la taille d'échantillon désirée ont été, en résumé, de répéter le même processus de sélection une deuxième fois à l'intérieur de toutes les grappes sélectionnées dans la RSS où le besoin en échantillon se faisait sentir. Ceci a eu pour effet d'accroître l'échantillon et on a dû en tenir compte dans la pondération afin de correctement représenter la probabilité de sélection. Un facteur d'ajustement représentant le taux d'accroissement de l'échantillon a donc été calculé. Cependant, cet accroissement de l'échantillon n'a pas été observé dans toutes les régions. En effet, pour certaines régions, le plan de l'EPA conduit à des tailles d'échantillon supérieures à celles requises par l'ESCC. Pour ces régions, le taux d'accroissement de l'échantillon qui est calculé représente plutôt un taux de décroissement. Le poids initial calculé en A0 est multiplié par ce facteur d'ajustement, ce qui permet d'obtenir le poids A1.

A2 – Stabilisation

Dans certaines RSS, l'accroissement de l'échantillon tel que décrit au paragraphe précédent résultait en un échantillon beaucoup plus grand que nécessaire. Une stabilisation a donc été instaurée afin de ramener la taille de l'échantillon au niveau désiré. Le processus de stabilisation consistait à sous-échantillonner des logements aléatoirement à l'intérieur de la RSS. Un facteur d'ajustement représentant l'effet de la stabilisation a donc été calculé afin de corriger la probabilité de sélection. Ce facteur, multiplié par le poids A1, produit le poids A2.

[1] Statistique Canada (1998). *Méthodologie de l'enquête sur la population active du Canada.* Statistique Canada numéro 71-526-XPB au catalogue.

A3 – Retrait des unités hors champ

Parmi tous les logements échantillonnés, une certaine proportion de ceux-ci est, lors de la collecte, identifiée comme étant hors du champ de l'enquête. Des logements détruits ou en construction, des logements vacants, saisonniers ou secondaires, de même que des établissements, sont tous des exemples de cas hors champ pour l'ESCC de 2005. Ces logements sont tout simplement retirés de l'échantillon, ne laissant plus que les logements faisant partie du champ de l'enquête. Ces derniers conservent donc le même poids qu'à l'étape précédente que l'on appelle maintenant poids A3.

A4 – Non-réponse ménage

Lors de la collecte, une certaine proportion des logements visités a inévitablement résulté en non-réponse. Ceci survient habituellement lorsque le ménage habitant le logement refuse de participer à l'enquête, fournit des données inutilisables, ou encore, ne peut être rejoint pour réaliser l'interview. Le poids des ménages non-répondants est redistribué aux répondants à l'aide de classes de réponse. L'algorithme CHAID (*Chi-Square Automatic Interaction Detector*), disponible dans *Knowledge Seeker*[2], permet d'identifier les caractéristiques qui divisent le mieux l'échantillon en groupes selon leurs propensions à répondre. Noter que ces groupes sont formés de façon indépendante à l'intérieur de chaque RSS. Puisque l'information disponible auprès des non-répondants est très limitée, seules quelques caractéristiques telles que la période de collecte et un indicateur du milieu rural/urbain ont pu être utilisées pour la création des classes. Il s'est avéré que l'indicateur rural/urbain était la caractéristique la plus significative pour la création des classes pour chacune des RSS. La période de collecte (avec 4 périodes: janvier à mars, avril à mai, juin à août et septembre à novembre) était également une caractéristique significative pour un petit nombre de RSS. Un facteur d'ajustement a donc été calculé à l'intérieur de chaque classe de la façon suivante:

$$\frac{\textit{Somme des poids A3 pour tous les ménages}}{\textit{Somme des poids A3 pour tous les ménages répondants}}$$

Le poids A3 des ménages répondants a donc été multiplié par ce facteur d'ajustement pour produire le poids A4. Les ménages non-répondants sont éliminés du processus de pondération à partir de ce point.

A5 – Non-réponse personne

Comme il a été mentionné plus haut, un interview de l'ESCC peut être vu comme un processus en deux étapes. Dans un premier temps, l'intervieweur obtient la liste complète des personnes vivant dans le ménage, puis par la suite interviewe la personne sélectionnée dans le ménage. Dans un premier temps, l'intervieweur obtient la liste complète des personnes vivant dans le ménage, puis par la suite interviewe la personne sélectionnée dans le ménage. Dans certains cas, les intervieweurs ne réussissent qu'à compléter la première étape, soit parce qu'ils ne peuvent entrer

2. ANGOSS Software. *Knowledge Seeker IV for Windows - User's Guide*, ANGOSS Software International Limited. 1995.

en contact avec la personne sélectionnée, ou encore parce que la personne sélectionnée refuse d'être interviewée. De tels cas sont définis comme étant des non-réponses à l'échelle de la personne, et un facteur d'ajustement doit être appliqué aux poids des ménages pour compenser cette non-réponse. Tout comme pour la non-réponse à l'échelle du ménage, l'ajustement est appliqué à l'intérieur de classes définies à partir des caractéristiques disponibles pour les répondants et non-répondants. Toutes les caractéristiques recueillies lors du listage des membres du ménage étaient en fait disponibles pour créer ces classes. L'algorithme CHAID, disponible dans *Knowledge Seeker*, a encore une fois été utilisé pour obtenir la définition des classes et le résultat final présente quelques variations dans la définition des classes d'une RSS à l'autre. Selon la RSS, les caractéristiques suivantes ont pu être utilisées pour former les classes d'ajustement : les tailles des ménages, le sexe, l'indicateur de milieu rural/urbain, la période de collecte, l'état matrimonial, l'âge, les dispositions de vie et le nombre de personnes de 12 ans et moins dans le ménage. Un facteur d'ajustement est calculé à l'intérieur de chaque classe de la façon suivante:

$$\frac{\textit{Somme des poids A4 pour toutes les personnes sélectionnées}}{\textit{Somme des poids A4 pour toutes les personnes sélectionnées répondantes}}$$

Le poids A4 des personnes répondantes a donc été multiplié par ce facteur d'ajustement pour produire le poids A5. Les personnes non-répondantes sont éliminées de la pondération à partir de ce point.

Étant donné que cet ajustement est le dernier nécessaire pour l'échantillon provenant de la base aréolaire, le poids A5 représente donc le ***poids final de la base aréolaire***. Ce poids sera plus tard intégré au poids final de la base téléphonique (section 3.3) pour créer le poids final de l'ESCC de 2005.

3.2 Pondération de l'échantillon provenant de la base téléphonique

Tel que mentionné précédemment, la base téléphonique est en fait composée de deux bases : la base de sondage à composition aléatoire (CA), puis une base liste de numéros de téléphone. Noter qu'une seule de ces deux bases peut être utilisée à l'intérieur d'une RSS. La base liste est toujours utilisée comme complément à la base aréolaire tandis que la base CA est toujours utilisée seule. Les unités provenant de ces deux bases téléphoniques sont toutefois traitées ensemble et sont donc toutes soumises aux mêmes ajustements. Il existe toutefois trois exceptions: d'abord, puisque la probabilité de sélection est relative à la base utilisée pour faire la sélection, cette probabilité sera légèrement différente dépendamment que l'unité provienne de la base CA ou de la base liste. Les autres exceptions impliquent les ajustements T3 et T4. Les détails de ces exceptions sont donnés dans les sous-sections réservées aux ajustements impliqués.

Une autre particularité propre aux unités provenant de la base téléphonique affecte la façon dont l'échantillon a été pondéré. Cette particularité concerne l'emplacement géographique des unités échantillonnées. En effet, la géographie utilisée pour sélectionner l'échantillon à partir de la base téléphonique ne répliquait pas parfaitement la géographie des RSS, ce qui a forcé certaines unités à être sélectionnées dans une certaine région alors que l'information fournie lors de l'interview les localisait plutôt dans une région avoisinante. Cette particularité a été contournée lors de la pondération en appliquant tous les ajustements relativement à la RSS assignée lors de la sélection

de l'échantillon. Toutefois, puisque les unités devaient en bout de ligne appartenir à leur vraie RSS, telle qu'identifiée lors de la collecte, on a dû ajuster les poids de celles-ci comme si elles avaient fait partie de leur vraie région dès la sélection de l'échantillon. Cet ajustement a été fait via la post-stratification (I3) qui est traitée plus tard dans cette section.

T0 – Poids initial

Le poids initial est calculé quelque peu différemment selon que l'échantillon provienne de la base CA ou de la base liste. Dans les deux cas, le poids initial est défini comme étant l'inverse de la probabilité de sélection, mais puisque les méthodes de sélection diffèrent, les probabilités diffèrent aussi. Pour la base CA, la sélection des numéros est faite à l'intérieur de chaque strate CA. Une strate CA représente un agrégat d'indicatifs régionaux et préfixes (IRP: les six premiers chiffres du numéro à 10 chiffres), contenant chacune des banques valides de cent numéros (voir Norris et Paton[3] pour plus de détails). Conséquemment, la probabilité de sélection est le ratio entre le nombre d'unités échantillonnées et cent fois le nombre de banques présentes dans la strate CA. Pour la base liste, les numéros de téléphone sont sélectionnés parmi tous les numéros disponibles dans la liste, et ce indépendamment pour chaque RSS. Ainsi, la probabilité de sélection correspond au ratio entre le nombre d'unités échantillonnées et le nombre de numéros de téléphone dans la liste pour la RSS. Puisque l'échantillonnage pour la base téléphonique est fait sur une base mensuelle (voir ajustement T1) et que la base liste a été mise à jour durant l'enquête, le nombre de numéros disponibles dans chaque RSS a pu légèrement varier affectant ainsi la probabilité de sélection dans le temps. L'inverse de ces probabilités de sélection représente le poids initial T0.

T1 – Nombre de mois

Contrairement à la base aréolaire, pour laquelle l'échantillon a été sélectionné entièrement au début du processus d'échantillonnage, des échantillons ont été tirés à chaque mois pour la base téléphonique. À chacun de ces échantillons mensuels correspond un poids initial faisant en sorte que chaque échantillon soit représentatif de la RSS. Toutefois, pour que l'échantillon total ne représente qu'une seule fois la population, un facteur d'ajustement a dû être appliqué pour réduire les poids de chaque échantillon mensuel. Le facteur d'ajustement appliqué à chaque échantillon mensuel était égal à la proportion que représentait cet échantillon mensuel parmi l'échantillon total. Or, puisque deux versions différentes de la base liste ont été utilisées et que chaque version possède une couverture différente, l'ajustement du nombre de mois a été calculé indépendamment pour chaque version de la base liste. À partir de ce moment, l'échantillon de la base liste représente deux fois la population totale, soit une fois pour chaque version de la base liste. Les échantillons provenant des deux bases listes sont combinés à l'étape T4 de telle sorte que la base téléphonique représente alors une seule fois la population. Le poids T1 est donc obtenu en multipliant le poids T0 par le facteur d'ajustement défini ci-dessus.

[3] Norris, D.A. et Paton, D.G. (1991). L'Enquête sociale générale canadienne: bilan des cinq premières années. *Techniques d'enquête*. 17, 245-260.

T2 - Retrait des unités hors champ

Les numéros de téléphone associés à des entreprises, des établissements ou à d'autres logements hors du champ de l'enquête, de même que les numéros hors service sont tous des exemples de cas hors champ pour la base téléphonique. Comme pour la base aréolaire, ces cas sont simplement retirés de l'échantillon, ne laissant ainsi dans l'échantillon que les logements dans le champ de l'enquête. Ces derniers conservent le même poids qu'à l'étape précédente que l'on appelle maintenant poids T2.

T3 – Couverture des bases listes

Puisque la base liste ne couvre pas certains numéros de téléphone qui sont toutefois couverts par la base CA, un ajustement doit être apporté au poids initial des unités de la base liste pour que les deux bases soient comparables en ce qui a trait à la couverture. Cet ajustement consiste à gonfler le poids des unités de la base liste proportionnellement au taux de couverture dans chaque RSS. L'estimation de ce taux de couverture a été une tâche ardue, et a pu être faite à l'aide des données recueillies auprès de l'échantillon de la base aréolaire. En effet, le questionnaire utilisé pour l'interview des personnes sélectionnées par la base aréolaire incluait un ensemble de questions vérifiant la présence d'un téléphone dans le logement du répondant, le nombre de lignes utilisées à des fins personnelles, puis le numéro pour chacune de ces lignes. Pour dériver le taux de couverture désiré, on a simplement calculé le pourcentage des numéros de téléphone recueillis étant présents sur la base liste. Ce taux a été calculé pour chaque version de la base liste étant donné que la couverture diffère d'une version à l'autre. L'inverse de ce taux représente le facteur utilisé pour cet ajustement. Le facteur, une fois multiplié par le poids T2, produit le poids T3.

T4 - Combinaison des bases listes

L'échantillon provenant de chaque version de la base liste représente jusqu'à cette étape, la population totale des RSS où la base liste est utilisée. Les unités des deux versions doivent donc être combinées afin qu'elles ne représentent qu'une seule fois la population. Pour se faire, un facteur de combinaison tenant compte de l'importance de chaque version est calculé de la façon suivante :

$$\frac{\textit{Taille d' échantillon provenant de la version de la base liste}}{\textit{Taille totale d' échantillon provenant de la base liste}}$$

Ce facteur est calculé et appliqué indépendamment dans chaque RSS où la base liste a été utilisée. Pour les régions où c'est la base CA qui est utilisée, le facteur d'ajustement est égal à 1. Le poids T4 est obtenu en multipliant le poids T3 par le facteur de combinaison.

T5 - Non-réponse ménage

L'ajustement fait ici pour compenser l'effet de la non-réponse ménage est identique à celui appliqué pour la base aréolaire (ajustement A4). Comme c'était le cas pour A4, la période de collecte s'est avérée une caractéristique significative pour expliquer la non-réponse. C'est donc cette variable qui a été utilisée pour définir les classes d'ajustement. Le facteur d'ajustement calculé à l'intérieur de chaque classe a été obtenu de la façon suivante:

$$\frac{\textit{Somme des poids } T4 \textit{ pour tous les ménages}}{\textit{Somme des poids } T4 \textit{ pour tous les ménages répondants}}$$

Le poids T4 des ménages répondants a donc été multiplié par ce facteur d'ajustement pour produire le poids T5. Les ménages non-répondants sont éliminés à partir de ce point.

T6 - Ménages sans téléphone

Une certaine proportion de la population canadienne n'a pas accès à une ligne téléphonique résidentielle privée. Tel qu'expliqué à l'étape T3, de l'information concernant la présence d'un téléphone dans le logement du répondant est recueillie auprès de l'échantillon de la base aréolaire. Cette information a été utilisée pour estimer la proportion de ménages n'ayant pas le téléphone à l'échelle de chaque RSS. Tout comme pour T3, cette proportion est ensuite utilisée pour gonfler le poids des unités de la base téléphonique, ajustant ainsi pour la sous-représentation de la base due à cette sous-population non couverte. Le facteur utilisé pour cet ajustement correspond à l'inverse de la proportion estimée, et une fois multiplié par le poids T5, procure le poids T6.

T7 – Non-réponse personne

Cet ajustement est similaire à l'ajustement A5 utilisé pour la base aréolaire. Il consiste à compenser pour l'effet de la non-réponse à l'échelle de la personne. Tout comme pour A5, une approche par classes d'ajustement a été utilisée. Ces classes étaient définies à partir des variables disponibles pour toutes les personnes sélectionnées, répondantes ou non (voir A5 pour la liste des variables disponibles). Un facteur d'ajustement a donc été calculé à l'intérieur de chaque classe de la façon suivante:

$$\frac{\textit{Somme des poids } T6 \textit{ pour toutes les personnes sélectionnées}}{\textit{Somme des poids } T6 \textit{ pour toutes les personnes sélectionnées répondantes}}$$

Le poids T6 des personnes répondantes a donc été multiplié par ce facteur d'ajustement pour produire le poids T7. Les personnes non-répondantes sont éliminées à partir de ce point.

T8 - Lignes multiples

Le fait que certains ménages possèdent plus d'une ligne téléphonique résidentielle a un impact sur la pondération: plus le ménage a de lignes, meilleure est sa probabilité d'être sélectionné. Conséquemment, les poids doivent être ajustés pour tenir compte du nombre de lignes

résidentielles que le ménage possède. Malgré que cette caractéristique soit relative au ménage, l'information n'est recueillie que durant l'interview auprès de la personne. C'est pour cette raison que l'ajustement est fait à ce stade-ci de la pondération. Le facteur d'ajustement représente l'inverse du nombre de lignes dans le ménage et le poids T8 est obtenu en multipliant ce facteur par le poids T7.

Puisque cet ajustement est le dernier nécessaire pour l'échantillon provenant de la base téléphonique, le poids T8 représente donc le ***poids final de la base téléphonique***. Ce poids sera par la suite, à l'étape I1, intégré au poids final de la base aréolaire pour finalement créer le poids final du cycle 3.1 de l'ESCC.

3.3 Intégration des bases aréolaire et téléphonique (I1)

Cette étape consiste à intégrer les poids finaux des échantillons aréolaire et téléphonique créés jusqu'à maintenant, en un seul poids en appliquant une méthode d'intégration[4]. Un facteur d'ajustement, compris entre 0 et 1, est déterminé au niveau de RSS de façon à représenter l'importance relative de chaque échantillon dans l'échantillon total. Cette importance relative est mesurée en termes de taille d'échantillon et d'effet de plan. Plus la proportion d'échantillon qu'une base représente dans l'échantillon total est grande, plus grande sera son importance relative dans l'échantillon total. Pour ce qui de l'effet de plan, l'importance relative sera plus grande pour les unités provenant de la base dont l'effet de plan est plus petit. Pour obtenir le facteur d'ajustement d'intégration, on calcule d'abord un facteur α, obtenu de la façon suivante:

$$\alpha = \frac{n_A}{R} \Big/ \left(\frac{n_A}{R} + n_T \right)$$

où n_A et n_T représentent respectivement les tailles d'échantillon des bases aréolaire et téléphonique, alors que R représente le rapport médian des effets de plan estimés de plusieurs caractéristiques clés pour chacune des deux bases. Le poids des unités de la base aréolaire est multiplié par ce facteur α, alors que le poids des unités de la base téléphonique est multiplié par 1- α. Il est à noter que dans les cas où une RSS n'est couverte que par une seule base, le facteur d'ajustement est égal à 1. Le produit du facteur d'ajustement dérivé ici, par le poids final calculé auparavant (A5 ou T8 dépendant de quelle base provient l'unité), procure le poids intégré I1.

3.4 Effet saisonnier et Winsorization (I2)

L 'ESCC de 2005 avait initialement planifié de répartir la collecte des données également sur les douze mois de l'année de référence de l'enquête afin de contrôler entre autres l'effet saisonnier des données recueillies. Certains événements ont toutefois affecté ce plan, de sorte qu'un ajustement additionnel a dû être ajouté pour assurer qu'il n'y ait pas d'effet saisonnier dans les estimations produites. L'ajustement appliqué en I2 a été fait de façon à ce que la somme des poids des unités interviewées lors d'une des quatre saisons, représente exactement 25 % de la somme des poids de

[4] Skinner, C.J. et Rao, J.N.K. (1996). Estimation in Dual Frame Surveys with Complex Designs. *Journal of the American Statistical Association*. 91, 433, 349-356.

l'échantillon total. Bref, après l'application de cet ajustement, la portion d'échantillon interviewée à chaque saison représente 25 % de la population totale de chaque RSS.

Les quatre saisons définies pour l'ESCC sont les périodes couvrant septembre à novembre, décembre à février, mars à mai, puis juin à août. Le facteur d'ajustement utilisé pour contrôler l'effet saisonnier d'une personne interviewée lors de la saison *S*, est défini comme suit:

$$\frac{\textit{Somme des poids I1 pour l'échantillon total}}{4 \times \textit{somme des poids I1 de l'échantillon interviewé lors de la saison S}}$$

Cet ajustement saisonnier appliqué au poids I1 permet d'obtenir le poids I2.

Winsorization : Noter que suite à la série d'ajustements appliqués sur les poids, il est possible que certaines unités se retrouvent avec des poids se démarquant des autres poids de leur RSS au point même de devenir aberrants. Certains répondants peuvent effectivement représenter une proportion anormalement élevée de leur RSS et ainsi influencer fortement les estimations de ces RSS. Afin d'éviter cette situation, le poids des répondants qui contribuent de façon aberrante à leur groupe RSS-âge-sexe est ajusté à la baisse selon une méthode « winsorization ».

3.5 Post-stratification (I3)

La dernière étape nécessaire afin d'obtenir le poids final des ménages de l'ESCC de 2005 est la poststratification à des comptes de ménages connus. La poststratification est appliquée afin de s'assurer que la somme des poids finaux corresponde aux estimations du nombre de ménages et ce à l'échelle des provinces par taille de ménage. Les groupes d'intérêts étaient définis par les tailles suivantes : ménages d'une personne, ménages de 2 personnes, ménages de 3 personnes et plus. La poststratification a été faite au niveau provincial seulement.

Les estimations des comptes de ménages utilisées sont basées sur les comptes du Recensement de 2001. La moyenne des estimations mensuelles de 2005 pour chacun des croisements Province-taille de ménage a été retenue pour calculer la poststratification. Le poids I2 a donc été ajusté afin d'obtenir le poids final I3, à l'aide du facteur d'ajustement I3 défini comme suit:

$$\frac{\textit{Estimation de population pour le groupe RSS - âge - sexe du répondant}}{\textit{Somme des poids I2 pour le groupe RSS - âge - sexe du répondant}}$$

Le poids I3 correspond au ***poids de ménage final de l'ESCC de 2005*** que l'on retrouve dans le fichier de poids-ménage portant le nom de variable WTSE_MHH pour le poids maître et WTSE_SHH pour le poids partagé.

3.6 Particularités de la pondération pour les trois territoires

Pour l'ESCC de 2005, le plan d'échantillonnage utilisé pour les trois territoires était quelque peu différent de celui utilisé dans les 10 provinces. La stratégie de pondération a donc dû être adaptée pour répondre à ces différences. Cette section résume les changements apportés à la stratégie expliquée aux sous-sections 3.1 à 3.5.

D'abord pour la base aréolaire, une étape additionnelle de sélection a été ajoutée pour les territoires. Chaque territoire était initialement stratifié selon des regroupements de communautés à l'intérieur desquels on a sélectionné aléatoirement une communauté. Noter que les capitales de chaque territoire formaient une strate à elles seules, et étaient donc toutes trois sélectionnées automatiquement à cette première sélection. Cette particularité n'a eu d'effet que dans le calcul de la probabilité de sélection, et donc dans la valeur du poids initial (A0). Une fois ce poids initial calculé, la même série d'ajustements (A1 à A5) a été appliquée aux unités de la base aréolaire. Les classes d'ajustement pour les non-réponses ménage et personne ont été construites à l'aide du même ensemble de variables disponibles pour les provinces.

Pour ce qui est de la pondération des unités de la base téléphonique, mentionnons tout d'abord que seule la base CA a été utilisée, et ce, uniquement à l'intérieur des capitales du Yukon et des Territoires du Nord-Ouest. Ceci élimine donc le besoin d'avoir recours aux ajustements T3 (couverture des bases listes) et T4 (combinaison des bases listes). Les autres ajustements de la base téléphonique ont tous été appliqués. Finalement, l'ajustement T6 (ménages sans téléphone) a aussi subi une légère modification puisque la base CA était utilisée uniquement dans les capitales. Les proportions de ménages sans téléphone ont été dérivées, tout comme pour les provinces, à partir des données de la base aréolaire, mais en excluant toutefois du calcul les données des ménages situés à l'extérieur des capitales.

Les deux ensembles de poids (aréolaire et téléphonique) ont ensuite été intégrés, puis ajustés pour la saisonnalité et finalement post-stratifiés de façon semblable à ce qui a été fait pour les provinces, à l'exception de deux détails. D'abord, l'intégration a été appliquée uniquement pour les unités situées dans les capitales du Yukon et des Territoires du Nord-Ouest; les autres communautés ayant été couvertes uniquement par la base aréolaire. Un autre chose à noter pour le Nunavut est que les comptes de la population utilisés pour la calibration représentent 70% de la population seulement (et environ 74% des ménages seulement) étant donné la sous couverture de la base aréolaire (voir la section 5.4.1 du Guide de l'utilisateur pour plus de détails).