Imputation sur le revenu pour l'Enquête sur la santé dans les collectivités canadiennes

Chi Wai Yeung, méthodologiste, ESCC
Steven Thomas, méthodologiste principal, ESCC
Mai 2012

1. Introduction

Quelques questions sur le revenu sont demandées durant les interviews pour l'Enquête sur la santé dans les collectivités canadiennes (ESCC) en raison de leur association possible avec certaines variables sur la santé. La variable de revenu la plus communément utilisée dans les analyses est celle du revenu total du ménage (variable INC_3). Toutefois, puisque rapporter son revenu est de nature délicate, seulement 66% des répondants de l'ESCC l'ont déclaré en 2011. Pour les non-répondants au revenu total du ménage, une série de questions (INC_5A/B/C) est administrée afin de déterminer une tranche de revenu. En 2011, 45% des non-répondants au revenu ont accepté de fournir une telle tranche de revenu. Veuillez référer au questionnaire de l'ESCC pour plus d'information sur le module de revenu de l'ESCC.

En plus d'un faible taux de réponse, une étude menée en 2009 suggérait que les non-répondants au revenu avaient des caractéristiques de santé différentes des répondants. En raison de cette différence dans les profils de santé et le faible taux de réponse, les analyses qui sont basées uniquement sur les répondants au revenu pourraient être biaisées. Il a donc été décidé d'imputer le revenu total du ménage pour la première fois, et ce pour la diffusion de l'ESCC de 2011.

Pour les utilisateurs souhaitant faire des analyses examinant uniquement le revenu du ménage, il est fortement recommandé d'avoir recours à d'autres sources de données propres au revenu, plutôt qu'utiliser l'ESCC. Pour les analyses impliquant à la fois le revenu des ménages et des variables « santé », les utilisateurs devraient utiliser des variables dérivées du revenu telles que les quintiles de revenu, plutôt que d'utiliser la valeur exacte du revenu. Le processus d'imputation donne de bons résultats pour prédire les quintiles de revenu, alors qu'il produit une plus grande variabilité pour la prédiction du revenu exact.

2. Revenu du ménage modélisé

Une variable auxiliaire importante au processus d'imputation est **le revenu du ménage modélisé.** Il est calculé pour tous les répondants à l'ESCC (répondant ou non aux questions sur le revenu) en utilisant un processus en trois étapes. Les détails de son calcul sont donnés ici.

<u>Étape 1</u>
À l'aide d'un modèle de régression, le revenu personnel pour *tous* les membres d'un ménage répondant est dérivé. Les variables utilisées dans le modèle incluent le groupe d'âge, le niveau d'éducation, les sources de revenu, la province d'habitation, l'état matrimonial, la taille du

ménage, si le logement est possédé ou loué, et une variable indiquant si la personne sélectionnée pour l'interview à l'ESCC est un adulte ou non. Il est bon de noter qu'aucune variable de santé n'est utilisée dans le modèle, et ce afin d'éviter la création de relations artificielles entre le revenu et certaines variables de santé.

Étape 2

Une valeur de revenu du ménage préliminaire est dérivée en additionnant tous les revenus personnels de l'étape 1. Les totaux résultant ne reflètent pas fidèlement les renseignements sur le revenu recueillis par l'ESCC de sorte que ces valeurs nécessitent d'autres ajustements.

Étape 3

Le revenu médian des ménages à partir des données fiscales T1 est calculé au niveau du code postal, et ce selon la variable de taille du ménage groupée. À l'aide d'un modèle de régression incluant le revenu médian provenant des données fiscales et le revenu du ménage préliminaire obtenu à l'étape 2, la valeur finale du revenu du ménage modélisé est obtenue. Ce revenu final modélisé n'apparaît pas sur le fichier de données, mais est plutôt utilisé en tant que variable auxiliaire dans le processus d'imputation par le plus proche voisin.

3. Processus d'imputation

Une méthode d'imputation par le plus proche voisin est utilisée afin d'imputer le revenu. Le revenu du ménage modélisé défini ci-dessus est utilisé (comme mesure de distance) afin de déterminer quelle paire donneur-receveur est la "plus proche", et ce à l'intérieur de classes d'imputation.

Les classes d'imputation sont formées différemment selon que les non-répondants au revenu aient fourni ou non une tranche de revenus. Pour ceux l'ayant fournis, les classes d'imputation sont basées sur la tranche de revenu et la taille du ménage. Étant donné que les tranches de revenu sont petites, les revenus imputés en utilisant cette approche sont très précis. Pour les personnes n'ayant pas fourni une tranche de revenu, les classes d'imputation sont formées au niveau de la région socio-sanitaire et selon la taille du ménage. Même si les revenus imputés ici ne sont pas aussi précis que ceux imputés à l'aide d'une tranche de revenu, leur qualité demeure acceptable.

Le tableau suivant présente le nombre d'unités imputées dans le fichier maître de l'ESCC 2011:

Étapes de l'imputation	**Nombre de personnes**	**Pourcentage du total**
Revenu déclaré	42 215	66,4%
Imputation au sein d'une tranche de revenu par taille du ménage	9613	15,1%
Imputation au sein de la région socio-sanitaire par taille du ménage	11 714	18,4%
Total	**63 542**	**100%**

4. Fichier de données de 2011

À partir de la diffusion des données de 2011, presque tous les répondants ont une valeur pour la variable portant sur le revenu total du ménage (INC_3). Les cas de 'partage partiel' sur le fichier de partage constituent la seule exception. Dans certains cas, l'information sur le revenu est fournie par une personne désignée comme étant la 'personne la mieux renseignée' (PMKPROXY). Lorsque cette personne refuse que cette information fasse partie du fichier de partage, mais que le répondant accepte de partager ses autres données d'enquête, on obtient un cas de 'partage partiel'. Dans un tel cas, la variable INC_3 est considérée comme 'non déclarée'. Un indicateur d'imputation INCFIMP est inclus dans le fichier afin d'identifier les enregistrements ayant une valeur imputée pour le revenu total du ménage. De plus, les variables dérivées à partir du revenu total du ménage, telles que INCDHH, INCDADR, INCDRCA, etc., seront aussi dérivées pour les enregistrements ayant maintenant une valeur imputée du revenu du ménage.

Il convient de noter que le revenu personnel total (variable INC_8A) n'est pas imputé; les utilisateurs doivent ainsi prendre les mesures appropriées afin d'analyser cette variable.