Variables et sources de revenu dans le fichier de partage de l'Enquête sur la santé dans les collectivités canadiennes

1. Introduction

En prévision du couplage avec les dossiers fiscaux, les questions sur le revenu de 2016 n'ont pas été posées dans la majorité des cas. Les questions sur le revenu ont seulement été posées lorsque les répondants ont refusé le couplage ou lorsqu'il y avait une faible probabilité de trouver un couplage (selon les travaux préliminaires). Bien que de nombreux répondants aient consenti au couplage avec les dossiers fiscaux et aient également consenti au partage de leurs données, des restrictions ont été imposées interdisant le partage des données fiscales avec les partenaires de partage, conformément à la *Loi de l'impôt sur le revenu*. Ce document décrit les variables du revenu dans le fichier de partage de 2016 et la manière dont elles ont été établies.

2. Données des répondants

La variable relative au revenu la plus fréquemment utilisée dans les analyses est le revenu total du ménage (variable INC_021). En 2016, environ le quart des répondants ont fourni une estimation du revenu annuel du ménage pour 2015. Le taux de réponse était semblable pour les personnes admissibles à répondre à la question sur le revenu personnel total (INC_041). Un autre 5 % environ des répondants ont fourni une tranche estimée du revenu du ménage et 3,5 % environ ont fourni une tranche du revenu personnel total. Les données des répondants ont été utilisées dans la mesure du possible pour établir les variables de partage relatives au revenu.

3. Imputation du revenu

Si les répondants ont fourni une tranche de revenu pour le revenu total du ménage ou le revenu personnel total, une imputation du revenu par enregistrement donneur a été effectuée. À l'aide des caractéristiques du répondant et de son ménage, un enregistrement donneur a été trouvé dans la tranche de revenu fournie selon la méthode du plus proche voisin. Le revenu du ménage et le revenu personnel modélisés décrits à la section suivante sont utilisés comme mesure de distance pour déterminer la paire d'enregistrement donneur-bénéficiaire qui est la plus « proche » dans les classes d'imputation.

3.1 Revenu modélisé pour l'imputation par enregistrement donneur

Une variable auxiliaire importante utilisée dans le processus d'imputation est le revenu modélisé. Celle-ci est calculée pour tous les répondants à l'ESCC (qu'ils aient répondu aux questions sur le revenu ou non) à l'aide d'un processus semblable à la modélisation décrite à la section 4. Ce calcul est fait à l'échelle du ménage et à l'échelle de la personne.

À l'aide d'un modèle de régression, le revenu du ménage ou le revenu personnel est estimé en fonction de la taille du ménage, du niveau de scolarité des membres du ménage, des renseignements sur l'emplacement, des caractéristiques liées à l'emploi et à la santé ainsi que de l'âge et du sexe des membres du ménage et du revenu médian du ménage issu des données fiscales du fichier T1 pour le code postal du répondant. Les variables et les coefficients utilisés dans ces modèles pour estimer le revenu à l'échelle du ménage et à l'échelle de la personne sont différents.

3.2 Choix d'un enregistrement donneur

Les classes d'imputation sont créées différemment selon que le revenu imputé est un revenu total du ménage ou un revenu personnel total. Pour le revenu total du ménage, les classes d'imputation sont fondées sur la tranche de revenu et la taille du ménage. Pour le revenu personnel total, les classes d'imputation sont fondées sur l'âge et le sexe plutôt que sur la taille du ménage. L'imputation a également été restreinte par la tranche de revenu fournie par le répondant ainsi que le revenu total du ménage ou le revenu personnel total si celui-ci est fourni.

4. Imputation à partir d'un modèle de revenu à l'aide des données de l'ESCC et des dossiers administratifs

Pour les trois autres quarts des répondants, la méthode d'imputation par enregistrement donneur utilisée ci-dessus ne convient pas en raison du grand nombre d'enregistrements nécessitant une valeur imputée comparativement au nombre d'enregistrements donneurs potentiels. C'est pourquoi des modèles de revenu ont été créés à l'aide de données fiscales agrégées et d'un certain nombre de variables de l'ESCC.
L'échantillon de l'ESCC a été divisé en 10 groupes, chaque groupe ayant une représentation de tous les revenus. Pour imputer les revenus d'un groupe, les neuf autres groupes de répondants à l'ESCC ont été agrégés ensemble et un modèle a été ajusté en fonction de leurs données fiscales agrégées. Les variables de l'ESCC ainsi que le logarithme du revenu médian du code postal (ou seulement les trois premiers caractères du code postal pour les lieux que peu de personnes habitent) ont été utilisés comme prédicteurs du revenu. Le modèle résultant a ensuite été appliqué à l'autre groupe afin d'imputer un revenu pour chaque répondant.
Les variables de l'ESCC utilisées dans la modélisation étaient les suivantes :

- DHHDVHSZ (taille du ménage)
- DHHDVL18 (nombre de membres du ménage âgés de moins de 18 ans)
- Geodvur & geodvur2 (centre de population ou région rurale)
- ehg2dvh9 (niveau de scolarité le plus élevé dans le ménage)
- ehg2dvr9 (niveau de scolarité le plus élevé du répondant)
- GEO_PRV (province/territoire)
- LBF_10 (employé, travail autonome, entreprise familiale)
- LBF_030 (avait plus d'un emploi)
- LBFDVHPW (nombre habituel d'heures de travail par semaine)
- LBFDVPFT (statut à temps plein ou à temps partiel)
- LBFDVING (groupe d'industrie, selon le SCIAN de 2012)

- LBFDVOCG (groupe professionnel, selon la CNP de 2011)
- SDC_015 (faisant partie des Premières Nations, des Métis ou des Inuits)
- SDC_010A-SDC_010U (origine ethnique/culturelle)
- SDC_IM3 (immigrant reçu)
- DHH_OWN (détient ou loue un logement)
- DHH_MS (état matrimonial)
- DHH_AGE (âge du répondant)
- DHH_SEX (sexe du répondant)
- GEN_005 (autoévaluation de la santé)
- GEN_015 (autoévaluation de l'état de santé mentale)
- GEODVPSZ (classification comme centre de population ou région rurale)
- FSCDVHFS (niveau de sécurité alimentaire du ménage)
- MAC_005 (activité principale la semaine précédente)
- INS_010A (régime d'assurance offert par le gouvernement)

Le modèle utilisé était présenté comme suit :

$$\log(y) = \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n$$

Où y était le revenu issu des fichiers de données fiscales, β_i représentait les coefficients et X_i représentait les valeurs des variables indépendantes qui ont été retenues dans la liste ci-dessus. Les valeurs estimées issues des modèles ont été converties en revenu du ménage et en revenu personnel et elles ont été utilisées pour créer les variables finales du revenu de partage de l'ESCC de 2016.

5. Fichier de données

Le revenu total du ménage (ou le revenu personnel total, s'il y a lieu) a été imputé à partir d'un modèle pour environ deux tiers des répondants du fichier de partage de l'ESCC de 2016. La qualité des revenus modélisés a été évaluée avant la diffusion des données. Si les modèles ont généralement permis de déterminer si les répondants avaient des revenus supérieurs ou inférieurs, les revenus modélisés n'avaient pas la précision d'un montant en dollars précis. C'est pourquoi les variables liées au revenu total à l'échelle du ménage et à l'échelle de la personne (INC_021 et INC_041) sont absentes du fichier de partage. Elles ont été remplacées par les variables groupées INC_020 et INC_040. La variable groupée du revenu du fichier de partage de l'ESCC attribue correctement les répondants à leur groupe de revenu dans environ 60 % des cas. Les répondants se trouvent dans un seul groupe de revenu dans environ 88 % des cas. De même, les variables déciles du revenu (INCDVRCA, INDVRPR et INCDVRRS) ont été remplacées par des variables quintiles (INCDVSCA, INCDVSPR, INCDVSRS). Ces quintiles sont calculés en fonction du montant en dollars précis fourni par le répondant ou imputé à partir d'un enregistrement donneur de l'ESCC ou à partir du modèle. Les variables des sources de revenu (INC_005A-O, INC_Q025A-O) et les variables de principale source de revenu (INC_015, INC_035) ont été retirées en raison du taux élevé de données manquantes, seules les données du répondant étant la source. Les indicateurs INCFSH et INCFSP informent les utilisateurs de la méthode utilisée pour établir les variables du revenu.

Tableau 1 Valeurs pour INCFSH

INCFSH	2016 Code
1	Déclarée par le répondant
2	Imputée par donneur
3	Imputée d'un modèle de revenu

Tableau 2 Valeurs pour INCFSP

INCFSP	2016 Code
1	Déclarée par le répondant
2	Imputée par donneur
3	Imputée d'un modèle de revenu
6	Sans objet

Pour obtenir plus d'information, veuillez communiquer avec les Services à la clientèle au (613-951-1746; télécopieur : 613-951-0792 ou statcan.HD-DS.statcan@canada.ca).