Variables et sources de revenu dans le fichier maître de l'Enquête sur la santé dans les collectivités canadiennes

1. Introduction

Des variables sur le revenu sont diffusées dans le cadre de l'Enquête sur la santé dans les collectivités canadiennes (ESCC) en raison de leur lien possible avec les variables relatives à la santé. La variable relative au revenu la plus fréquemment utilisée dans les analyses est le revenu total du ménage (variable INC_021). Cependant, étant donné la nature sensible de la déclaration du revenu, dans le passé, le taux de réponse à la question sur le revenu total du ménage était de 65 % à 70 % chez les répondants à l'ESCC. En plus d'un faible taux de réponse, une étude menée en 2009 suggérait que les non-répondants à la question sur le revenu avaient des caractéristiques de santé différentes des répondants. En outre, une étude de 2015 montrait que le revenu total du ménage déclaré par les répondants était possiblement sous- évalué (par rapport aux dossiers d'impôt) et que les données étaient moins fiables chez les ménages à revenu plus faible. Afin d'améliorer la qualité des variables relatives au revenu, tout en réduisant le fardeau imposé aux répondants et en économisant sur les coûts relatifs à la collecte, le couplage des données fiscales des répondants a commencé au cycle 2016 de l'ESCC.

Pour 2020, les variables sur le revenu de l'ESCC sont un ensemble de données fiscales (~84 %), de données recueillies auprès des répondants (~3 %) et de montants de revenu imputés (~13 %). La source utilisée pour créer les montants des revenus totaux pour chaque répondant est désignée par INCFIMPH en ce qui concerne le revenu des ménages (INC_021) et par INCFIMPP pour ce qui est du revenu personnel (INC_041). Les tableaux 1 et 2 ci-dessous fournissent davantage de renseignements sur les valeurs de ces deux variables, ainsi que sur la concordance avec l'indicateur précédent, INCFIMP4. À partir de 2019, toute information en provenance des données fiscales sera indiquée comme imputée.

Tableau 1. Valeurs pour INCFIMPH et correspondance avec l'indicateur de 2018 et de 2015

INCFIMPH	Code 2020	Code 2018	Correspondance avec le code 2015 INCFIMP4
Couplées aux données d'impôt	2	1 et 2	S.O.
Données recueillies auprès des répondants	1	3	1
Imputées en fonction d'un intervalle de revenu déclaré	2	4	2 et 4
Imputées sans intervalle de revenu	2	5	3

Tableau 2. Valeurs pour INCFIMPP et correspondance avec l'indicateur de 2018

INCFIMPP	Code 2020	Code 2018
Couplées aux données d'impôt	2	1 & 2
Imputées sans intervalle de revenu	2	5
Sans object	6	6

Les utilisateurs qui souhaitent faire des analyses univariées axées sur le revenu du ménage devraient recourir à d'autres sources de données sur le revenu plutôt qu'à l'ESCC. Pour analyser à la fois le revenu des ménages et les variables sur la santé, les utilisateurs devraient utiliser des variables dérivées du revenu telles que les quintiles de revenu, plutôt que d'utiliser la valeur exacte du revenu. La source utilisée pour créer les montants des revenus comporte de légères différences et des degrés variables de fiabilité. Le processus d'imputation permet de prévoir adéquatement les quintiles de revenu. Cependant, il y a d'autres variables pour évaluer la valeur exacte du revenu.

Ce document fournit un aperçu général des sources de revenus, ainsi que du processus d'imputation.

2. Données fiscales

En ce qui concerne les répondants qui ne refusent pas le couplage avec les données fiscales et dont les dossiers d'impôt peuvent être couplés, leurs sources de revenus (INC_005A-O, INC_Q025A-O), leur principale source de revenus (INC_015, INC_035) et les montants totaux de leur revenu (INC_021, INC_041) sont déterminés au moyen des dossiers d'impôt. Les dossiers d'impôt ont été utilisés au niveau individuel et du ménage. Tandis que seulement environ 84 % des données des répondants à l'ESCC ont été couplées aux dossiers d'impôt, les données couplées étaient d'une qualité très élevée car le couplage a été effectué dans l'Environnement de couplage de données sociales[1].

Les dossiers d'impôt viennent d'une source parmi deux. Lorsque c'était possible, les dossiers d'impôt de 2019 ont été utilisés. Cela correspond à l'année de référence utilisée par les répondants en ce qui concerne les revenus déclarés et les sources. Lorsqu'il n'était pas possible de faire un couplage avec les données de 2019, les données fiscales de 2018 étaient utilisées. En plus du changement d'année, les fichiers de 2018 ont été davantage traités et ont donc des concepts légèrement différents. Le fichier de 2018 regroupe les personnes selon le concept de « famille » et non de « ménage ». Dans certains cas, les sources et les montants des revenus peuvent ne pas se fonder sur le même ensemble de personnes dans les fichiers de 2018 et dans les fichiers de 2019.

Les utilisateurs devraient connaître les différences entre les données déclarées par les répondants et les données sur le revenu provenant des dossiers d'impôt. Dans l'ESCC, la taille du ménage est établie en fonction du nombre d'occupants répertoriés par l'intervieweur au moment de l'interview. La période de référence pour les revenus déclarés des répondants est 2019, et 2019 ou 2018 pour les dossiers d'impôt couplés. Dans certains cas, au moment de l'interview, la composition ou la taille du ménage peut avoir changé depuis la période de référence en ce qui concerne le revenu. Les revenus totaux du ménage se fondent sur les déclarants couplés pour l'exercice financier de référence, pas sur la taille déterminée du ménage dans le cadre de l'ESCC en 2020.

Des études internes dans le cadre desquelles les données sur le revenu des répondants à l'ESCC ont été comparées aux dossiers d'impôt couplés ont mis en évidence d'autres différences clés. En moyenne, les répondants sous-évaluent légèrement le revenu total, par rapport aux revenus indiqués sur leur déclaration de revenus. C'est pourquoi, en moyenne, les revenus du ménage et personnels totaux seront supérieurs à ceux attendus si le répondant avait répondu aux questions. En outre, les dossiers d'impôt montrent un portrait plus complet des sources de revenus. Les sources de faibles revenus, comme les dividendes et les intérêts (INC_005C, INC_025C), se trouvent dans les dossiers d'impôt. Cependant, les répondants sont moins susceptibles de les déclarer. De plus, les revenus provenant de l'aide sociale/du

[1] https://www.statcan.gc.ca/fra/ecds/index

bien-être social (INC_005J, INC_025J) sont aussi plus prévalents dans les dossiers d'impôt par rapport aux données déclarées.

3. Données des répondants

Les données des répondants ont été utilisées lorsqu'il n'était pas possible de faire un couplage avec les données fiscales. Comme mentionné ci-dessus, les études ont découvert des divergences entre les données recueillies auprès des répondants et leurs dossiers d'impôt. Les répondants ont tendance à oublier de déclarer certaines sources de revenus, comme les dividendes et intérêts (INC_005C, INC_025C) et l'aide sociale ou le bien-être social (INC_005J, INC_025J). En moyenne, les revenus déclarés sont inférieurs aux revenus consignés dans les dossiers d'impôt couplés. Souvent, les revenus totaux déclarés sont aussi arrondis. Lorsque c'était possible, les dossiers d'impôt ont été utilisés au lieu des données des répondants.

4. Imputation du revenu

Dans environ 13 % des cas, les revenus ont été imputés pour le revenu total du ménage et dans environ 16 % des cas, le revenu personnel total a été imputé (s'il y a lieu). L'imputation du revenu a été réalisée pour les montants totaux des revenus lorsqu'aucune donnée n'avait été recueillie et qu'aucun couplage avec les données fiscales n'avait été trouvé ou que le couplage avait été refusé par les répondants. Seuls les montants totaux des revenus ont été imputés, pas les sources de revenus. Lorsque le revenu total a été imputé pour INC_021 ou INC_041, les questions sur les sources de revenus (INC_005A-O, INC_Q025A- O) et les questions sur la source principale de revenu (INC_015, INC_035) sont produites si le répondant a répondu. Sinon, elles n'apparaissent pas.

4.1 Aperçu du processus d'imputation

Une méthode d'imputation par le plus proche voisin est utilisée afin d'imputer le revenu. Le revenu du ménage et le revenu personnel modélisés décrits à la section suivante sont utilisés comme mesure de distance pour déterminer la paire d'enregistrements donneur-bénéficiaire qui est la plus « proche » dans les classes d'imputation.

4.1.1 Revenu modélisé

Une variable auxiliaire importante utilisée dans le processus d'imputation est le **revenu modélisé**. Il est calculé pour tous les répondants à l'ESCC (répondant ou non aux questions sur le revenu) en utilisant un processus en trois étapes. Les détails de son calcul sont donnés ici.

<u>Étape 1</u>
À l'aide d'un modèle de régression, le revenu personnel de tous les membres d'un ménage répondant est dérivé. Le revenu personnel total du répondant sélectionné et de tout autre membre du ménage est dérivé séparément. Le revenu personnel total des répondants est obtenu tout d'abord au moyen de variables, comme le groupe d'âge, le niveau de scolarité, les sources de revenus, la province de résidence, l'état matrimonial, la taille du ménage, le fait que le logement est loué ou possédé, le statut d'immigrant et l'état de santé, par exemple si la personne a un cancer.

Le revenu personnel de tous les autres membres est obtenu au moyen des mêmes variables que celles indiquées ci-dessus. Cependant, elles excluent le statut d'immigrant et les renseignements personnels sur la santé.

En ce qui concerne le revenu personnel total, l'étape 2 ci-dessous est sautée, et la valeur imputée uniquement pour le répondant à l'ESCC est utilisée pour déterminer le voisin le plus proche dans le cadre du processus d'imputation.

Étape 2
Une valeur de revenu du ménage préliminaire est dérivée en additionnant tous les revenus personnels de l'étape 1. Les totaux résultants ne reflètent pas fidèlement les renseignements sur le revenu recueillis par l'ESCC de sorte que ces valeurs nécessitent d'autres ajustements.

Étape 3
Le revenu médian des ménages à partir des données fiscales T1 est calculé au niveau du code postal selon le groupe de taille de ménage. Au moyen d'un modèle de régression utilisant le revenu médian tiré des données fiscales, des variables sur la santé et du revenu préliminaire obtenus à l'étape 1 pour le revenu personnel, et à l'étape 2 pour les revenus des ménages, un revenu modélisé définitif a été obtenu. Ce revenu modélisé définitif n'apparaît pas dans le fichier de données définitif, mais est plutôt utilisé en tant que variable auxiliaire dans le processus d'imputation par le plus proche voisin pour le revenu total.

4.1.2 Choix d'un enregistrement donneur

Les classes d'imputation sont créées différemment, à savoir si le revenu imputé est un revenu total du ménage ou un revenu personnel total, et si les répondants ont fourni un intervalle de revenu ou non. Pour le revenu total du ménage et les intervalles de revenu, les classes d'imputation sont fondées sur l'intervalle de revenu et la taille du ménage. Dans le cas des personnes qui ne fournissent pas d'intervalle de revenu, les classes d'imputation pour le revenu total du ménage sont créées en fonction de la région sociosanitaire et de la taille du ménage. Pour le revenu personnel total, les classes d'imputation sont fondées sur l'âge et le sexe plutôt que sur la taille du ménage.

5. Fichier de données

Les utilisateurs peuvent se servir des indicateurs de revenu INCFIMPH et INCFIMPP pour déterminer la source des variables sur le revenu et leur qualité. Les variables dérivées du revenu, comme INCDHH, INCDADR, INCDRCA et autres, se fonderont sur la valeur imputée du revenu du ménage lorsqu'une imputation a été réalisée.

Pour obtenir plus de renseignements, veuillez communiquer avec les Services à la clientèle (613-951-1746; télécopieur : 613-951-0792 ou statcan.Hd-Ds.statcan@canada.ca).