Enquête sur la santé dans les collectivités canadiennes (ESCC)

Composante annuelle

Guide de l'utilisateur

Fichier de microdonnées de 2023

Octobre 2024

Statistics Canada Statistique Canada

Canada

TABLE DES MATIÈRES

2. HISTORIQUE 8

3. REMANIEMENT DE L'ESCC 10

3.1 Remaniement de l'ESCC en 2015 10

3.2. Remaniement de l'ESCC en 2022 10

4. STRUCTURE DU CONTENU DE L'ESCC 11

4.1 Contenu de base 11

4.2 Contenu thématique 11

4.3 Contenu optionnel 11

4.4 Contenu de réponse rapide 12

4.5 Contenu des fichiers de microdonnées 12

5. PLAN D'ÉCHANTILLONNAGE 12

5.1 Population cible 12

5.2 Régions sociosanitaires 12

5.3 Bases de sondage et stratégies d'échantillonnage des ménages 13

5.3.1 Échantillonnage des ménages à partir de la base aréolaire 13

5.3.2 Échantillonnage des ménages du recensement de 2021 pour l'initiative PADD. 15

5.4 Taille et répartition de l'échantillon 15

5.5 Répartition de l'échantillon par période de collecte des données 16

5.6 Échantillonnage des personnes interviewées 16

6. COLLECTE DES DONNÉES 17

6.1 Questionnaires électroniques 17

6.2 Développement des applications de l'ESCC 18

6.3 Formation des intervieweurs 18

6.4 L'interview 19

6.5 Opérations sur le terrain 20

6.6 Contrôle de la qualité et gestion de la collecte 21

7. TRAITEMENT DES DONNÉES 21

7.1 Vérification 21

7.2 Flux 21

7.3 Codage 22

7.4 Création de variables dérivées 22

7.5 Pondération 23

7.6 Variables du revenu pour 2023 - couplage et imputation 23

7.7 Imputation du code postal 24

7.8 Codage du genre 24

8. PONDÉRATION 25

8.1 Aperçu 25

8.2 Pondération de l'échantillon de la base aréolaire 27

8.3 Pondération de l'échantillon de la base de sondage du PADD 29

8.4 Ajustement des poids finaux en fonction de la combinaison de la base aréolaire et la base PADD 30

8.5 Création d'un poids partagé 32

9. QUALITÉ DES DONNÉES 33

9.1 Taux de réponse 33

9.2 Erreurs dans les enquêtes 33

9.2.1 Erreurs non dues à l'échantillonnage 33

9.2.2 Erreurs dues à l'échantillonnage 34

10. LIGNES DIRECTRICES POUR LA TOTALISATION, L'ANALYSE ET LA DIFFUSION 35

10.1 Lignes directrices pour l'arrondissement 35

10.2 Lignes directrices pour la pondération de l'échantillon en vue de la totalisation 36

10.2.1 Définitions : estimations de type nominal, estimations quantitatives 36

10.2.2 Totalisation d'estimations de type nominal 37

10.2.3 Totalisation d'estimations quantitatives 37

10.3 Lignes directrices pour l'analyse statistique 38
10.4 Lignes directrices pour la diffusion 38
10.4.1 Fichier maître ou de partage 39
10.4.2 Règles de diffusion pour les estimations de proportions 40
10.4.3 Règles de diffusion pour les estimations de comptes, de moyennes et de totaux 41
10.4.4 Règles de diffusion pour les différences et les rapports 41
10.4.5 Règles additionnelles au sujet des intervalles de confiance 42
11. TABLEAUX DE LA VARIABILITÉ D'ÉCHANTILLONNAGE APPROXIMATIVE 42
11.1 Comment utiliser les tableaux de c.v. pour calculer les limites de confiance 44
11.2 Comment utiliser les tableaux de c.v. pour les estimations de type nominal 45
11.3 Exemples d'utilisation des tableaux de c.v. pour des estimations de type nominal afin de calculer les intervalles de confiance 47
11.4 Comment utiliser les tableaux de c.v. pour effectuer un test Z 50
11.5 Exemple d'utilisation des tableaux de c.v. pour effectuer un test Z 50
11.6 Variances ou coefficients de variation exacts 50
12. FICHIERS DE MICRODONNÉES: DESCRIPTION, ACCÈS ET UTILISATION 51
12.1 Fichiers maîtres 52
12.1.1 Centre de données de recherche 52
12.1.2 Totalisations personnalisées 52
12.1.3 Télé-accès 52
12.1.4 Système d'accès à distance en temps réel 52
12.2 Fichiers de partage 53
12.3 Fichiers de microdonnées à grande diffusion 53
12.4 Utilisation des fichiers de l'ESCC : fichier annuel ou fichier deux ans? 55
12.5 Utilisation de la variable de pondération 55
12.6 Convention appliquée pour nommer les variables 56
12.7 Dictionnaires de données 57
ANNEXE A -L'ENQUÊTE SUR LA SANTÉ DANS LES COLLECTIVITÉS CANADIENNES (ESCC) - APERÇU DU CONTENU - 2023 59
ANNEXE B - GÉOGRAPHIE DISPONIBLE SUR LE FICHIER MAÎTRE ET DE PARTAGE ET CODES CORRESPONDANTS: CANADA, PROVINCES, RÉGIONS SOCIOSANITAIRES ET GROUPES HOMOLOGUES 63
ANNEXE C - RÉPARTITION DE L'ÉCHANTILLON PAR PROVINCE (ESCC DE 2023) 67
ANNEXE D - TAUX DE RÉPONSE PAR PROVINCE (ESCC DE 2023) 69

QUOI DE NEUF DANS L'ENQUÊTE SUR LA SANTÉ DANS LES COLLECTIVITÉS CANADIENNES (ESCC) 2023?

En plus du précédent remaniement de 2015, l'Enquête sur la santé dans les collectivités canadiennes (ESCC) a fait l'objet d'un deuxième remaniement majeur en 2022. Ce remaniement était axé sur un changement de mode de collecte, lequel est passé des interviews téléphoniques assistées par ordinateur (ITAO)/interviews sur place assistées par ordinateur (IPAO) à un format de questionnaire électronique (QE) comprenant une ITAO/IPAO de suivi en cas de non-réponse. Par conséquent, il convient d'être prudent lors de la comparaison des données entre différents cycles (c.-à-d. les données antérieures à 2015, les données de 2015 à 2021, les données de 2022 à aujourd'hui).

En outre, la taille de l'échantillon et la couverture pour les territoires ont été augmentées afin d'obtenir une couverture intégrale du Nord pour le fichier de 2022. Étant donné que les territoires ne sont normalement couverts que par des fichiers de deux ans, les données du Nord pour 2022 sont conservées dans un fichier de microdonnées distinct afin que le fichier annuel ne couvre que les provinces. En outre, le plan d'échantillonnage pour le Nord est revenu au plan biennal pour 2023-2024, de sorte que la couverture annuelle du nord en 2022 est un événement unique propre à cette année.

Échantillonage

Pour le cycle de 2023 de l'ESCC, la couverture de la population canadienne selon l'âge a été ajustée pour ne couvrir que la population adulte de 18 ans et plus, ce qui a réduit la couverture des personnes âgées de 12 à 17 ans. Ce changement a été mis en œuvre en raison du lancement de l'Enquête canadienne sur la santé des enfants et des jeunes, qui couvrira les jeunes de 12 à 17 ans avec un échantillon plus riche et un contenu mieux conçu pour couvrir les caractéristiques, les comportements et les résultats de santé de cette population.

Le Recensement 2021 a été choisi comme cadre supplémentaire pour l'ESCC 2023, car il s'agit de la meilleure option pour permettre la stratification selon les caractéristiques de la population. Les données du recensement 2021 ont été utilisées pour cibler les ménages dont les membres ont été identifiés lors du recensement 2021 comme appartenant à des groupes faisant partie de l'initiative appelée « Plan d'action pour les données désagrégées, PADD ». Un échantillon supplémentaire de 37 000 ménages a été sélectionné à partir des données du formulaire détaillé du recensement de 2021. Ces ménages ont été répartis également au cours des trois dernières périodes de collecte de 2023. Cet échantillon supplémentaire a été sélectionné au niveau de la province et du groupe d'équité.

Collecte

En 2023, la collecte de l'ESCC a été mise à jour pour permettre aux répondants de répondre directement à l'enquête au moyen d'un questionnaire électronique (QE) en ligne, accompagné des ITAO et des IPAO de suivi en cas de non-réponse. Avant 2022, le contenu de l'ESCC était conçu exclusivement pour les interviews assistées par ordinateur (IAO). Le passage à la collecte de QE a constitué un changement important qui a nécessité des mises à jour considérables du format de

tous les modules de l'ESCC. C'est pourquoi il convient d'être prudent lors de la comparaison des données entre les différents cycles (c.-à-d. les données antérieures à 2015, les données de 2015 à 2021, les données publiées pour le cycle 2022 et les suivants).

Contenu

Comme il est indiqué plus haut, le passage à la collecte du QE a nécessité de nombreuses mises à jour du format de tous les modules de l'ESCC. Par exemple, les changements suivants ont été appliqués à l'ensemble du contenu de l'ESCC, le cas échéant.

- Les notes de l'intervieweur pour l'approfondissement des réponses des répondants ont été remplacées par un texte d'aide à l'écran condensé.
- Les questions et les catégories de réponses correspondantes ont été raccourcies par souci de clarté.
- Les questions répétitives ont été regroupées sous un même en-tête, au lieu de former une série de questions individuelles (p. ex. en utilisant une grille pour poser de multiples questions liées).
- Le nombre de contrôles nécessaires pour vérifier les réponses des répondants a été réduit.
- À l'exception des questions requises pour vérifier l'identité du répondant, la non-réponse était autorisée pour tous les contenus (c.-à-d. la possibilité de sauter des questions).

Vous trouverez ci-dessous un aperçu de haut niveau des mises à jour apportées au contenu de base et thématique de l'ESCC :

Changements apportés aux modules de base :

- Un nouveau module autonome **Date de naissance (AGE)**; ce module était auparavant un sous-bloc du module **Âge du répondant (ANC1)**.
- Le module **Conditions chroniques (CCC)** a été scindé en deux modules : un module CCC mis à jour et un nouveau module **Conditions chroniques 1 (CC1)**.
- Le module **Usage du tabac (SMK)** a été divisé en trois nouveaux modules : **Usage actuel de la cigarette (CSS)**; **Usage antérieur du tabac (SPU)**; et **Cigarettes électroniques et vapotage (ECV)**.
- Le module **Mesures de la satisfaction à l'égard de la vie (LSM)** a été ajouté en tant que nouveau sous-bloc **Santé général (GEN)**. Auparavant, ce module faisait partie du sous-bloc minimal **bien-être subjectif (SLM)**.
- Un nouveau module autonome **Grossesse (PRS)**; ce module faisait auparavant partie du module **Activité principale (MAC)**.
- Un nouveau module autonome **Perception du poids (WTP)**; ce module faisait auparavant partie du module **Taille et poids (HWT)**.
- Le module **Matrice des relations (REL)** et le sous-bloc **Lien de parenté sans confirmation (RNC)** ont été combinés pour créer le nouveau module **Lien de parenté (RWC)**.
- Les modules suivants ont été mis à jour pour s'aligner avec le contenu harmonisé standard de Statistique Canada :
    - **Activité principale (MA)** et sous-bloc **Fréquentation scolaire (EDC)**
    - **Lieu de naissance, immigration et citoyenneté (IM)**
    - **Identité autochtone (ABM)**
    - **Orientation sexuelle (SOR)**

- **Vérification (VER2)**
- Le module **Cigarettes électroniques et vapotage 2 (ECV2)** n'existe plus puisque les questions sont maintenant dans le module **Cigarettes électroniques et vapotage (ECV)**.
- Un nouveau module distinct **Conditions à long terme (LTC)** ; ce module porte sur l'identification en tant que personne ayant une incapacité.
- Le module **Activité principale 1 (MAC)** n'existe plus puisqu'il fait maintenant partie du module **Activité principale 2 (MA)**.
- **Sécurité alimentaire (FSC)** était un thème de deux ans en 2021-2022, mais a été ajouté au contenu de base en 2023.
- **Services de soins de santé à domicile (HMC)** un thème de deux ans en 2021-2022, mais a été ajouté au contenu de base en 2023.
- **Fournisseur habituel de soins de santé (RHC)** est désormais un module de base (il s'agissait d'un module thématique en 2022).

Modifications des modules thématiques

- Le module **Habitudes alimentaires (EAH)** a été remanié, en se basant sur le module original **Consommation de fruits et légumes (FVC)**.
- **Vaccin contre la grippe (FLU)** a été ajouté en tant que module thématique en 2022; auparavant, il faisait partie du contenu de base de l'ESCC de 2015 à 2020.
- Les modules **Santé buccale (OHM)** et **Santé buccale 3 (OHM3)** ont été introduits en 2022 pour recueillir des données sur la santé bucco-dentaire et les habitudes de soins dentaires (modification du module optionnel OHT en 2020).
- Le module **Coût des ordonnances (PCN)** a été ajouté pour recueillir des données sur le non-respect d'ordonnances de médicaments en raison des coûts (modification du module de réponse rapide de 2016 intitulé **Ordonnances - Non-respect lié aux coûts**).
- Le module **Utilisation de médicaments – antidouleur (PRM)** a été ajouté en tant que module autonome. Il faisait auparavant partie du module **Utilisation de médicaments (MED)** et recueille des renseignements sur la consommation de médicaments analgésiques, qu'ils soient prescrits ou non. Ces questions faisaient auparavant partie du contenu thématique en 2018 et du contenu optionnel en 2019 et 2020.
- Un module **Passeport vaccinal COVID-19 (PVC)** a été ajouté pour recueillir des données sur les passeports vaccinaux pour la COVID-19.
- Le module **Fournisseur habituel de soins de santé (RHC)** a été ajouté pour recueillir des données indiquant si les personnes interrogées ont un fournisseur de soins de santé habituel (modification du module **Soins de santé primaires (PHC)** précédent).
- Le module **Utilisation d'équipements protecteur (UPE)** ont été reformaté sous forme de grille. Il s'agissait d'un module thématique en 2017 et 2018 et d'un module optionnel en 2020.
- Le module **Washington Group - mesure d'incapacité (WDM)** a été reformaté sous forme de grille. Il s'agissait d'un contenu thématique en 2017 et 2018.
- **Équilibre travail-famille (WLB)** et **Productivité au travail (WPL)** sont de nouveaux modules de réponse rapide pour 2022.

- Le module **COVID-19 2 (COV2)** a été divisé en sept petits modules par sujet : **COVA** (la santé mentale pendant la pandémie), **COVB** (précautions prises pendant la pandémie), **COVC** (a présenté des symptômes de COVID-19), **COVD** (le statut vaccinal), **COVE** (les raisons pour le statut vaccinal), **COVF** (la probabilité de recevoir une dose de rappel), et **COVG** (la probabilité de recevoir un rappel annuel).
- **Capacités (WDM)** a été remplacé par l'Indice **de l'état de santé (HUI)**
- **Activités physiques – adultes 18+ (PAA)** a été remplacé par deux modules : **Activité physique modérée (MPA)** et **Autre activités physiques (OPA)**
- **Consommation d'alcool au cours de la dernière semaine (ALW) –** nouveau module thématique, était contenu optionnel en 2020

Modules optionnels pour 2023 :

- **Bien-être mentale (PMS) –** Nouveau module
- **Utilisation d'équipement protecteur (UPE)** – était un module thématique de 2 ans pour 2021-2022
- **Activités de la vie quotidienne (ADL) –** était un module thématique d'un an en 2021
- **Expériences de maternité (MEX)** – était un module thématique de 2 ans pour 2021-2022
- **Consultations en santé mentale (CMH) –** était contenu optionnel en 2020
- **Santé mentale (DEP) –** a été nommé « Dépression » et contenu optionnel en 2021
- **Provisions sociales (SPS) –** a été utilisé pour la dernière fois en tant que contenu optionnel en 2021

Les modules suivants ont été retirés de l'enquête pour 2023 :

- **Perception du poids (WTP)**
- **Passeport vaccinal COVID-19 (PVC)**
- **Blessures (INJ)**
- **Santé buccale (OHM et OHM3)**
- **Comportements sédentaires (SBE)**
- **Sommeil (SLP)**
- **Expériences maternelles – usage du tabac pendant la grossesse (MXS)**
- **Expériences maternelles – consommation d'alcool pendant la grossesse (MXA)**
- **Couverture d'assurance (INL et INP)**
- **Côut des ordonnances (PCN)**
- **Activités physiques - jeunesse (PAY)**

Pour l'échantillon d'adultes, l'ESCC a recommencé à utiliser la base aréolaire de l'Enquête sur la population active (EPA) en 2022 au lieu du Fichier de l'univers des logements (FUL) qui avait été utilisé en 2021.

Pour des renseignements plus détaillés sur le contenu de l'ESCC, voir l'annexe A.

Géographie
L'échantillonnage pour l'ESCC a été mis en œuvre à l'échelle de la région sociosanitaire à l'aide de la définition des RH de 2018. Aux fins de la pondération et de la diffusion, la variable géographique incluse GEODVHR4 est fondée sur les définitions des régions sociosanitaires de 2023. Voir (Régions sociosanitaires : limites et correspondance avec la géographie du recensement (statcan.gc.ca))

Documentation
- Errata : Les erreurs relevées dans les fichiers et produits de données de l'ESCC après la diffusion sont communiquées aux utilisateurs dans un document des erreurs cumulatives intitulé « ESCC Errata ». L'errata fournit des renseignements sur :
    - les produits touchés (p. ex. le fichier maître, les fichiers partagés ou le FMGD);
    - les années touchées;
    - les corrections suggérées (si possible);
    - les étapes à suivre pour effectuer la correction.

Depuis la publication de l'ESCC de 2021, il y a eu une entrée dans le document Errate:
- Erreur dans PHC_030 à PHC_060

Pour votre commodité, le document des erreurs contient un index à la première page. Celui-ci fournit une liste des modules et des années touchés. Pour vérifier si une variable particulière est affectée, suivre les hyperliens menant aux numéros des erreurs connexes.

Une copie à jour d'ESCC Errata peut être obtenue en communiquant avec le Centre de données sur la santé de la population de la Direction de la statistique de la santé au 613-951-1746 ou à l'adresse HD-DS@statcan.gc.ca.

1. Introduction
L'Enquête sur la santé dans les collectivités canadiennes (ESCC) est une enquête transversale qui vise à recueillir des renseignements sur l'état de santé, l'utilisation des soins de santé et les déterminants de la santé de la population canadienne. Elle est réalisée auprès d'un grand échantillon de répondants et conçue pour fournir des estimations fiables à l'échelle de la région sociosanitaire. Avant 2022, l'ESCC était réalisée par interview assistée par ordinateur, par téléphone (ITAO) ou en personne (IPAO). En 2022, l'enquête est passée à l'autodéclaration directe en utilisant un questionnaire électronique en ligne, avec l'ajout d'interviews téléphoniques assistées par ordinateur (ITAO) et d'interviews sur place assistées par ordinateur (IPAO) pour les cas de non-réponse. L'ESCC a également fait l'objet d'un remaniement majeur qui a commencé en 2012 et a été mis en œuvre en 2015. Un deuxième remaniement a eu lieu en 2022. Les détails de ces remaniements sont présentés au chapitre 3.

Les objectifs de l'enquête sont les suivants:
- soutenir les programmes de surveillance en santé en produisant des données sur la santé à l'échelle nationale, provinciale et à l'échelle des régions sociosanitaires;
- offrir une source unique de renseignements pour la recherche sur la santé des petites populations et sur des caractéristiques rares;

- diffuser de l'information facilement accessible à une communauté diversifiée d'utilisateurs dans un temps opportun;
- proposer un instrument d'enquête flexible qui inclut une option de réponse rapide pour répondre à des questions émergentes liées à la santé de la population.

Les données de l'ESCC sont normalement recueillies auprès des personnes âgées de 18 ans et plus demeurant dans des logements privés dans plus de 100 régions sanitaires couvrant toutes les provinces et tous les territoires. Sont exclues de la base de sondage les personnes vivant sur les réserves indiennes et les terres de la Couronne, les résidents d'institutions (institutions de santé, prisons, institutions religieuses, couvents, etc.), les membres à temps plein des Forces canadiennes, et les personnes vivant dans certaines régions éloignées. L'ESCC couvre environ 97 % de la population canadienne âgée de 18 ans et plus.

Le présent document a pour but de faciliter la manipulation des fichiers de microdonnées de l'ESCC et de décrire la méthodologie utilisée. L'ESCC produit trois types de fichiers de microdonnées : les fichiers maîtres, les fichiers de partage et les fichiers de microdonnées à grande diffusion (FMGD). Les caractéristiques de chacun de ces fichiers sont présentées dans ce guide. Les fichiers maîtres et les fichiers de partage seront publiés le 2 octobre 2024.

Pour toute question concernant les ensembles de données ou leur utilisation, s'adresser à :

Service d'aide aux utilisateurs :	1-800-949-9491
Totalisations spéciales ou renseignements généraux sur les données:	
Services personnalisés à la clientèle, Direction de la statistique de la santé:	HD-DS@statcan.ca
Renseignements sur le télé-accès:	statcan.cchssm-esccds.statcan@statcan.gc.ca

2. HISTORIQUE

En 1991, le Groupe de travail national sur l'information en matière de santé a relevé plusieurs questions et problèmes posés par le système d'information sur la santé. Selon ses membres, les données étaient fragmentées, elles étaient incomplètes, elles ne pouvaient être échangées facilement et elles n'étaient pas analysées aussi pleinement que possible; en outre, les résultats des études réalisées n'atteignaient pas de façon régulière la population canadienne[1].

En 1999, pour résoudre ces problèmes, l'Institut canadien d'information sur la santé (ICIS), Statistique Canada et Santé Canada ont conjugué leurs efforts en vue de créer un Carnet de route de l'information sur la santé. L'Enquête sur la santé dans les collectivités canadiennes (ESCC) a été conçue à partir de ce mandat. Le format, le contenu et les objectifs de l'enquête ont été définis après avoir mené des consultations approfondies auprès de spécialistes et d'intervenants fédéraux, provinciaux et de régions sociosanitaires communautaires en vue de déterminer leurs exigences en matière de données[2]. La collecte de données dans le cadre de l'enquête a débuté en 2000.

Afin de combler les nombreux besoins en données, le cycle de collecte des données de l'ESCC s'étendait sur deux années. Jusqu'en 2007, la première année du cycle d'enquête, désignée par « .1 », a constitué une enquête sur la santé de l'ensemble de la population qui visait à fournir des estimations fiables à l'échelon des régions sociosanitaires. La deuxième année du cycle d'enquête,

[1] Santé Canada, Statistique Canada. 1999 *Carnet de route de l'information sur la santé : Répondre aux besoins*, p. 3.
[2] Institut canadien d'information sur la santé; Statistique Canada. 1999 *Carnet de route de l'information sur la santé : Entreprendre le voyage*. ISBN 1-895581-70-2. p. 19.

désigné par « .2 », reposait sur un échantillon plus modeste et visait à fournir des résultats à l'échelle provinciale sur des sujets particuliers relatifs à la santé.

À partir de 2007, la composante régionale du programme de l'ESCC a commencé à faire l'objet d'une collecte continue. Les cycles x.1 de l'ESCC ont été renommés « composante annuelle » de l'ESCC et ont désormais fait l'objet d'une collecte chaque année. Le titre complet d'un cycle annuel donné est « Enquête sur la santé dans les collectivités canadiennes – Composante annuelle, 20XX » et le titre abrégé est simplement « ESCC – 20XX ».

La composante axée sur le contenu de l'enquête a été désignée par le nom de l'enquête suivi du sujet des thèmes visés par chaque enquête (p. ex. « Enquête sur la santé dans les collectivités canadiennes portant sur le vieillissement en santé » ou « ESCC – Vieillissement en santé »).

En 2012, un remaniement en profondeur de l'enquête a commencé, qui a modifié l'échantillonnage et la stratégie de collecte. Le contenu de l'enquête a fait l'objet d'essais qualitatifs visant à assurer la validité et la fiabilité en préparation à un nouveau plan octennal du contenu débutant en 2015.

En 2022, l'ESCC a fait l'objet d'un deuxième remaniement majeur.

3. REMANIEMENT DE L'ESCC

Vous trouverez ci-dessous les principaux changements résultant du remaniement de l'ESCC :

3.1 Remaniement de l'ESCC en 2015

- Des changements ont été apportés au contenu de la majorité des modules, mais principalement à celui des modules de base et des modules thématiques. Environ 70 % des modules qui existaient avant le remaniement ont fait l'objet d'un certain degré de changement. Les changements en question varient et vont des raffinements mineurs aux changements majeurs concernant des concepts, du vocabulaire ou des catégories de réponse. Certains nouveaux modules ont été créés pour le traitement de nouveaux concepts ou pour combler des lacunes statistiques cernées par des partenaires échangeant des données, comme Santé Canada, l'Agence de la santé publique du Canada et les ministères provinciaux et territoriaux responsables de la santé.

- Les règles relatives aux variables ont changé en 2015. Les règles d'affectation des noms utilisées pour les variables dans l'ESCC de 2015 utilisent un maximum de huit caractères. Comme auparavant, les trois premiers caractères correspondent au nom du module et de la section du questionnaire, tandis que le quatrième caractère indique le type de variable (soulignement, D, F, C ou G). Les éléments d'enquête à l'intérieur du questionnaire (p. ex. E, C, D, Q, N) sont désormais assujettis à des règles uniformes qui augmentent par incréments de 5 (p. ex. CCC_005, CCC_010, CCC_015).

- Toutes les variables dérivées ont été examinées et les spécifications ont été mises à jour avec les nouveaux noms de variables. Les modifications ayant trait aux concepts et au contenu ont elles aussi été passées en revue, ce qui a donné lieu à la création de nouvelles variables dérivées correspondant aux nouveaux modules de contenu. La stratégie annuelle de collecte des données a été modifiée en 2015. Avant 2015, la collecte se déroulait dans le cadre de six périodes de collecte de deux mois. À partir de 2015, la collecte pour l'enquête a été divisée en quatre périodes de trois mois qui ne se chevauchent pas.

- À partir de 2015, la collecte des données dans le Nord a été modifiée de sorte qu'environ la moitié des collectivités de chaque territoire sont visitées chaque année. En conséquence, les données ne sont représentatives des territoires qu'au bout de deux ans.

3.2. Remaniement de l'ESCC en 2022

Le remaniement de l'ESCC de 2022 a entraîné des changements majeurs en ce qui a trait à la méthodologie et au contenu.

Changements méthodologiques :

- Avant 2022, l'ESCC était réalisée par interview assistée par ordinateur, par téléphone (ITAO) ou en personne (IPAO). En 2022, l'enquête est passée à l'autodéclaration directe en utilisant un questionnaire électronique en ligne, avec l'ajout d'interviews téléphoniques assistées par ordinateur (ITAO) et d'interviews sur place assistées par ordinateur (IPAO) pour les cas de non-réponse. En raison de ce passage au format de QE, un nombre important de modules ont été modifiés. La transition vers le QE pourrait également avoir un effet sur le mode de collecte, étant donné qu'en 2021, toutes les collectes ont été effectuées par

téléphone, alors qu'en 2022, 51 % des cas étaient autodéclarés, au moyen d'un questionnaire rempli en ligne, 48,5 % ont été réalisés par téléphone et seulement 0,5 % ont été réalisés en personne. Le taux de réponse a également varié considérablement entre 2021 et 2022 (24,1 % par rapport à 43,0 %).

- L'ESCC est passé de l'utilisation du logiciel Blaise pour les interviews assistées par ordinateur et le traitement des enquêtes au Portail de gestion de la collecte (PGC) interne.

Changements apportés au contenu en 2022 :

- Un nombre important de variables ont changé de nom (219 sur 413 variables).
- De nombreux choix de réponses ont été modifiés (nouvelles catégories, catégories supprimées ou catégories modifiées).
- L'ordre de certaines questions a été modifié au sein des modules et certains textes ont été légèrement ou complètement modifiés.

Pour obtenir de plus amples renseignements sur le contenu de l'ESCC de 2023, veuillez-vous reporter à l'annexe A.

4. STRUCTURE DU CONTENU DE L'ESCC

Outre les données sociodémographiques et administratives, l'ESCC comporte trois composantes de contenu, qui répondent chacune à des besoins différents : le contenu commun (contenu de base et contenu thématique), le contenu optionnel et le contenu de réponse rapide. L'annexe A dresse la liste des modules inclus dans le questionnaire de 2023 et de leur type de composante.

4.1 Contenu de base

La composante de contenu de base de l'ESCC comprend des questions posées aux répondants de toutes les provinces et territoires (à moins d'exception).

4.2 Contenu thématique

Le contenu thématique, demandé à tous les participants à l'enquête, se compose de modules et, dans certains cas, de groupes de questions faisant partie de ces modules, ayant trait à un sujet précis. Des données sont recueillies chaque année pour deux types de thèmes : les modules thématiques biennaux, demandés pendant une période de deux ans, et les modules thématiques annuels, demandés pendant une période d'un an. Les thèmes annuels changent chaque année. Certains thèmes peuvent être réintroduits dans l'enquête au besoin. Cette composante permet de mieux planifier le contenu de l'ESCC à moyen terme.

4.3 Contenu optionnel

Le contenu optionnel comprend des modules qui ont été sélectionnés par les provinces et les territoires pour répondre à leurs besoins particuliers en matière de données.

4.4 Contenu de réponse rapide

La composante de réponse rapide est offerte par recouvrement des coûts aux organisations désirant obtenir des estimations nationales sur un sujet émergent ou particulier lié à la santé de la population. La réponse rapide est formée d'un maximum de deux minutes de contenu. Les questions apparaissent au questionnaire pour une ou deux périodes de collecte (trois à six mois) et sont posées à tous les répondants de l'ESCC au cours de cette période, à l'exception de ceux des territoires.

En 2023, deux composantes de réponse rapide ont été regroupées en un seul fichier et publiées le 6 novembre 2023; Usage du tabac - les étapes du changement 2 (SCH2) et Produits du remplacement du tabac (TAL) ont été recueillis du 3 janvier 2023 au 31 décembre 2023[3]. Équilibre travail-famille (WLB) a été recueilli du 1er juillet au 31 décembre 2023.

4.5 Contenu des fichiers de microdonnées

Différents fichiers de données sont produits à partir des données de l'enquête :

- Fichier de données d'un an
- Fichier de données de réponse rapide

5. PLAN D'ÉCHANTILLONNAGE

5.1 Population cible

En 2023, l'ESCC couvre la population âgée de 18 ans et plus vivant dans les 10 provinces et les 3 territoires. Les trois territoires sont couverts sur une période de deux années de collecte. Les personnes exclues de la couverture de l'enquête comprennent : les personnes habitant sur des réserves et d'autres établissements autochtones dans les provinces; les membres à temps plein des Forces canadiennes; les personnes placées dans des établissements et les personnes habitant dans les régions sociosanitaires du Québec du Nunavik et de la région des Terres-Cries-de-la-Baie-James. En tout, ces exclusions représentent moins de 3 % de la population cible.

5.2 Régions sociosanitaires

À des fins administratives, chaque province est divisée en plusieurs régions sociosanitaires (RS) et chaque territoire est considéré comme formant une RS unique. En collaboration avec les provinces, Statistique Canada est parfois appelé à modifier les limites de certaines RS afin qu'elles correspondent aux données géographiques du recensement ou encore afin de mieux tenir compte des besoins en données sur la santé selon de nouvelles bornes géographiques. Pour l'ESCC de 2023, les données ont été recueillies dans plus de 100 RS dans les 10 provinces, ainsi que dans une RS par territoire (annexe B).

[3] En utilisant les données des deux premières périodes de collecte (janvier à juillet 2023), une diffusion préliminaire a eu lieu le 29 février 2024 pour les modules de réponse rapide SCH2 et TAL

5.3 Bases de sondage et stratégies d'échantillonnage des ménages

En 2023, deux changements majeurs ont été apportés à l'échantillonnage de l'ESCC. Tout d'abord, la population des jeunes (12 à 17 ans) n'a pas été incluse dans l'échantillon. Deuxièmement, un nouvel échantillon ciblé a été introduit pour répondre aux besoins du Plan d'action sur les données désagrégées (PADD), dont l'objectif est de collecter, d'analyser et de diffuser des données plus désagrégées. Par conséquent, l'échantillon de l'ESCC 2023 se compose de deux bases de sondage : la base de sondage régionale (qui est la même qu'en 2022) et la base de sondage PADD (qui est nouvelle pour 2023).

5.3.1 Échantillonnage des ménages à partir de la base aréolaire

La base aréolaire utilisée pour l'Enquête sur la population active (EPA) est employée comme base de sondage dans le cas de la population adulte. L'EPA utilise un plan d'échantillonnage à deux degrés[4]. Au premier degré, un échantillon d'unités primaires d'échantillonnage (UPE) est sélectionné, correspondant à des régions géographiques appelées grappes. Dans chacune des UPE sélectionnées, un échantillon de logements est sélectionné au second degré. Les détails concernant la base aréolaire et le plan d'échantillonnage de l'EPA peuvent être consultés ici : https://www150.statcan.gc.ca/n1/fr/catalogue/71-526-x

Échantillonnage des ménages à partir de la base aréolaire dans les provinces

Les provinces sont divisées en grappes, des régions géographiques généralement composées de 100 à 600 logements. Chaque grappe est classée dans l'un des six groupes de renouvellement de l'EPA, et les grappes sont regroupées en groupes géographiques ou socioéconomiques homogènes et mutuellement exclusifs, appelés strates. La base aréolaire contient toutes les UPE et leur strate correspondante.

Au premier degré d'échantillonnage, un échantillon de grappes est sélectionné dans chaque strate. Au deuxième degré, des listes de logements sont dressées pour chaque grappe sélectionnée, et les logements sont sélectionnés dans ces listes par échantillonnage systématique.

Chaque grappe est divisée en un ensemble d'origines pour permettre l'échantillonnage systématique des logements au sein de chaque grappe. Par exemple, une grappe de 300 logements pourrait être divisée en 20 origines. Sur une liste dans laquelle les 300 logements sont classés selon leur emplacement, la première origine correspondrait aux logements nº 1, nº 21, nº 41…, nº 281; la deuxième origine correspondrait aux logements nº 2, nº 22, nº 42…, nº 282, et ainsi de suite. La taille de l'échantillon fournie par une origine donnée (15 logements dans le cas présent) est appelée le rendement de l'origine.

[4] Excepté pour l'Île-du-Prince-Édouard, où un plan d'échantillonnage aléatoire simple est utilisé.

La division des grappes en origines a été effectuée au moment du dernier remaniement de l'EPA en 2015, et le rendement prévu de chaque origine a été calculé à ce moment-là. Lorsqu'une grappe est sélectionnée une première fois pour faire partie d'une enquête, une liste actuelle des logements se trouvant dans cette grappe est dressée. En appliquant le taux d'échantillonnage qui avait été déterminé lors du remaniement de l'EPA au plus récent dénombrement des logements, on peut déterminer de façon plus précise le rendement prévu pour les origines de la grappe.

Puisqu'on connaît le rendement prévu de chaque origine, le processus de réservation de l'échantillon de l'Enquête sur la santé dans les collectivités canadiennes (ESCC) a pour objectif de déterminer combien d'origines doivent être sélectionnées dans chaque strate de l'EPA de sorte que le rendement prévu soit suffisamment important pour obtenir la taille d'échantillon attribuée à chacune des strates de l'ESCC. Lors de la sélection des origines dans une strate de l'EPA donnée, le même nombre d'origines doit être sélectionné dans chacun des six groupes de renouvellement de l'EPA, ce qui signifie que le nombre d'origines sélectionnées est toujours un multiple de six[5].

Les strates de l'EPA et celles de l'ESCC ont des limites géographiques différentes, ce qui signifie que les origines sélectionnées à partir d'une certaine strate de l'EPA peuvent fournir un échantillon pour différentes strates de l'ESCC. Étant donné que nous veillons à ce que le rendement total prévu à l'intérieur de chaque strate de l'ESCC corresponde au moins à la taille de l'échantillon requis, et que les origines soient sélectionnées par groupes de six, le rendement total prévu obtenu à partir des origines sélectionnées dépassera généralement, sauf exception, le minimum requis pour chacune des strates de l'ESCC. Le cas échéant, un sous-échantillon de logements est sélectionné dans chaque strate de l'ESCC au moyen d'un processus appelé stabilisation, de sorte que la taille de l'échantillon final corresponde à la répartition de l'échantillon cible pour chaque strate de l'ESCC.

Échantillonnage des ménages à partir de la base aréolaire dans les trois territoires

Pour des raisons opérationnelles, le plan d'échantillonnage à partir de la base aréolaire de l'EPA pour les trois territoires est différent. Pour chaque territoire, les collectivités les plus populeuses ont chacune leur propre strate, alors que les collectivités les moins populeuses sont groupées en strates en fonction de diverses caractéristiques (population, données géographiques, proportion d'Inuit et/ou d'Autochtones et revenu médian du ménage). L'EPA a défini 6 strates pour le Yukon, 10 pour les Territoires du Nord-Ouest et 10 pour le Nunavut. Pour les strates regroupant plus d'une collectivité, le premier degré d'échantillonnage consiste à sélectionner aléatoirement une collectivité avec probabilité proportionnelle à la taille de la population dans chaque strate. Puis, à l'intérieur de chaque collectivité, le deuxième degré d'échantillonnage consiste à sélectionner des ménages de façon identique à la stratégie d'échantillonnage décrite plus haut. Si trop ou pas assez de logements étaient disponibles pour une collectivité à l'intérieur d'une strate, une autre collectivité était choisie pour l'ESCC. Pour les collectivités les plus populeuses ayant leur propre strate, seulement un plan à un degré était nécessaire pour sélectionner directement les ménages de façon identique à la stratégie d'échantillonnage décrite plus haut.

Il convient de mentionner que la base de sondage de l'ESCC couvrait 94 % de la population ciblée au Yukon, 96 % dans les Territoires du Nord-Ouest et 93 % au Nunavut.

[5] Quelques strates de l'EPA ont 2 ou 3 grappes pour chaque groupe de renouvellement, ce qui signifie que les origines viennent en groupe de 12 ou 18.

5.3.2 Échantillonnage des ménages du recensement de 2021 pour l'initiative PADD.

Pour l'ESCC 2023, une nouvelle base de sondage a été ajoutée pour répondre aux besoins du PADD (Plan d'action sur les données désagrégées). Le PADD vise à soutenir des méthodes de collecte de données plus représentatives, à améliorer les statistiques sur les diverses populations pour permettre des analyses intersectionnelles, et à soutenir les efforts des gouvernements et de la société pour remédier aux inégalités connues en intégrant des considérations d'équité et d'inclusion dans la prise de décisions[6]. Des données désagrégées basées sur les quatre groupes d'équité en matière d'emploi devraient être fournies : Les peuples autochtones, les femmes, les populations racialisées et les personnes handicapées. En 2021 et 2022, la taille de l'échantillon de l'ESCC a été augmentée d'environ 50 % afin d'accroître le nombre de répondants du groupe PADD.

Pour l'ESCC 2023, l'initiative PADD a été renforcée par la disponibilité des données du recensement 2021. Le recensement 2021 a été choisi comme base de sondage supplémentaire pour l'ESCC 2023 afin de permettre une stratification en fonction des caractéristiques de la population. Les données du recensement 2021 ont été utilisées pour cibler les ménages dont les membres ont déclaré appartenir à des groupes faisant partie de l'initiative PADD. Un échantillon supplémentaire de 33 000 ménages a été sélectionné à partir des données du formulaire long du recensement de 2021. Ces ménages ont été répartis sur les trois dernières périodes de collecte de 2023. Cet échantillon supplémentaire a été sélectionné au niveau de la province et du sous-groupe d'équité.

5.4 Taille et répartition de l'échantillon

Bien qu'un des principaux objectifs de l'ESCC soit de produire des estimations fiables pour chaque RS compte tenu du budget accordé, la qualité des estimations au niveau provincial pour certaines caractéristiques importantes a été jugée importante également. Par conséquent, la stratégie de répartition de l'échantillon tient en compte les besoins au niveau provincial. Pour limiter le fardeau de réponse, on impose une fraction de sondage maximum de 10 % afin d'éviter d'échantillonner trop de logements dans des petites RS qui sont aussi interpellées par d'autres enquêtes.

Pour l'échantillon de la base aréolaire dans les 10 provinces, un échantillon d'environ 72 000 répondants a été réparti entre les provinces, en utilisant une répartition de puissance de 0,75 basée sur la taille de la population. Ensuite, l'échantillon de chaque province a été réparti parmi les RS de la province, selon une répartition proportionnelle à la taille de la population de la RS à la puissance 0,35. En Ontario et en Alberta, les tailles d'échantillons obtenues pour les RS ont ensuite été réparties au niveau des strates selon une répartition proportionnelle à la taille de la population de la strate.

Pour l'échantillon de la base aréolaire dans les trois territoires, environ 4 500 répondants sont nécessaires pour un cycle de deux ans. L'échantillon a été réparti proportionnellement à la taille des strates.

---

[6] Plus d'informations à l'adresse suivante
Plan d'action sur les données désagrégées (statcan.gc.ca)

La stratégie de répartition de l'échantillon pour la base PADD est sensiblement différente. Les quatre principaux groupes PADD (autochtones, populations racialisées, minorités de genre et personnes handicapées) ont été divisés en sous-groupes qui varient selon les provinces. L'échantillon PADD annuel a été stratifié par province et par sous-groupe PADD. L'échantillon a été réparti de manière égale entre les provinces et les quatre principaux groupes PADD. Au sein des groupes PADD, l'échantillon a été réparti de manière égale entre les sous-groupes.

Le nombre de répondants attribués à chaque strate a ensuite été gonflé pour compenser les non-réponses attendues et les unités hors du champ de l'enquête. On appelle la taille ainsi gonflée d'un échantillon la taille brute de l'échantillon; elle correspond au nombre de logements devant être envoyés à la collecte pour obtenir le nombre requis de répondants. Le nombre d'unités envoyées à la collecte par province/territoire pour l'ESCC de 2023 est disponible à l'annexe C.

5.5 Répartition de l'échantillon par période de collecte des données

Afin d'équilibrer la charge de travail des intervieweurs et d'atténuer les effets saisonniers potentiels sur les estimations, la taille initiale de l'échantillon pour chaque base a été répartie de manière égale entre les quatre périodes de collecte.

Pour la base aréolaire (adultes), chaque origine sélectionnée dans chaque RS a été assignée de manière aléatoire à une période de collecte en tenant compte d'un certain nombre de contraintes liées aux opérations sur le terrain ou à la pondération, tout en conservant une taille uniforme pour chaque période.

L'échantillon PADD a été sélectionné au niveau annuel. Afin d'optimiser les activités de collecte, l'échantillon annuel a ensuite été assigné à des périodes de collecte alignées sur les emplacements géographiques des grappes d'échantillonnage de la base de données régionale. Ceci a été fait pour minimiser les déplacements des enquêteurs. Les unités d'échantillonnage PADD qui ne correspondaient pas géographiquement aux grappes de la base de sondage ont été affectées à une période de collecte de manière aléatoire.

5.6 Échantillonnage des personnes interviewées

La stratégie d'échantillonnage adoptée a tenu compte des besoins des utilisateurs de données, du coût, de l'efficacité du plan d'échantillonnage, du fardeau de réponse et des contraintes opérationnelles. Une seule personne par ménage est sélectionnée au moyen de diverses probabilités tenant compte de l'âge et de la composition du ménage. Les probabilités choisies font suite à des résultats de simulations reposant sur divers paramètres dans le but de déterminer l'approche optimale sans générer de poids d'échantillonnage extrêmes.

Le tableau 5.1 donne les facteurs de sélection au niveau de la personne utilisés pour déterminer les probabilités de sélection des personnes dans les ménages échantillonnés selon le groupe d'âge. Par exemple, pour un ménage de trois personnes formé de deux adultes âgés de 35 à 64 ans et d'un jeune de 19 ans, le jeune aura 1 chance sur 2 d'être sélectionné (c.-à-d. 20/[20+10+10]) tandis que chacun des adultes âgés de 35 à 64 ans aura 1 chance sur 4 d'être sélectionné. Afin d'éviter l'obtention de poids extrêmes, il y a une exception à la règle : si la taille du ménage est plus grande

ou égale à 5, alors le facteur de sélection au niveau de la personne est égal à 1 pour toutes les personnes du ménage. Dans ce cas, toutes les personnes du ménage ont la même probabilité d'être sélectionnées.

Tableau 5.1 Facteurs de sélection au niveau de la personne, selon l'âge

Âge	**18-34**	**35-49**	**50-64**	**65+**
Facteur	20	10	10	20

6. COLLECTE DES DONNÉES

6.1 Questionnaires électroniques

En 2023, l'ESCC a utilisé le questionnaire électronique (QE) pour recueillir les données. Ce questionnaire électronique peut être consulté en toute sécurité par les répondants en ligne ou par les intervieweurs formés par Statistique Canada lors d'une interview téléphonique ou en personne.

Toutes les unités sélectionnées disposant d'une adresse postale ont reçu une lettre d'introduction (voir le paragraphe 6.4a pour obtenir plus de détails) contenant des renseignements sur la manière d'accéder au questionnaire électronique ou de communiquer avec un intervieweur pour répondre avec l'aide de ce dernier. Un code d'accès sécurisé (CAS) unique a été inclus dans chaque lettre pour offrir une méthode sécurisée d'accès à l'enquête en ligne. Pour les unités n'ayant pas d'adresse postale, les intervieweurs ont tenté de réaliser une interview par téléphone ou en personne, en fonction des coordonnées disponibles pour ces unités. Que l'enquête soit réalisée en ligne par le répondant lui-même ou par l'intervieweur, le contenu est exactement le même.

Le QE a été connecté à un système de gestion de la collecte pour suivre l'état de la réponse d'une unité sélectionnée et la méthode par laquelle l'enquête a été réalisée ou consultée pour la dernière fois. Ce système permet également de gérer les appels et les visites de l'intervieweur afin de maximiser son efficacité.

Un autre avantage du QE est qu'il permet également de réaliser des interviews personnalisées pour chaque répondant en fonction de ses caractéristiques individuelles et de ses réponses à l'enquête. Notamment :

- l'application saute automatiquement les questions qui ne s'appliquent pas au répondant;
- des règles de vérification sont appliquées automatiquement pour repérer les réponses incohérentes ou non incluses dans l'éventail de valeurs permises, et des messages-guides apparaissent à l'écran en réaction à une inscription non valable. De cette façon, l'intervieweur reçoit une rétroaction immédiate et peut corriger toute incohérence;
- le texte des questions, y compris les périodes de référence et les pronoms, est personnalisé automatiquement d'après des facteurs comme l'âge et le sexe du répondant, la date de l'interview et les réponses aux questions précédentes.

6.2 Développement des applications de l'ESCC

Le questionnaire électronique comprend deux parties, une composante principale et une composante supplémentaire. La composante principale détermine la résidence du ménage, les données démographiques et l'éligibilité du répondant. À l'aide de ces informations, il sélectionne au hasard le répondant de l'enquête et génère la composant supplémentaire qui sera administré au répondant sélectionné. La composante supplémentaire du QE contient tout le contenu relatif à la santé de l'enquête, qui est constitué de divers modules de santé basés sur différents sous-thèmes. L'application a subi trois étapes de mise à l'essai : les tests modulaires, intégrés et de bout en bout.

Les tests modulaires consistent à mettre à l'essai indépendamment chaque module de contenu afin de vérifier la spécification exacte des instructions « passez à », la logique d'enchaînement et le texte, dans les deux langues officielles.

Les essais intégrés ont lieu au moment du regroupement des modules mis à l'essai et des composantes Principale et Supplémentaire. Ce second stade d'essais vérifie la transmission de l'information démographique essentielle de la composante Entrée au contenu sur la santé et à la composante Sortie des applications. Il confirme également que les variables qui influent sur les instructions « passez à » et la logique d'enchaînement sont transmises correctement de module en module à l'intérieur de la composante Contenu sur la santé.

Les tests de bout en bout ont lieu lorsque l'application entièrement intégrée est placée dans un environnement de collecte simulé. Cette étape du test se concentre sur le fonctionnement du questionnaire électronique au sein de l'infrastructure de collecte de Statistique Canada. Cela permet de tester tous les aspects techniques en dehors de l'application EQ de l'ESCC elle-même, comme la sélection aléatoire d'un répondant et la création ultérieure de la composante complémentaire, le test de la génération des courriels d'invitation et la transmission et l'extraction des données. Il permet également de détecter une dernière fois les erreurs dans le questionnaire électronique lui-même.

Les scénarios créés par le Centre de données sur la santé de la population (CDSP) sont saisis par les bureaux régionaux, la Division de la planification et de la recherche en matière de collecte (DPRC) et d'autres testeurs du CDSP. Les données transmises sont ensuite comparées aux cas avec script pour en vérifier l'exactitude.

6.3 Formation des intervieweurs

Les gestionnaires de projet, les intervieweurs principaux et les intervieweurs des bureaux régionaux responsables de la collecte des données de l'ESCC ont reçu des trousses d'autoformation avant les séances de formation formelles et le début de la collecte. Les séances de formation visaient à habituer les intervieweurs à l'utilisation de l'application de l'ESCC de 2023 et à les familiariser avec le contenu de l'enquête et les procédures d'interview propres à l'ESCC.

La formation était centrée sur :

- les buts et objectifs de l'enquête;
- la méthodologie de l'enquête;
- les fonctionnalités des applications;

- l'examen du contenu des questionnaires et des exercices axés sur les changements significatifs apportés au contenu;
- les techniques à appliquer par l'intervieweur pour maintenir le taux de réponse et des exercices pour réduire au minimum la non-réponse;
- la simulation d'interviews difficiles et de situations de non-réponse;
- la gestion de l'enquête;
- les procédures de transmission.

La formation visait en priorité à réduire au minimum les cas de non-réponse. Des exercices à cette fin ont été préparés pour les intervieweurs. Ces exercices permettaient aux intervieweurs de s'exercer à persuader des répondants réticents à participer à l'enquête. En outre, les intervieweurs principaux responsables de la conversion des cas de refus à chaque bureau régional de collecte ont participé à une série d'ateliers sur la façon d'éviter les refus.

Une version hors ligne de l'application de QE a également été fournie aux intervieweurs afin qu'ils se familiarisent avec l'application, en particulier avec les scripts d'entrée et le contenu de l'enquête elle-même. Tout écart fonctionnel entre les applications utilisées à des fins d'exercice et l'application réelle a été couvert par la formation des intervieweurs et la documentation connexe.

6.4 L'interview

Les unités de l'échantillon ont été sélectionnées à partir d'une base liste de logements, le Fichier de l'univers des logements (FUL), dans le cas de la population âgée de 18 ans et plus.

Dans tous les logements sélectionnés du FUL , l'intervieweur demandait à un membre du ménage bien informé de fournir l'information démographique de base sur tous les occupants. Puis, il sélectionnait un membre du ménage pour une interview plus approfondie, appelée interview du contenu sur la santé.

Afin d'assurer la qualité des données recueillies, les intervieweurs avaient reçu l'instruction de prendre tous les moyens à leur disposition pour mener en privé l'interview avec le répondant choisi. Là où la situation était inévitable, le répondant a été interviewé en présence d'une autre personne.

De nombreuses techniques, y compris les suivantes, ont été mises en œuvre afin de parvenir à un taux de réponse optimal :

a) Lettres d'introduction
Avant le début de chaque période de collecte, les ménages échantillonnés ont reçu des lettres d'introduction et des brochures qui expliquaient l'objet de l'enquête. Elles énonçaient, notamment, l'importance de l'enquête et offraient des exemples de l'utilisation prévue des données tirées de l'ESCC.

b) Prise de contact
On a demandé aux intervieweurs de faire tous les efforts raisonnables pour obtenir des entrevues. De nombreux rappels ont été effectués, à divers moments et différents jours. Lorsque l'appel de l'intervieweur ne convenait pas, un rendez-vous était pris pour rappeler à un meilleur moment.

c) Conversion des cas de refus
Si une personne refusait initialement de participer à l'enquête, le bureau régional de Statistique Canada lui faisait parvenir une lettre qui soulignait l'importance de l'enquête et de la coopération du ménage. Ensuite, un intervieweur principal, un surveillant de projet ou un autre intervieweur rappelait le répondant pour faire valoir l'importance de sa participation.

d) Obstacles linguistiques
Pour parer aux problèmes de langue qui pourraient nuire aux interviews, tous les bureaux régionaux de Statistique Canada ont embauché des intervieweurs qui parlent plusieurs langues. Au besoin, les cas étaient transférés à un intervieweur capable de remplir le questionnaire dans la langue voulue.

e) Interviews par procuration
Dans les cas où le répondant sélectionné était, pour des raisons de santé physique ou mentale, incapable de se prêter à l'interview, les renseignements à son sujet ont été fournis par un autre membre bien informé du ménage. C'est ce qu'on appelle une interview par personne interposée. Quoique les répondants substituts aient été en mesure de donner des réponses exactes à la plupart des questions de l'enquête, les questions plus délicates ou personnelles allaient au-delà des connaissances d'un répondant substitut. Par conséquent, certaines questions posées dans le cadre des interviews par personne interposée sont demeurées sans réponse. Tous les efforts ont été faits pour réduire au minimum le nombre d'interviews par personne interposée.

Le module d'interview par personne interposée (PR) du QE supplémentaire invite l'intervieweur à préciser si l'interview par personne interposée est menée en raison d'un problème de santé physique ou mental. Dans l'un ou l'autre de ces cas, l'intervieweur devait ensuite inscrire le problème particulier. La variable ADM_PRX indique si l'interview a été réalisée par personne interposée ou non.

6.5 Opérations sur le terrain

L'ESCC 2023 a été conçue pour comporter quatre périodes de collecte qui ne se chevauchent pas. La collecte devait commencer le 3 janvier 2023 et se terminer le 31 décembre 2023. Chaque cycle dure environ trois mois. Cependant, le deuxième cycle, qui devait commencer le 3 avril 2023 et se terminer le 30 juin 2023, a été prolongé jusqu'au 31 juillet 2023 pour un certain nombre de raisons.

Les bureaux régionaux de collecte ont reçu l'instruction de passer les premières quelques semaines de chaque période de collecte à interviewer la majorité de l'échantillon, puis de consacrer les semaines suivantes au traitement du reste de l'échantillon et au suivi des cas de non-réponse. Tous les cas devaient avoir fait l'objet de tentatives avant la deuxième semaine de chaque période de collecte. Les fichiers d'échantillons ont été envoyés environ deux semaines avant le début de chaque période de collecte. Une série de cas fictifs a été incluse dans chaque échantillon. Chaque échantillon IPAO comprenait une série de cas fictifs dont devaient s'occuper les intervieweurs principaux afin de confirmer que les procédures de transmission de données fonctionnaient bien tout au long du cycle de collecte.

Pour les taux de réponse finaux, consultez l'annexe D.

6.6 Contrôle de la qualité et gestion de la collecte

Durant l'année de collecte, plusieurs méthodes ont servi à assurer la qualité des données et l'optimisation de la collecte des données. Il s'agit, entre autres, de mesures internes de vérification du rendement de l'intervieweur et d'une série de rapports de contrôle des diverses cibles de collecte et de la qualité des données.

Un système de validation a été utilisé régulièrement pour valider le travail des intervieweurs par le personnel de collecte principal. Des cas choisis ont été repérés aléatoirement dans les échantillons à chaque période de collecte. Par souci de repérer promptement les problèmes, la validation avait généralement lieu au cours des premières semaines d'une période de collecte. Les surveillants adressaient régulièrement une rétroaction aux intervieweurs.

7. TRAITEMENT DES DONNÉES

7.1 Vérification

Avant 2022, la plupart des vérifications des données étaient effectuées au moment de l'interview par l'utilisation d'une interview assistée par ordinateur (IAO). Les intervieweurs ne pouvaient pas entrer de valeurs hors-norme et les erreurs d'enchaînement faisaient l'objet d'instructions « passez à » programmées. Par exemple, l'IAO s'assurait de ne pas poser au répondant les questions non pertinentes. En réponse à certaines données incompatibles ou inhabituelles, on a signalé des messages d'avertissement, mais sans prendre de mesures correctrices au moment de l'interview.

En raison de la transition vers le mode de collecte par QE, les vérifications au cours du questionnaire ont été réduites au minimum afin de ne pas perturber l'expérience de l'utilisateur. Le cas échéant, les vérifications sont effectuées après la collecte des données. Les incohérences ont généralement été résolues en attribuant à l'une ou à l'ensemble des variables concernées le code « non déclaré ».

Dans le QE, les répondants ont désormais la possibilité de modifier leurs réponses, d'interrompre le questionnaire et d'y revenir à tout moment jusqu'à la date limite de l'enquête. Il arrive qu'un répondant ne revienne pas à un questionnaire interrompu, ce qui entraîne plusieurs questionnaires non soumis. Tous ces questionnaires non soumis sont analysés au cas par cas selon des critères de complétude préétablis, et ceux qui répondent aux critères sont considérés comme étant des réponses valides. Les réponses valides sont ensuite ajoutées à l'ensemble de données final.

7.2 Flux

Lorsque les données recueillies sur le terrain sont transmises, les questions qui n'ont pas été posées apparaissent comme un champ vierge dans les fichiers de données préliminaires. Durant le traitement, l'un des codes de traitement qui suivent est attribué à chaque variable vide :

« Sans objet » – S.O.
Dans le cas des variables d'une longueur de 1, la valeur du code S.O. correspondra simplement à 6. Autrement, ces valeurs figureront dans le fichier sous la forme d'une série de 9, suivis d'un 6, selon la longueur de la variable numérique ou de la zone de texte.

Le code S.O. est utilisé chaque fois qu'une question est sautée parce qu'elle ne s'applique pas aux répondants (exclusion de la population). Ce code est principalement utilisé dans deux situations : pour les variables du module optionnel dans le cas des répondants des provinces où le contenu en question n'a pas été retenu et lorsque des questions sont sautées dans le flux du questionnaire parce qu'elles ne s'appliquent pas, comme les questions au sujet des expériences maternelles dans le cas des répondants masculins.

« Non déclaré » - ND
Dans le cas d'une variable d'une longueur de 1, la valeur de ND sera simplement 9. Autrement, ces codes figureront dans le fichier sous la forme d'une série de 9, selon la longueur de la variable numérique ou de la zone de texte.

Le code ND est appliqué chaque fois qu'une question est omise, mais aurait pu être posée. Les répondants en question font partie de l'univers, mais aucune réponse n'est présente. Les deux principales situations où ce code est employé sont celles où les questions sont sautées parce que l'interview est réalisée par personne interposée et celles où les questions sont sautées parce que la réponse à une question précédente était elle-même « Non déclaré ». Par exemple, si un répondant refuse de répondre à la question CCC_Q05 (Avez-vous du diabète?), les questions l'interrogeant au sujet de l'âge du diagnostic, de l'utilisation d'insuline, etc. comporteront toutes la mention « Non déclaré », car on ne sait pas si le répondant souffre ou non du diabète.

7.3 Codage

On a fourni des catégories de réponses précodées pour toutes les variables appropriées. Les intervieweurs ont reçu une formation durant laquelle ils ont appris à classer les réponses recueillies dans la catégorie appropriée.

Si la réponse d'un répondant ne pouvait pas être facilement classée dans une catégorie existante, plusieurs questions permettaient également à l'intervieweur d'entrer une réponse au long dans la catégorie « Autre – précisez ». Toutes ces questions ont fait l'objet d'un examen approfondi au cours du traitement. Dans certains cas, on a donné aux réponses en toutes lettres le code d'une catégorie figurant sur la liste si la réponse faisait double emploi. En 2023, les variables codées de cette manière comprenaient RWC_05, GDRA_010, SOR_01, CAN_015, CAN_025, CAN_035, CCC_60 et PG_05. D'autres variables de ce cycle pour lesquelles des réponses « Autre – Précisez » sont requises n'ont pas été sélectionnées pour le codage. On tiendra compte des réponses « Autre – précisez » fournies pour toutes les questions lors du perfectionnement des catégories de réponses en vue de futurs cycles de l'enquête.

Lorsque les réponses écrites (« Autre – précisez ») sont codées dans une catégorie existante au moment du traitement au bureau central, il se peut que d'autres questions viennent s'ajouter au champ d'enquête pour le répondant. Comme ces questions n'ont jamais été posées pendant l'interview, les réponses manquantes étaient réglées à « non déclaré » pendant le traitement.

7.4 Création de variables dérivées

Pour faciliter l'analyse des données, on a dérivé un certain nombre de variables à partir des éléments disponibles sur le questionnaire de l'ESCC. Le quatrième caractère du nom des variables dérivées est en général un « D », « G » ou un « F ». Dans certains cas, les variables dérivées sont

simples, donnant lieu à un regroupement des catégories de réponses. Dans d'autres cas, on a combiné plusieurs variables pour en créer une nouvelle. La *Documentation sur les variables dérivées (VD)* fournit des détails sur la façon de dériver ces variables plus complexes. Pour de plus amples renseignements concernant la nomenclature, veuillez vous référer à la section 12.6.

7.5 Pondération

Le principe de base de l'estimation dans un échantillon aléatoire comme celui de l'ESCC repose sur le fait que chaque personne représente, en plus d'elle-même, plusieurs autres personnes qui ne font pas partie de l'échantillon. Par exemple, dans un échantillon aléatoire simple de 2 % de la population, chaque personne incluse dans l'échantillon représente 50 membres de la population. Dans la terminologie en usage ici, nous dirons que nous avons attribué à chaque personne un facteur de pondération de 50.

L'étape de détermination des facteurs de pondération donne lieu au calcul du poids d'échantillonnage de chaque personne échantillonnée. Ce poids, qui figure dans le fichier de microdonnées, doit servir à calculer des estimations significatives à partir du sondage. Par exemple, si l'on doit évaluer le nombre de personnes qui fument tous les jours, on le fait en choisissant dans l'échantillon les enregistrements des personnes qui présentent cette caractéristique et en faisant la somme des facteurs de pondération que représentent ces enregistrements. Pour de plus amples renseignements concernant la pondération de l'ESCC, veuillez vous référer à la section 8.

7.6 Variables du revenu pour 2023 - couplage et imputation

Depuis 2016, les variables de revenu du fichier maître de l'ESCC de 2023 proviennent de l'une des trois sources suivantes : dossiers fiscaux, données fournies par le répondant, données imputées. Lorsque les répondants ne se sont pas opposés à un couplage avec leurs données fiscales et lorsqu'un couplage avec les dossiers fiscaux appropriés pouvait être trouvé, les variables de source de revenus (INC_005A-O, INC_Q025A-O), la principale source de revenus (INC_015, INC_035), le supplément pour personnes handicapées, si reçu (INC_010, INC_030) et les montants de revenu total (INC_021, INC_041) ont été établis à partir des dossiers fiscaux. Lorsque le couplage avec les données fiscales n'était pas possible, les données des répondants ont été utilisées. Il convient de noter qu'en 2023, les variables sur les sources de revenus n'a pas été demandée, la seule question sur le revenu étant le revenu total du ménage. De plus, lors de la dernière période de collecte (octobre-décembre), aucune personne interrogée n'a été invitée à déclarer ses revenus. Si ni les données fiscales couplées ni les données déclarées par le répondant n'étaient disponibles, une imputation des variables du revenu personnel total et du revenu total du ménage a été effectuée. Les sources de revenus (INC_005A-O, INC_010, INC_015, INC_025A-O, INC_030, INC_035) n'ont pas été imputées.

La variable INCFIMPP indique la source utilisée pour les variables du revenu personnel et la variable INCFIMPH indique la source utilisée pour celles du revenu du ménage. À partir de 2019, toute information en provenance des données fiscales sera indiquée comme imputée. Pour de plus amples renseignements concernant les revenus dans le fichier maître, veuillez consulter le document intitulé « ESCC_2023_Revenu_Fichier_Maître » accessible dans le répertoire de documentation de l'ESCC de 2023. Pour plus amples renseignements concernant les revenus dans le fichier de partage, veuillez consulter le document « ESCC_2023_Revenu_Fichier_Partage ».

7.7 Imputation du code postal

Le code postal d'une unité échantillonnée est utilisé, de même que le fichier de conversion des codes postaux, pour dériver le reste des variables géographiques qui figurent dans le fichier de données de l'ESCC. Il est donc important que toutes les unités échantillonnées aient un code postal valide. Si le code postal d'une unité échantillonnée est manquant ou invalide, il est généralement imputé dans le cadre d'un processus d'imputation par enregistrement donneur, mais d'autres méthodes d'imputation sont aussi parfois utilisées. L'enregistrement donneur est choisi à partir de la même région géographique, avec le plus de précision possible, comme l'unité dont le code postal est manquant ou invalide.

Pour l'ESCC de 2023, environ 5.9% des unités échantillonnées dans la base aréolaire (de 18 ans et plus) ont fait l'objet d'une imputation du code postal. Pour les unités échantillonnées dans la base PADD, environ 3.1% ont fait l'objet d'une imputation du code postal.

7.8 Codage du genre

Le genre réfère à l'identité personnelle et sociale d'un individu en tant qu'homme, femme ou personne non binaire (une personne qui n'est pas exclusivement homme ni femme). Le genre comprend les concepts suivants :

- L'identité de genre, qui correspond au genre qu'une personne ressent intimement et individuellement
- L'expression de genre, qui désigne la manière dont une personne présente son genre à travers son langage corporel, des choix esthétiques ou des accessoires (p. ex. vêtements, coiffure et maquillage) qui peuvent avoir été traditionnellement associés à un genre particulier, et ce, sans égard à son identité de genre

Le genre d'une personne peut différer de son sexe à la naissance et de la mention qui figure sur ses pièces d'identité ou documents juridiques actuels, tels que son certificat de naissance, son passeport ou son permis de conduire. Le genre d'une personne peut changer au fil du temps. Certaines personnes peuvent ne pas s'identifier à un genre en particulier.

Étant donné que la taille de la population non binaire est petite, il est parfois nécessaire d'agréger les données dans une variable sur le genre à deux catégories pour protéger la confidentialité des réponses. Dans ces cas, les individus de la catégorie « personnes non binaires », ainsi que ceux qui ne répondent pas à la question, sont répartis dans les deux autres catégories de genre et sont désignés par le symbole « + » (p. ex. hommes+, femmes+).

Lorsqu'ils publient des données désagrégées en fonction de la variable de genre recodée, les utilisateurs peuvent inclure les notes suivantes :

- Hommes+ : cette catégorie comprend les hommes (et les garçons) ainsi que certaines personnes non binaires.
- Femmes+ : cette catégorie comprend les femmes (et les filles) ainsi que certaines personnes non binaires.

Afin de faciliter l'utilisation de la variable binaire agrégée relative au genre, le fichier de l'ESCC comprend une variable recodée : GENDER_2, déjà codée dans les catégories hommes+ et femmes+. Il est conseillé aux utilisateurs d'utiliser cette variable, plutôt que d'effectuer leur propre recodage, afin d'être cohérents avec les analyses et les tableaux produits par Statistique Canada pour l'ESCC.

8. PONDÉRATION

Pour que les estimations produites à partir de données d'enquête soient représentatives de la population couverte, et non pas seulement représentatives de l'échantillon comme tel, l'utilisateur doit incorporer les poids d'enquête dans ses calculs. Un poids d'enquête est attribué à chaque répondant inclus dans l'échantillon final. Ce poids correspond au nombre de personnes représentées par le répondant dans l'ensemble de la population.

Comme décrit dans la section 5, l'ESCC utilise deux bases de sondage pour la sélection de son échantillon : une base aréolaire pour la population canadienne âgée de 18 ans et plus et une nouvelle base de sondage créée à l'aide du Recensement de 2021 pour répondre aux besoins du PADD (Plan d'action sur les données désagrégées).

Les corrections de pondération en 2023 sont donc similaires à celles de 2022, lorsque la base aréolaire était également utilisée.

La stratégie de pondération traite la base aréolaire et la base du PADD indépendamment l'une de l'autre afin d'obtenir des pondérations distinctes au niveau du ménage pour chacune des bases utilisées. Les poids des deux bases sont ensuite intégrés en une seule série de poids, ils font conjointement l'objet de quelques autres ajustements, notamment un ajustement au niveau de la personne et un appariement avec des totaux de populations connus, et ils deviennent les poids personne finaux.

8.1 Aperçu

Les sous-sections suivantes décrivent le processus de pondération pour les provinces. Les unités de la base aréolaire et de la base du DDAP sont traitées séparément jusqu'à l'ajustement pour la non-réponse au niveau du ménage, inclusivement. La sous-section 8.2 fournit des détails sur la stratégie de pondération pour la base aréolaire, tandis que la sous-section 8.3 traite de la stratégie pour la base du DDAP Les étapes finales de la pondération, soit la winsorisation et le calage, sont décrites à la section 8.4.

Suivant le remaniement de l'ESCC en 2015, la collecte d'un échantillon représentatif pour certaines géographies s'échelonnera sur une période de deux ans en raison de contraintes opérationnelles. Par exemple, les estimations pour les trois territoires sont en général seulement représentatives sur deux années. Ainsi, les répondants des territoires ne figureront pas dans les fichiers d'un an et ne seront inclus que dans les fichiers de deux ans. Le processus de pondération s'appliquant aux territoires comporte certaines particularités, qui seront présentées plus en détail dans la documentation relative aux fichiers de deux ans de l'ESCC.

Le poids des unités est rajusté à de nombreuses reprises tout au long du processus de pondération. Les ajustements appliqués aux unités de la base aréolaire sont numérotés de *A0* à *A7*, tandis que les ajustements appliqués aux unités de la base du DDAP sont numérotés de D*0* à D7. Les ajustements finaux appliqués suivant la combinaison des bases aréolaire et du DDAP sont numérotés I1 à I6. Le diagramme A présente un aperçu des ajustements les plus importants prévus dans le cadre de la stratégie de pondération.

Diagramme A – Aperçu de la stratégie de pondération

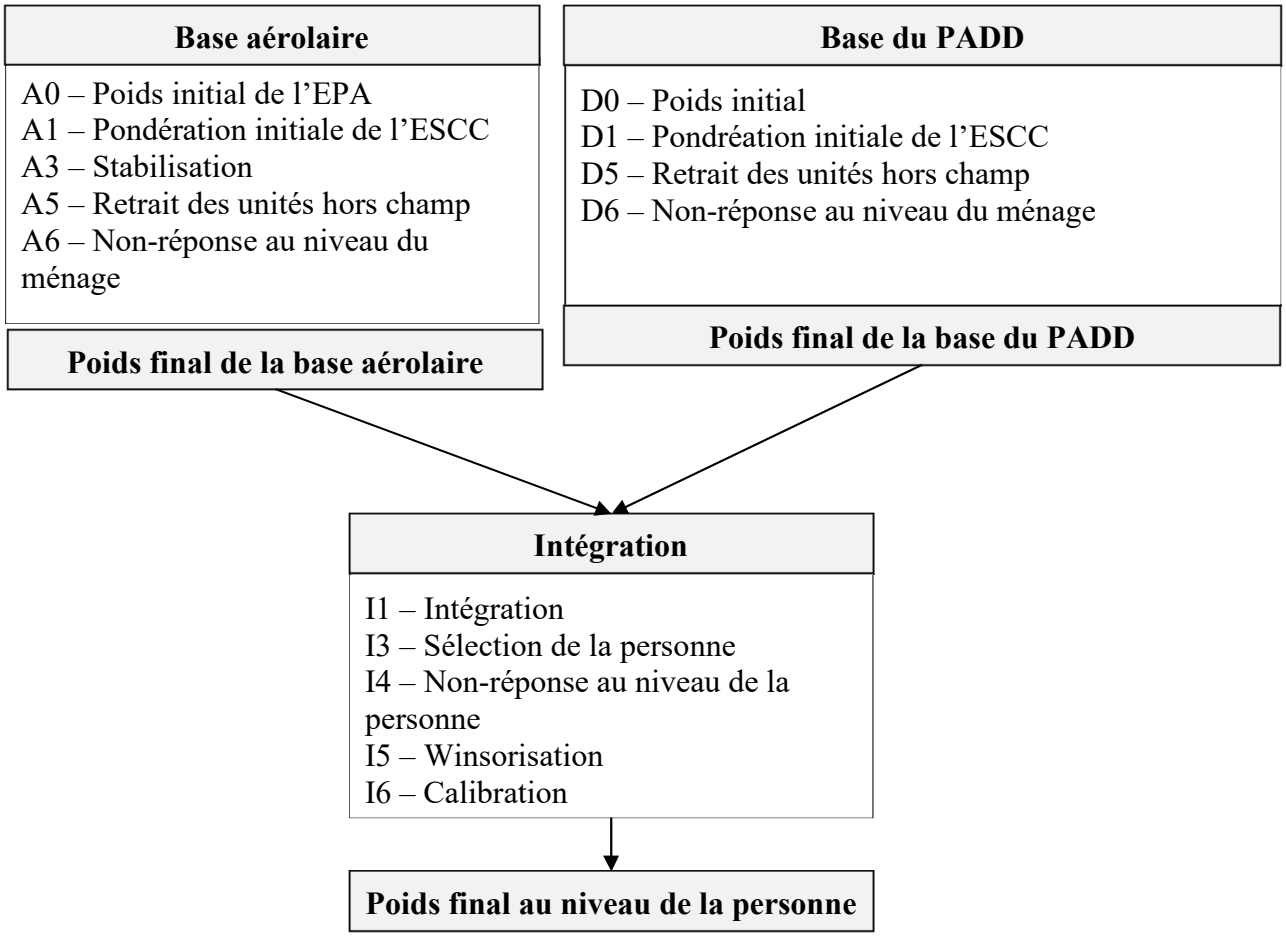

Les sous-sections 8.2 à 8.4 présentent en détail l'ensemble des étapes illustrées dans le diagramme A.

8.2 Pondération de l'échantillon de la base aréolaire

A0 – Poids initial de l'EPA

Le processus de pondération de l'échantillon de la base aréolaire commence avec un poids fourni par l'Enquête sur la population active (EPA). Ce poids est basé sur le plan de l'EPA parce que le plan d'échantillonnage de la base aréolaire de l'ESCC découle de celui de l'EPA. Le plan de l'EPA vise un échantillon de logements à l'intérieur de grappes sélectionnées dans des strates de l'EPA et les poids initiaux de l'EPA correspondent aux probabilités de sélection à l'intérieur des strates de l'EPA.

A1 – Pondération initiale de l'ESCC

Dans l'ajustement initial A1, le poids initial de l'EPA est ajusté pour tenir compte du fait que l'ESCC sélectionne un échantillon de taille suffisante pour une estimation au niveau de la région sociosanitaire. L'ESCC sélectionne pour ce faire un nombre de grappes différent de l'EPA et peut répéter l'échantillonnage de logements dans les grappes sélectionnées. Le poids obtenu est appelé

poids A1. Pour obtenir plus de détails sur le mécanisme de sélection, ainsi que pour consulter une définition plus complète des strates et des grappes de l'EPA, voir Statistique Canada (2020)[7].

A3 – Stabilisation

Dans certaines RS, l'accroissement de la taille de l'échantillon, comme décrit dans la section 5, produit un échantillon beaucoup plus volumineux que nécessaire. On a recours à la stabilisation pour réduire la taille de l'échantillon au niveau souhaité. Pour limiter la dispersion des poids et ainsi réduire la variabilité des estimations, on effectue la stabilisation de l'une de deux façons possibles à l'intérieur de chaque RS. Si les poids initiaux dans chaque grappe d'une RS sont identiques, le processus consiste à sous-échantillonner des logements au hasard à l'échelle de la RS parmi les logements originalement sélectionnés dans chaque grappe. Si, toutefois, les poids initiaux ne sont pas identiques dans chaque grappe à l'intérieur d'une RS, on a recours à un processus itératif. On sélectionne d'abord la grappe dont le poids initial est le plus faible et on enlève une unité de cette grappe. Les poids sont ensuite recalculés aux fins d'un ajustement tenant compte de l'unité enlevée. Encore une fois, on sélectionne la grappe dont le poids est le plus faible et on en retire une unité. Ce processus est repris jusqu'à ce que l'on obtienne la taille souhaitée pour l'échantillon. Un facteur d'ajustement représentant l'effet de la stabilisation est calculé pour la correction de la probabilité de sélection. Ce facteur, multiplié par le poids précédent, donne le poids A3.

A5 – Retrait des unités hors champ

Parmi tous les logements échantillonnés, une certaine proportion de ceux-ci est, lors de la collecte, désignée comme unités hors du champ de l'enquête. Les logements détruits ou en construction, les logements vacants, saisonniers ou secondaires, de même que les établissements, sont tous des exemples de cas hors champ pour l'ESCC. Les logements dans lesquels tous les résidents sont hors champ, par exemple ceux où tous les résidents sont des membres à temps plein des Forces armées ou des personnes en visite au Canada, sont également des logements hors champ. Tous les logements hors champ et les poids connexes sont simplement supprimés de l'échantillon, car on suppose que les logements hors champ pondérés à l'intérieur de l'échantillon sont représentatifs des logements hors champ dans la population. Lorsqu'on ignore si les logements sont admissibles (on n'a pas recueilli suffisamment de renseignements pour déterminer leur admissibilité), on réduit leur poids du taux d'unités hors champ de leur strate de l'ESCC afin de considérer une certaine proportion de ces unités comme unités hors champ. L'échantillon obtenu est représentatif des logements ou ménages faisant partie du champ de l'enquête. Les logements admissibles conservent le même poids qu'à l'étape précédente et que l'on appelle maintenant poids A5.

A6 – Non-réponse au niveau du ménage

Lors de la collecte, une certaine proportion des ménages échantillonnés aboutit inévitablement à une non-réponse. Cela survient habituellement lorsque le ménage refuse de participer à l'enquête, qu'il fournit des données inutilisables, ou qu'il ne peut être joint pour une interview. Les poids des ménages non-répondants sont redistribués aux ménages répondants à l'intérieur des groupes de réponses homogènes (GRH), formés à l'intérieur de la province. Pour créer des GRH, on utilise une méthode de cotation basée sur une régression logistique permettant de déterminer la probabilité de réponse, puis ces probabilités sont utilisées afin de diviser l'échantillon en groupes aux propriétés de réponse similaires.

[7] Statistique Canada, 2020. *Guide de l'enquête sur la population active*, produit nº 71-543-G au catalogue de Statistique Canada.

Les informations disponibles pour les non-répondants étant limitées, les modèles de régression utilisent des caractéristiques telles que la période de collecte, des informations géographiques, la langue du questionnaire et des variables provenant de la base de sondage des ménages de Statistique Canada. Le facteur d'ajustement calculé à l'intérieur de chaque GRH a été obtenu de la façon suivante :

$$\frac{Somme\ des\ poids\ A5\ pour\ tous\ les\ ménages}{Somme\ des\ poids\ A5\ pour\ tous\ les\ ménages\ répondants}$$

Le poids de l'étape précédente est multiplié par ce facteur d'ajustement pour l'obtention du poids A6 des ménages répondants. Les ménages non-répondants sont éliminés du processus à ce stade.

8.3 Pondération de l'échantillon de la base de sondage du PADD

D0 – Poids initial

Le processus de pondération pour l'échantillon de la base de sondage du PADD commence par le poids hérité du questionnaire détaillé du Recensement de 2021. Il y a plusieurs étapes de pondération pour le recensement, y compris un ajustement pour la non-réponse et un calage. L'ESCC utilise l'ajustement de poids pour la non-réponse comme poids de départ, puisque le calage est effectué plus tard dans le processus de pondération.

D1 – Pondération initiale de l'ESCC

Le poids de la non-réponse au recensement est ajusté en fonction de l'inverse de la probabilité de sélection des logements dans chaque strate du PADD. C'est-à-dire que le nombre d'unités dans la base de sondage est divisé par le nombre de logements échantillonnés au cours de l'année. Les poids initiaux (D0) sont multipliés par ce facteur de correction pour obtenir le poids D1.

D5 – Retrait des unités hors champ

Comme pour la base aréolaire, parmi l'ensemble des logements échantillonnés, certains sont identifiés pendant la collecte comme étant hors du champ de l'enquête. Il s'agit, par exemple, de logements vacants, d'établissements institutionnels ou de logements où tous les résidents sont hors du champ de l'enquête. La méthode utilisée ici est la même que pour la base aréolaire, c'est-à-dire que ces cas sont simplement retirés de l'échantillon, n'y laissant ainsi que les logements admissibles. Quant aux logements dont l'admissibilité est inconnue, on réduit leurs poids du taux d'unités hors du champ de l'enquête dans leur strate. Les logements admissibles conservent le même poids qu'à l'étape précédente, que l'on appelle maintenant poids D5.

D6 – Non-réponse au niveau des ménages

L'ajustement appliqué ici pour compenser l'effet de la non-réponse au niveau des ménages est identique à celui appliqué dans le cas des unités de la base aréolaire (ajustement A6). Le facteur d'ajustement calculé à l'intérieur de chaque groupe de réponses homogènes (GRH) est obtenu de la façon suivante :

$$\frac{Somme\ des\ poids\ D5\ pour\ tous\ les\ ménages}{Somme\ des\ poids\ D5\ pour\ tous\ les\ ménages\ répondants}$$

Le poids des ménages répondants est multiplié par ce facteur de correction pour obtenir le poids D6. Les ménages non-répondants sont retirés du processus à partir de cette étape.

8.4 Ajustement des poids finaux en fonction de la combinaison de la base aréolaire et la base PADD

À ce stade du processus, l'échantillon des deux bases de sondage peut être combiné en prévision de la correction des poids finaux (ajustements au niveau de la personne, winsorisation et calage). Puisque la population de la base de sondage du PADD fait partie de la population de la base aréolaire, il est nécessaire d'effectuer une correction supplémentaire de la pondération lors de la combinaison des bases de sondage.

I1 – Intégration des bases de sondage

Pour le cycle de 2023, l'ESCC a introduit un échantillon supplémentaire de la base de sondage du PADD qui représente la même population que celle couverte par la base aréolaire. Cette étape consiste à combiner les facteurs de pondération pour les ménages communs à la base de sondage du PADD et à la base aréolaire en appliquant une méthode d'intégration[8]. Un ajustement de l'intégration est calculé pour les provinces à l'aide de quatre facteurs de correction, calculés séparément pour représenter chacun des quatre principaux groupes du PADD (α, β, γ et δ). Chaque facteur de correction peut prendre une valeur de 0 à 1. Pour chaque province, ces facteurs sont déterminés de façon à représenter l'importance relative de chaque échantillon du groupe total intégré. Le terme « importance » fait ici référence à la taille réelle estimée de l'échantillon de chaque base de sondage : le rapport de la taille réelle de l'échantillon (taille de l'échantillon divisée par l'effet de plan) dans chacun des deux groupes intégrés.

De plus, chaque facteur d'intégration peut être ajusté en fonction de la probabilité qu'un ménage appartienne à chaque groupe du PADD. Lorsque l'appartenance à un groupe du PADD est connue, la probabilité de faire partie de ce groupe (ou d'aucun groupe du PADD) peut être établie à 1, et la probabilité de faire partie des autres groupes (autres groupes du PADD ou groupes ne faisant pas partie du PADD) est de 0. Pour les ménages dont l'appartenance à un domaine est inconnue, la probabilité de faire partie d'un groupe du PADD est estimée à l'aide de la proportion pondérée de ménages répondants du questionnaire détaillé du recensement. De plus, lorsqu'une personne du logement a répondu à l'ESCC, ses réponses peuvent être utilisées pour estimer la probabilité conditionnelle que le ménage fasse partie d'un groupe du PADD.

La probabilité connexe, p, de faire partie de chaque groupe (a=aucun groupe du PADD et seule la base aréolaire, d=ayant une incapacité, r=racisé, g= minorité de genre et i=Autochtone) et les facteurs d'intégration associés pour chaque groupe ($\alpha = incapacité, \beta = racisé, \gamma = minorité\ de\ genre$ et $\delta = Autochtone$) peuvent être utilisés pour créer l'ajustement :

$$AdjI1 = p_{aj} + p_{dj}\alpha + p_{rj}\beta + p_{gj}\gamma + p_{ij}\delta$$

[8] Skinner, C.J. et Rao, J.N.K. 1996. Estimation dans le cadre d'enquêtes à base de sondage double avec plans complexes. *Journal of the American Statistical Association*. 91(433), p. 349-356.

À noter que pour les ménages dont l'appartenance au groupe du PADD est connue, ADjI1 simplifie le facteur d'intégration de ce groupe, ou 1 pour les ménages dont on sait qu'ils ne font pas partie d'un groupe du PADD. À cette étape, les poids précédents de la base aréolaire et de la base du PADD sont combinés en un seul fichier. Le poids des unités de la base aréolaire est multiplié par ce facteur AdjI1, tandis que le poids de la base de sondage du PADD est multiplié par (1-AdjI1). Ce rajustement s'appelle I1.

I3 – Sélection des personnes

Puisque l'unité d'échantillonnage finale est la personne, les poids au niveau du ménage calculés jusqu'ici doivent être convertis en poids au niveau de la personne. Le poids au niveau de la personne est obtenu en multipliant le poids au niveau du ménage par l'inverse de la probabilité de sélection de la personne sélectionnée dans le ménage. Nous obtenons ainsi le poids I3. La probabilité de sélection d'une personne vivant dans un logement sélectionné à partir de la base aréolaire varie selon le nombre de personnes au sein du ménage et selon leur âge (voir la sous-section 5.6 pour obtenir plus de détails).

I4 – Non-réponse au niveau des personnes

Le questionnaire de l'ESCC pour les logements de la base des adultes peut être considéré comme un processus en deux parties. Tout d'abord, un membre du ménage fournit une liste de toutes les personnes qui composent le ménage. Ensuite, la personne sélectionnée remplit le questionnaire. Dans certains cas, seule la première partie est remplie, soit parce qu'il n'est pas possible de communiquer avec la personne sélectionnée, soit parce que cette dernière refuse de remplir le questionnaire électronique ou d'être interviewée. De tels cas sont définis comme des non-réponses au niveau de la personne, et un facteur de correction doit être appliqué aux poids des personnes répondantes pour compenser cette non-réponse. Comme lors du traitement de la non-réponse au niveau du ménage, l'ajustement est appliqué à l'intérieur de groupes de réponses homogènes (GRH). Dans le cadre de ce processus, la méthode de notation permet de définir une probabilité de réponse définie à partir des caractéristiques des répondants et des non-répondants accessibles. Toutes les caractéristiques recueillies lors du listage des membres du ménage, en plus de celles utilisées pour modéliser la non-réponse au niveau du ménage (information géographique et paradonnées), sont accessibles aux fins d'estimation des probabilités de réponse. Ces probabilités sont groupées sous forme de GRH et le facteur de correction suivant est calculé à l'intérieur de chaque groupe :

$$\frac{\textit{Somme des poids I3 pour toutes les personnes sélectionnées}}{\textit{Somme des poids I3 pour toutes les personnes répondantes sélectionnées}}$$

Le poids des personnes répondantes est multiplié par le facteur de correction ci-dessus pour l'obtention du poids I4. Les personnes non répondantes sont éliminées du processus de pondération à partir de cette étape.

I5 – Winsorisation

Après la série d'ajustements appliqués aux répondants, il est possible que certaines unités se retrouvent avec des poids extrêmes comparativement aux autres unités du même domaine d'intérêt.

Ces unités peuvent influer fortement sur la variance. Pour prévenir une telle situation, on rajuste à la baisse le poids des unités aberrantes au moyen de l'approche de réduction par winsorisation.

I6 – Calage

La dernière étape nécessaire pour l'obtention du poids final de l'ESCC est le calage (I6). Le calage est effectué au moyen du système d'estimation généralisé de Statistique Canada, G-EST, afin que la somme des poids finaux corresponde aux estimations de la population définies à l'échelle des RS pour l'ensemble des 10 groupes d'âge et de sexe d'intérêt. Les cinq groupes d'âge comprennent les groupes de 18 à 34 ans, de 35 à 49 ans, de 50 à 64 ans, de 65 à 74 ans et de 75 ans et plus, chez les hommes et chez les femmes. Une taille minimale de 15 répondants est nécessaire aux fins du calage au niveau RS par âge et par sexe. Lorsque le nombre de répondants est inférieur à 15, certains regroupements sont effectués à l'échelle de la province ou selon le sexe. Les poids sont également ajustés afin que chaque période de collecte soit également représentée par l'échantillon. Il est à noter que le calage est effectué au moyen des données géographiques les plus récentes, qui peuvent différer des données géographiques utilisées lors de l'échantillonnage.

Les estimations de la population sont des projections basées sur les nombres du Recensement de 2021 et les comptes de naissance, de décès, d'immigration et d'émigration depuis cette date. Au cours d'une année normale, la moyenne des estimations mensuelles relatives à chaque post-strate RS-âge-sexe par période de collecte a été retenue pour le calage. Certaines modifications ont été apportées à ce calcul en 2023 en raison de changements apportés à la collecte.

- La deuxième et la troisième période de collecte se sont chevauchées en avril pour la population adulte. Pour représenter cela, les projections du recensement pour ce mois ont été utilisées dans l'estimation de la taille de la population adulte à la fois pour la première et la deuxième période de collecte. L'effet de ce changement sur la taille estimée de la population pour l'ensemble de l'année était négligeable.

Le poids de l'étape précédente est rajusté à l'aide de G-EST pour l'obtention du poids final I6. Le poids I6 correspond au ***poids-personne final de l'ESCC*** que l'on retrouve dans le fichier maître portant le nom de variable WTS_M.

8.5 Création d'un poids partagé

Outre le fichier maître qui contient tous les répondants de l'ESCC, un fichier de partage est créé, qui ne contient qu'une partie des répondants originaux de l'ESCC. En 2023, avec l'introduction du questionnaire électronique du répondant en 2022, le taux de partage est passé de plus de 90 % à moins de 80 %. Les personnes dans le fichier de partage ont consenti à la transmission de leurs données à certains partenaires. Pour compenser la perte de certains répondants du fichier, les poids des répondants qui ont consenti à échanger leurs données doivent être ajustés à l'aide du facteur :

$$\frac{\textit{Somme des poids I4 pour tous les répondants}}{\textit{Somme des poids I4 pour toutes les répondants acceptant de fournir leurs données}}$$

À l'instar des ajustements liés à la non-réponse, ce facteur est calculé à l'intérieur de groupes de réponses homogènes regroupant, dans ce cas, les ménages ayant une propension à partager jugée semblable. Le poids I4 des répondants qui ont consenti à échanger leurs données est multiplié par le facteur d'ajustement ci-dessus pour l'obtention d'un poids partagé. Comme on le fait dans le cadre du processus de pondération du fichier maître, on applique la winsorisation et le calage (de façon semblable aux ajustements I5 et I6) aux unités partagées. Le poids final après ces ajustements est appelé WTS_S.

9. QUALITÉ DES DONNÉES

9.1 Taux de réponse

Au total, 127 332 des unités sélectionnées dans l'ESCC de 2023 faisaient partie du champ de l'enquête[9], et 51 640 personnes ont répondu, ce qui donne un taux de réponse de 40,6%. L'annexe D présente les dénombrements des unités comprises dans le champ de l'enquête, les dénombrements des répondants et les taux de réponse correspondants, par province. Ces chiffres sont présentés séparément pour la base aréolaire et la base du PADD.

9.2 Erreurs dans les enquêtes

L'enquête permet de produire des estimations fondées sur l'information recueillie à partir d'un échantillon de personnes. On aurait pu obtenir des estimations quelque peu différentes si on avait effectué un recensement complet en utilisant le même questionnaire, les mêmes intervieweurs, les mêmes superviseurs, les mêmes méthodes de traitement, etc. que ceux utilisés pour l'enquête. La différence entre les estimations tirées de l'échantillon et celles qui découlent d'un dénombrement complet effectué dans des conditions semblables s'appelle l'*erreur due à l'échantillonnage* des estimations.

Des erreurs qui ne sont pas liées à l'échantillonnage peuvent se produire à presque toutes les étapes des opérations d'enquête. Il est possible que les intervieweurs comprennent mal les instructions, que les répondants fassent des erreurs en remplissant le questionnaire, que les réponses soient mal saisies et que des erreurs se produisent au moment du traitement et de la totalisation des données. Ces erreurs sont toutes des exemples d'*erreur non dues à l'échantillonnage*.

9.2.1 Erreurs non dues à l'échantillonnage

Sur un grand nombre d'observations, les erreurs aléatoires auront peu d'effet sur les estimations calculées à partir de l'enquête. Toutefois, les erreurs systématiques contribuent à biaiser les estimations de l'enquête. On a consacré beaucoup de temps et d'efforts à réduire les erreurs non dues à l'échantillonnage dans l'enquête. Des mesures d'assurance de la qualité ont été appliquées à chaque étape du cycle de collecte et de traitement des données afin de contrôler la qualité des données. On a notamment fait appel à des intervieweurs hautement qualifiés, une formation poussée sur les méthodes d'enquête et le questionnaire et l'observation des intervieweurs afin de

[9] Parmi les unités sélectionnées, certaines n'entrent pas dans le champ de l'enquête. Il s'agit, par exemple, de logements sélectionnés parmi la base liste de logements, mais qui se sont révélés inoccupés, ont été démolis ou ne sont pas des logements résidentiels. Ces unités ont été déterminées pendant la collecte des données, autrement, elles auraient été exclues avant la sélection de l'échantillon. Ces unités ne sont pas prises en compte dans le calcul des taux de réponse. Ce taux de réponse exclut les trois territoires.

déceler les problèmes. La mise à l'essai du questionnaire a également été une procédure essentielle pour réduire au maximum les erreurs de collecte de données.

L'une des principales sources d'erreurs non dues à l'échantillonnage et observées dans le cadre des enquêtes est l'effet de la non-réponse sur les résultats de l'enquête. L'étendue d'une non-réponse varie d'une non-réponse partielle (le fait de ne pas répondre simplement à une ou à plusieurs questions) à une non-réponse totale. Il y a eu peu de cas de non-réponse partielle dans l'ESCC, car une fois le questionnaire commencé, les répondants avaient tendance à le terminer. Il y a eu non-réponse totale lorsque la personne sélectionnée pour participer à l'enquête a refusé de le faire ou que l'intervieweur a été incapable d'entrer en contact avec elle. Les cas de non-réponse totale ont été considérés lors de la pondération en corrigeant les poids des personnes qui ont répondu à l'enquête afin de compenser ceux qui n'ont pas répondu. Voir la section 8 pour avoir de plus amples détails sur la correction de la pondération pour la non-réponse.

9.2.2 Erreurs dues à l'échantillonnage

Les estimations établies à partir d'une enquête-échantillon étant inévitablement sujettes aux erreurs d'échantillonnage, de bonnes méthodes statistiques exigent que les chercheurs fournissent aux utilisateurs une certaine indication de l'ampleur éventuelle de ce type d'erreur. L'ampleur potentielle des erreurs d'échantillonnage est mesurée au moyen de l'écart-type des estimations tirées des résultats de l'enquête. Cependant, en raison de la grande diversité des estimations que l'on peut tirer d'une enquête, l'écart-type d'une estimation est habituellement exprimé en fonction de l'estimation à laquelle il se rapporte. Cette mesure, appelée coefficient de variation (c.v.), s'obtient en divisant l'écart-type de l'estimation par l'estimation elle-même, et on l'exprime en pourcentage de l'estimation. Par exemple, supposons que l'on estime que 25 % des Canadiens âgés de 12 ans et plus sont des fumeurs réguliers et que cette estimation présente un écart-type de 0,003, le c.v. de cette estimation est calculé ainsi : (0,003/0,25) x 100 % = 1,2 %.

Toutefois, l'utilisation des c.v. comme mesure de la qualité des estimations des proportions fait longtemps l'objet de réserves. Pour ce type d'estimation, il y a lieu d'utiliser des intervalles de confiance pour obtenir une indication de l'erreur d'échantillonnage. L'écart-type et un seuil de probabilité donné (généralement 95 %) permettent de calculer un intervalle de confiance à l'intérieur duquel la vraie valeur de l'estimation a une probabilité de se retrouver. Les intervalles de confiance ont l'avantage de convenir à tous les types d'estimation, y compris les proportions, les moyennes, les totaux et les différences. Ils sont également faciles à interpréter.

Pour obtenir plus de détails sur la détermination des c.v. et des intervalles de confiance, voir la section 11. Pour consulter les lignes directrices relatives à la diffusion, voir la sous-section 10.4.

10. LIGNES DIRECTRICES POUR LA TOTALISATION, L'ANALYSE ET LA DIFFUSION

La présente section de la documentation comprend des lignes directrices destinées aux utilisateurs, pour la totalisation, l'analyse, la publication ou d'autres formes de diffusion des estimations tirées des fichiers d'enquête. Grâce à ces lignes directrices, les utilisateurs de microdonnées devraient pouvoir produire des chiffres semblables à ceux produits par Statistique Canada. Ils pourront aussi élaborer des chiffres non publiés actuellement en conformité avec les lignes directrices établies. Des méthodes visant à mesurer la précision et la qualité sont aussi décrites en parallèle avec les lignes directrices de diffusion afin de permettre de décider quand une estimation devrait être utilisée dans une publication.

10.1 Lignes directrices pour l'arrondissement

Afin que les estimations calculées d'après ces fichiers de microdonnées (fichier maître, fichier de partage, ou FMGD) correspondent à celles produites par Statistique Canada, il est vivement conseillé à l'utilisateur de les arrondir en se conformant aux lignes directrices suivantes :

a) Les estimations dans le corps principal d'un tableau statistique doivent être arrondies à la centaine près à l'aide de la technique d'arrondissement normale. Selon cette technique, si le premier ou le seul chiffre à supprimer se situe entre 0 et 4, le dernier chiffre à conserver ne change pas. Si le premier ou le seul chiffre à supprimer se situe entre 5 et 9, le dernier chiffre à conserver est augmenté de 1. Par exemple, selon la technique d'arrondissement normale à la centaine près, si les deux derniers chiffres se situent entre 00 et 49, ils sont remplacés par 00 et le chiffre précédent (le chiffre des centaines) reste inchangé. Si les derniers chiffres se situent entre 50 et 99, ils sont remplacés par 00 et le chiffre précédent est augmenté de 1;

b) Les totaux partiels de marge et les totaux de marge des tableaux statistiques doivent être calculés à partir de leurs éléments correspondants non arrondis, puis arrondis à leur tour à la centaine près selon la méthode d'arrondissement classique[10];

c) Les moyennes, les proportions, les taux et les pourcentages doivent être calculés à partir de composantes non arrondies (c.-à-d. des numérateurs et/ou des dénominateurs), puis être arrondis à leur tour à une décimale à l'aide de la technique d'arrondissement normale. Dans le cas d'un arrondissement normal à un seul chiffre, si le dernier ou le seul chiffre à supprimer se situe entre 0 et 4, le dernier chiffre à conserver ne change pas. Si le premier ou le seul chiffre à supprimer se situe entre 5 et 9, le dernier chiffre à conserver est augmenté de 1;

d) Les sommes et les différences d'agrégats (ou de rapports) doivent être calculées à partir de leurs composantes non arrondies correspondantes, puis être arrondies à leur tour à la centaine près (ou à la décimale près) à l'aide de la technique d'arrondissement normale;

[10] Les tableaux de l'ESCC depuis 2015 et des années suivantes utilisent un algorithme qui arrondit les totaux, puis qui résout les incohérences à l'intérieur du tableau pour que les totaux correspondent entre eux. Cette méthode d'arrondissement fait en sorte que les tableaux produits au moyen des microdonnées de l'ESCC pourraient ne pas fournir les mêmes totaux que ceux figurant dans les tableaux de données.

e) Dans les cas où, en raison de limitations d'ordre technique ou de toutes autres limites, une technique d'arrondissement autre que la technique normale est utilisée produisant des estimations à être publiées ou autrement diffusées différentes des estimations correspondantes publiées par Statistique Canada, nous conseillons vivement aux utilisateurs d'indiquer la raison de ces différences dans le ou les documents à publier ou à diffuser;

f) En aucun cas, les utilisateurs ne doivent publier ou autrement diffuser des estimations non arrondies. Les estimations non arrondies laissent entendre qu'elles sont plus précises qu'elles ne le sont en réalité.

10.2 Lignes directrices pour la pondération de l'échantillon en vue de la totalisation

Le plan d'échantillonnage utilisé pour cette enquête n'est pas auto pondéré. Autrement dit, le poids d'échantillonnage n'est pas le même pour toutes les personnes qui font partie de l'échantillon. Lorsqu'ils produisent des estimations simples, y compris des tableaux statistiques ordinaires, les utilisateurs doivent appliquer le poids d'échantillonnage approprié. Sinon, les estimations calculées à partir du ficher de microdonnées ne pourront être considérées comme représentatives de la population observée et ne correspondront pas à celles de Statistique Canada.

L'utilisateur ne doit pas non plus perdre de vue qu'en raison du traitement réservé au champ du poids, certains progiciels ne permettent pas d'obtenir des estimations qui coïncident exactement avec celles de Statistique Canada. Si des options sont disponibles, l'utilisateur devrait veiller à préciser que le poids est un poids d'échantillon plutôt qu'un poids de fréquence.

10.2.1 Définitions : estimations de type nominal, estimations quantitatives

Avant d'exposer la façon de totaliser et d'analyser les données de l'enquête, il est bon de décrire les deux grandes catégories d'estimations ponctuelles des caractéristiques de la population qui peuvent être produites à partir du fichier de microdonnées.

<u>Estimations de type nominal :</u>
Les estimations de type nominal sont des estimations du nombre ou du pourcentage de personnes qui, dans la population visée par l'enquête, possèdent certaines caractéristiques ou rentrent dans une catégorie définie. Le nombre de personnes qui fument tous les jours est un exemple d'estimation de ce genre. Une estimation du nombre de personnes possédant une certaine caractéristique peut aussi être désignée comme une estimation d'un agrégat.

Exemple de question de type nominal :

*Au cours des 30 derniers jours, à quelle fréquence ... a-t-il/elle fumé des cigarettes? (**CSS_020**)*
_ Tous les jours
_ Moins d'une fois par jour, mais au moins une fois par semaine
_ Moins d'une fois par semaine, mais au moins une fois au cours du dernier mois
_ Jamais

<u>Estimations quantitatives :</u>

Les estimations quantitatives sont des estimations de totaux ou de moyennes, de médianes ou d'autres mesures d'une tendance centrale de quantités reposant sur certains ou sur tous les membres de la population visée par l'enquête.

Un exemple d'estimation quantitative est le nombre moyen de cigarettes que fument par jour les personnes qui fument tous les jours. Le numérateur correspond à l'estimation du nombre total de cigarettes que fument par jour les personnes qui fument tous les jours et le dénominateur, à l'estimation du nombre de personnes qui fument tous les jours.

Exemple de question quantitative :

Habituellement, combien de cigarettes … fume-t-il/elle chaque jour? ***(CSS_025)***
|_|_|_| *Nombre de cigarettes*

10.2.2 Totalisation d'estimations de type nominal

On peut obtenir, à partir du fichier de microdonnées, des estimations du nombre de personnes qui possèdent une caractéristique donnée en additionnant les poids finaux de tous les enregistrements contenant des données sur la caractéristique étudiée.

Pour obtenir les proportions et les rapports de la forme $\hat{X} / \hat{Y}$ on doit :

a) Faire la somme des poids finaux des enregistrements contenant la variable étudiée pour obtenir le numérateur ($\hat{X}$);
b) Faire la somme des poids finaux des enregistrements contenant la variable étudiée pour obtenir le dénominateur ($\hat{Y}$);
c) diviser l'estimation du numérateur par celle du dénominateur.

10.2.3 Totalisation d'estimations quantitatives

Pour obtenir l'estimation d'une somme ou d'une moyenne pour une variable quantitative, on procède aux étapes suivantes (seule l'étape *a* est nécessaire pour obtenir l'estimation pour une somme) :

a) multiplier la valeur de la variable étudiée par le poids final puis faire la somme de cette quantité pour tous les enregistrements visés pour obtenir le numérateur ($\hat{X}$);
b) faire la somme des poids finaux des enregistrements contenant la variable étudiée pour obtenir le dénominateur ($\hat{Y}$);
c) diviser l'estimation du numérateur par celle du dénominateur.

Par exemple, pour obtenir l'estimation du nombre moyen de cigarettes fumées chaque jour par les personnes qui fument quotidiennement, il faut d'abord calculer le numérateur ($\hat{X}$) en additionnant le produit entre la valeur de la variable **CSS_025** et le poids **WTS_M.** Ensuite, additionnez cette valeur pour les enregistrements pour lesquels la valeur de la variable **CSS_020** est « tous les jours ». Le dénominateur ($\hat{Y}$) est obtenu en additionnant le poids final de tous les enregistrements pour lesquels la valeur de la variable **CSS_020** est « tous les jours ». Divisez ($\hat{X}$) par ($\hat{Y}$) pour obtenir le nombre moyen de cigarettes fumées chaque jour par les fumeurs quotidiens.

10.3 Lignes directrices pour l'analyse statistique

L'ESCC se fonde sur un plan de sondage complexe qui prévoit une stratification et un échantillonnage à plusieurs degrés, ainsi que la sélection des répondants avec probabilités inégales. L'utilisation des données provenant d'enquêtes aussi complexes présente des problèmes pour les analystes, parce que le plan d'enquête et les probabilités de sélection influent sur les procédures d'estimation et de calcul de la variance qui devraient être utilisées. L'utilisation des poids de sondage représente une première étape en vue de l'obtention de résultats appropriés.

Nombre de méthodes d'analyse intégrées aux progiciels statistiques permettent d'utiliser des poids, mais la signification et la définition de ces poids peuvent différer de celles applicables dans le contexte d'une enquête par sondage. Cela a pour résultat final que, même si dans plusieurs cas les estimations calculées au moyen des progiciels sont exactes, les variances et les statistiques fondées sur ces variances n'ont pratiquement aucune signification. Pour obtenir les résultats pertinents, les poids doivent être interprétés correctement par le progiciel, et on doit avoir recours à des techniques d'estimation de la variance appropriées.

Il existe plusieurs options pour assurer l'utilité des résultats obtenus au moyen de ce plan de sondage complexe. La première option, plus pertinente, consiste à utiliser les options de calcul de la variance énoncées au chapitre 11, fondées sur la méthode bootstrap. En deuxième lieu, il existe dans de nombreux progiciels des procédures propres aux enquêtes qui permettent d'interpréter le poids correctement. Par exemple, dans le SAS, PROC SURVEYMEANS fournit des résultats plus pertinents que les résultats produits à partir de PROC MEANS, car les poids bootstrap sont utilisés pour les estimations de la variance. PROC MEANS peut utiliser les poids de sondage pour redresser correctement les estimations, en tenant compte du plan de pondération inégal, mais tend à sous-estimer les variances en n'utilisant pas les poids bootstrap et en supposant que le plan de sondage prévoit un échantillon aléatoire simple. Veuillez consulter le document sur l'estimation de la variance bootstrap dans la documentation sur la diffusion de l'ESCC pour de plus amples renseignements. Il est recommandé aux utilisateurs de données d'utiliser des progiciels et des fonctions pouvant incorporer à la fois les poids d'échantillonnage et les poids bootstrap durant la réalisation de leurs analyses.

Toutefois, seules les options énoncées au chapitre 11 fondées sur la méthode bootstrap tiendront compte de la stratification, de la mise en grappes et du plan à bases de sondage multiples au moment du calcul de la variance.

10.4 Lignes directrices pour la diffusion

Étant donné que les estimations obtenues à partir de l'enquête sont fondées sur un échantillon, il existe une variabilité dans les valeurs obtenues, dans le sens où un échantillon différent pourrait donner lieu à des résultats différents. Pour tenir compte de cela, les utilisateurs doivent d'abord s'assurer qu'il y a suffisamment d'observations pour estimer de façon appropriée la statistique, ainsi que la variance. Une fois la variance obtenue, les utilisateurs devraient veiller à ce qu'elle soit suffisamment raisonnable pour que l'estimation puisse être interprétée de façon appropriée comme représentant à peu près la véritable valeur de population.

Avant de diffuser ou de publier des estimations, les analystes doivent prendre en considération la qualité de l'estimation. Tandis que les erreurs d'échantillonnage et non dues à l'échantillonnage

influencent la qualité des données, la présente section porte sur la qualité en ce qui a trait aux erreurs d'échantillonnage. À Statistique Canada, il est considéré comme une pratique exemplaire de faire état de l'erreur d'échantillonnage d'une estimation par l'intermédiaire de son intervalle de confiance (IC) de 95 %. L'intervalle de confiance devrait être diffusé avec l'estimation et dans le même tableau que l'estimation. En plus des intervalles de confiance, les estimations sont classées dans l'une des trois catégories de diffusion suivantes :

Catégorie A
Les estimations et intervalles de confiance peuvent être publiés sans mise en garde. Les utilisateurs des données doivent utiliser l'intervalle de confiance de 95 % pour évaluer si la qualité de l'estimation est suffisante. Notez que le « A » n'est pas un indicateur de qualité; il ne devrait pas être diffusé.

Catégorie E
Les estimations et les intervalles de confiance doivent être signalés par la lettre E (ou un quelconque identificateur similaire) et accompagnés d'un avertissement à propos de la qualité d'utiliser les estimations avec prudence. Les utilisateurs des données doivent utiliser l'intervalle de confiance de 95 % pour évaluer si la qualité de l'estimation est suffisante.

Catégorie F
Les estimations et les intervalles de confiance ne sont pas recommandés pour la diffusion. Ils sont jugés de si piètre qualité qu'ils ne peuvent pas être utilisés; ils présentent un niveau d'instabilité très élevé, ce qui les rend peu fiables et potentiellement trompeurs. Si les analystes insistent pour publier des estimations de piètre qualité, même après avoir été informés de leur exactitude, ces estimations doivent être accompagnées d'un avis de non-responsabilité. Les analystes doivent tenir compte des mises en garde reçues et s'engager à ne pas diffuser, présenter, ni rapporter les estimations, directement ou indirectement, sans cet avis de non-responsabilité. Ces estimations doivent être signalées par la lettre F (ou un quelconque identificateur semblable) et la mise en garde suivante doit accompagner les estimations et intervalles de confiance : « Nous informons l'utilisateur que ces estimations et intervalles de confiance (désignés par la lettre F) ne respectent pas les normes de qualité de Statistique Canada. Les conclusions basées sur ces données ne seront pas fiables et peuvent être non valides. »

Les règles d'attribution d'une estimation à une catégorie de diffusion dépendent du type d'estimation. En outre, il convient de noter que la taille de l'échantillon requis par les règles de diffusion est susceptible de changer d'une année à l'autre.

10.4.1 Fichier maître ou de partage

Pour les utilisateurs des fichiers maîtres ou de partage, il est recommandé d'avoir au moins 10 observations avec la caractéristique d'intérêt et 20 dans le domaine si une proportion est calculée. Lorsqu'il y a suffisamment d'observations, l'utilisateur peut calculer la variance et les coefficients de variation au moyen des poids bootstrap fournis avec les données, ainsi que du logiciel approprié pour effectuer l'analyse. Les variances peuvent être utilisées pour calculer les coefficients de variation et les intervalles de confiance. Les intervalles de confiance permettent d'évaluer la fiabilité d'une estimation relativement à la variabilité de l'échantillonnage. Le coefficient de variation fournit une mesure relative de l'erreur d'échantillonnage

proportionnellement à l'estimation. Les estimations doivent être vérifiées à l'aide des lignes directrices de la section 10.4. Les coefficients de variation augmenteront au fur et à mesure que croît la variabilité d'une estimation et ils diminueront au fur et à mesure qu'une estimation devient plus précise. Une estimation peut toutefois être précise tout en présentant un coefficient de variation important, en particulier si l'estimation a une valeur proche de zéro. L'examen de l'intervalle de confiance de l'estimation fournira une autre indication de la qualité de l'estimation du point de vue de la variabilité. Les longs intervalles de confiance signalent une précision inférieure de l'estimation, tandis que les intervalles de confiance plus courts signalent une précision accrue. Il faut tenir compte des intervalles de confiance des estimations lors de l'évaluation de la fiabilité des proportions d'un échantillon. Il est considéré comme une pratique exemplaire à Statistique Canada de faire état de la qualité d'une estimation par son intervalle de confiance de 95 %.

10.4.2 Règles de diffusion pour les estimations de proportions

Les proportions estimées sont calculées à partir de variables binaires. Les proportions estimées sont des estimations de la proportion de personnes/ménages présentant une caractéristique d'intérêt (p. ex. la proportion estimée de fumeurs quotidiens au sein de la population générale). Les proportions estimées peuvent également être calculés à partir de variables catégoriques, c'est-à-dire des estimations de la proportion de personnes/ménages appartenant à une catégorie.

Les règles de diffusion pour les estimations de proportions sont fondées sur la taille de l'échantillon et la taille effective de l'échantillon. Le tableau 10.1 présente les règles de diffusion pour l'ESCC. Des proportions estimées à 0% ou 100% ne doivent pas être publiées.

Il est important de noter que la taille d'échantillon effective $\frac{(1-\hat{p})}{(\hat{p})CV^2}$, peut être utilisée en exprimant la variance estimée: $\frac{\hat{p}(1-\hat{p})}{\widehat{Var(\hat{p})}}$

Tableau 10.1 : Règles générales pour les proportions

Taille de l'échantillon (n)	Catégorie de diffusion	Mesure à prendre
$n_2 \geq 100$ et $\frac{(1-\hat{p})}{(\hat{p})CV^2} \geq 60$	A*	Diffusion sans avertissement; les utilisateurs doivent utiliser l'IC comme indicateur de qualité
Autrement	E	Diffuser avec une mise en garde sur la qualité; les utilisateurs devraient utiliser l'IC comme indicateur de qualité
$n_2 < 50$ OU $\frac{(1-\hat{p})}{(\hat{p})CV^2} < 30$ OU $\mathbf{n_1 < 10}$	F	Supprimer l'estimation et son IC pour des raisons de qualité

* Il convient de noter que « A » n'est pas un indicateur de qualité et ne devrait pas être diffusé avec l'estimation. L'intervalle de confiance de 95 % est l'indicateur de qualité.

Pour les estimations de proportions, « n_1 » est défini comme le nombre non pondéré de répondants dans le numérateur et « n_2 » est défini comme le nombre non pondéré de répondants dans le dénominateur de la proportion.

10.4.3 Règles de diffusion pour les estimations de comptes, de moyennes et de totaux

Les chiffres estimés sont calculés à partir de variables binaires. Les chiffres estimés sont des estimations du nombre total de personnes/ménages présentant une caractéristiques d'intérêt, autrement dit, ils sont la somme pondérée d'une variable binaire (p. Ex. Le nombre estimé de fumeurs). Les règles de diffusion pour les estimations de comptes, de moyennes et de totaux de variables quantitatives ou de quantités sont fondées sur la taille de l'échantillon et sur le c.v. de l'estimation et sont décrites dans le tableau 10.2.

Tableau 10.2 : Règles générales pour les comptes, les moyennes et les totaux

Taille de l'échantillon (n)	Catégorie de diffusion	Mesure à prendre
$n \geq 100$ et c.v. $\leq 25\%$	A*	Diffusion sans avertissement; les utilisateurs doivent utiliser l'IC comme indicateur de qualité
$50 \leq n < 100$ et c.v. $\leq 35\%$	E	Diffuser avec une mise en garde sur la qualité; les utilisateurs devraient utiliser l'IC comme indicateur de qualité
Autrement	F	Supprimer l'estimation et son IC pour des raisons de qualité

* Il convient de noter que « A » n'est pas un indicateur de qualité et ne devrait pas être diffusé avec l'estimation. L'intervalle de confiance de 95 % est l'indicateur de qualité.

Pour les estimations de chiffres, « n » est défini comme le nombre non pondéré de répondants dont les valeurs sont différentes de zéro et qui contribuent à l'estimation. Pour les estimations de moyennes, « n » est défini comme le nombre non pondéré de répondants qui contribuent à l'estimation, y compris les répondants avec les valeurs de zéro. Pour les estimations de totaux, « n » est défini comme le nombre non pondéré de répondants dont les valeurs sont différentes de zéro et qui contribuent à l'estimation.

10.4.4 Règles de diffusion pour les différences et les rapports

Afin d'assigner à une catégorie de diffusion une estimation de différence ou de rapport entre deux estimations, l'analyste doit d'abord déterminer la catégorie de diffusion de chacune des deux estimations en utilisant les règles décrites précédemment. Par la suite, la catégorie de diffusion de la différence estimée ou de l'estimation de la variation est attribuée à la catégorie de diffusion la plus basse des deux estimations; cela peut être précisé comme suit :

- Si au moins l'une des deux estimations est une estimation de catégorie F, la différence estimée doit alors être attribuée à la catégorie F et supprimée.

- Autrement, si au moins l'une des deux estimations est de catégorie E, la différence estimée est alors attribuée à la catégorie E
- Si les deux estimations sont de catégorie A, alors l'estimation de la différence est assignée à la catégorie A.

10.4.5 Règles additionnelles au sujet des intervalles de confiance

Les règles de diffusion ci-dessus prévoient la suppression de la plupart des estimations et des intervalles de confiance de piètre qualité. Deux conditions indiquent également qu'un intervalle de confiance est de piètre qualité. Une estimation et son intervalle de confiance doivent être attribués à la catégorie de diffusion F si l'une des deux conditions suivantes est présente :

- La borne inférieure de l'intervalle de confiance de 95 % est égale à la borne supérieure de l'intervalle; autrement dit, l'intervalle de confiance est de longueur zéro. (Une exception survient si l'estimation correspond à un total de contrôle de calage.)
- La limite inférieure ou la limite supérieure de l'intervalle de confiance de 95 % n'est pas une valeur plausible pour l'estimation. À titre d'exemple, la borne inférieure d'une proportion estimée est négative.

11. TABLEAUX DE LA VARIABILITÉ D'ÉCHANTILLONNAGE APPROXIMATIVE

Afin de fournir une approximation rapide des coefficients de variation applicables à un large éventail d'estimations catégoriques tirées du fichier partagé, un ensemble de tables de variabilité d'échantillonnage approximative sera produit. Ces tableaux permettent aux utilisateurs d'obtenir un coefficient de variation approximatif selon la taille de l'estimation calculée à partir des données de l'enquête. L'intervalle de confiance sera calculé à partir de ce coefficient de variation. Le tableau 11.1 présente un tableau de consultation de l'ESCC de 2017 à l'échelle du Canada en exemple.

Tableau 11.1, ESCC Tableaux de la variabilité d'échantillonnage approximative, 2017 Partagé

NUMERATOR OF PERCENTAGE ('000)	ESTIMATED PERCENTAGE 0.1%	1.0%	2.0%	5.0%	10.0%	15.0%	20.0%	25.0%	30.0%	35.0%	40.0%	50.0%	70.0%	90.0%
1	126.8	126.2	125.5	123.6	120.3	116.9	113.4	109.8	106.1	102.2	98.2	89.7	69.5	40.1
2	89.6	89.2	88.8	87.4	85.1	82.7	80.2	77.7	75.0	72.3	69.5	63.4	49.1	28.4
3	73.2	72.9	72.5	71.4	69.5	67.5	65.5	63.4	61.3	59.0	56.7	51.8	40.1	23.2
4	63.4	63.1	62.8	61.8	60.2	58.5	56.7	54.9	53.1	51.1	49.1	44.8	34.7	20.1
5	56.7	56.4	56.1	55.3	53.8	52.3	50.7	49.1	47.5	45.7	43.9	40.1	31.1	17.9
6	51.7	51.5	51.3	50.5	49.1	47.7	46.3	44.8	43.3	41.7	40.1	36.6	28.4	16.4
7	47.9	47.7	47.5	46.7	45.5	44.2	42.9	41.5	40.1	38.6	37.1	33.9	26.3	15.2
8	44.8	44.6	44.4	43.7	42.5	41.3	40.1	38.8	37.5	36.1	34.7	31.7	24.6	14.2
9	42.3	42.1	41.8	41.2	40.1	39.0	37.8	36.6	35.4	34.1	32.7	29.9	23.2	13.4
10	40.1	39.9	39.7	39.1	38.0	37.0	35.9	34.7	33.6	32.3	31.1	28.4	22.0	12.7
11	38.2	38.0	37.9	37.3	36.3	35.3	34.2	33.1	32.0	30.8	29.6	27.0	20.9	12.1
12	36.6	36.4	36.2	35.7	34.7	33.8	32.7	31.7	30.6	29.5	28.4	25.9	20.1	11.6
13	35.2	35.0	34.8	34.3	33.4	32.4	31.5	30.5	29.4	28.4	27.2	24.9	19.3	11.1
14	33.9	33.7	33.6	33.0	32.2	31.2	30.3	29.4	28.4	27.3	26.3	24.0	18.6	10.7
15	32.7	32.6	32.4	31.9	31.1	30.2	29.3	28.4	27.4	26.4	25.4	23.2	17.9	10.4
16	31.7	31.5	31.4	30.9	30.1	29.2	28.4	27.5	26.5	25.6	24.6	22.4	17.4	10.0
17	30.7	30.6	30.4	30.0	29.2	28.4	27.5	26.6	25.7	24.8	23.8	21.7	16.8	9.7
18	29.9	29.7	29.6	29.1	28.4	27.6	26.7	25.9	25.0	24.1	23.2	21.1	16.4	9.5
19	29.1	28.9	28.8	28.4	27.6	26.8	26.0	25.2	24.3	23.5	22.5	20.6	15.9	9.2
20	28.3	28.2	28.1	27.6	26.9	26.1	25.4	24.6	23.7	22.9	22.0	20.1	15.5	9.0
21	27.7	27.5	27.4	27.0	26.3	25.5	24.8	24.0	23.2	22.3	21.4	19.6	15.2	8.8
22	27.0	26.9	26.8	26.4	25.7	24.9	24.2	23.4	22.6	21.8	20.9	19.1	14.8	8.6
23	26.4	26.3	26.2	25.8	25.1	24.4	23.7	22.9	22.1	21.3	20.5	18.7	14.5	8.4
24	25.9	25.8	25.6	25.2	24.6	23.9	23.2	22.4	21.7	20.9	20.1	18.3	14.2	8.2
25	25.4	25.2	25.1	24.7	24.1	23.4	22.7	22.0	21.2	20.4	19.6	17.9	13.9	8.0
30	23.1	23.0	22.9	22.6	22.0	21.3	20.7	20.1	19.4	18.7	17.9	16.4	12.7	7.3
35	21.4	21.3	21.2	20.9	20.3	19.8	19.2	18.6	17.9	17.3	16.6	15.2	11.7	6.8
40	20.0	20.0	19.9	19.5	19.0	18.5	17.9	17.4	16.8	16.2	15.5	14.2	11.0	6.3
45	18.9	18.8	18.7	18.4	17.9	17.4	16.9	16.4	15.8	15.2	14.6	13.4	10.4	6.0
50	17.9	17.8	17.8	17.5	17.0	16.5	16.0	15.5	15.0	14.5	13.9	12.7	9.8	5.7
55	17.1	17.0	16.9	16.7	16.2	15.8	15.3	14.8	14.3	13.8	13.2	12.1	9.4	5.4
60	16.4	16.3	16.2	16.0	15.5	15.1	14.6	14.2	13.7	13.2	12.7	11.6	9.0	5.2
65	15.7	15.7	15.6	15.3	14.9	14.5	14.1	13.6	13.2	12.7	12.2	11.1	8.6	5.0
70	15.2	15.1	15.0	14.8	14.4	14.0	13.6	13.1	12.7	12.2	11.7	10.7	8.3	4.8
75	14.6	14.6	14.5	14.3	13.9	13.5	13.1	12.7	12.3	11.8	11.3	10.4	8.0	4.6
80	14.2	14.1	14.0	13.8	13.5	13.1	12.7	12.3	11.9	11.4	11.0	10.0	7.8	4.5
85	13.7	13.7	13.6	13.4	13.0	12.7	12.3	11.9	11.5	11.1	10.7	9.7	7.5	4.3
90	13.4	13.3	13.2	13.0	12.7	12.3	12.0	11.6	11.2	10.8	10.4	9.5	7.3	4.2
95	13.0	12.9	12.9	12.7	12.3	12.0	11.6	11.3	10.9	10.5	10.1	9.2	7.1	4.1
100	12.7	12.6	12.6	12.4	12.0	11.7	11.3	11.0	10.6	10.2	9.8	9.0	6.9	4.0
125	11.3	11.3	11.2	11.1	10.8	10.5	10.1	9.8	9.5	9.1	8.8	8.0	6.2	3.6
150	10.3	10.3	10.3	10.1	9.8	9.5	9.3	9.0	8.7	8.3	8.0	7.3	5.7	3.3
200	9.0	8.9	8.9	8.7	8.5	8.3	8.0	7.8	7.5	7.2	6.9	6.3	4.9	2.8
250	8.0	8.0	7.9	7.8	7.6	7.4	7.2	6.9	6.7	6.5	6.2	5.7	4.4	2.5
300	7.3	7.3	7.2	7.1	6.9	6.8	6.5	6.3	6.1	5.9	5.7	5.2	4.0	2.3
350	********	6.7	6.7	6.6	6.4	6.2	6.1	5.9	5.7	5.5	5.3	4.8	3.7	2.1
400	********	6.3	6.3	6.2	6.0	5.8	5.7	5.5	5.3	5.1	4.9	4.5	3.5	2.0
450	********	5.9	5.9	5.8	5.7	5.5	5.3	5.2	5.0	4.8	4.6	4.2	3.3	1.9
500	********	5.6	5.6	5.5	5.4	5.2	5.1	4.9	4.7	4.6	4.4	4.0	3.1	1.8
750	**********	4.6	4.5	4.4	4.3	4.1	4.0	3.9	3.7	3.6	3.3	2.5	1.5	
1000	**********	4.0	3.9	3.8	3.7	3.6	3.5	3.4	3.2	3.1	2.8	2.2	1.3	
1500	**********	3.2	3.2	3.1	3.0	2.9	2.8	2.7	2.6	2.5	2.3	1.8	1.0	
2000	**********	2.8	2.7	2.6	2.5	2.5	2.4	2.3	2.2	2.0	1.6	0.9		
3000	**********	2.3	2.2	2.1	2.1	2.0	1.9	1.9	1.8	1.6	1.3	0.7		
4000	**********	1.9	1.8	1.8	1.7	1.7	1.6	1.6	1.4	1.1	0.6			
5000	**********	1.7	1.6	1.6	1.5	1.4	1.4	1.3	1.0	0.6				
6000	**********	1.5	1.5	1.4	1.4	1.3	1.3	1.2	0.9	0.5				
7000	**********	1.4	1.3	1.3	1.2	1.2	1.1	0.8	0.5					
8000	**********	1.2	1.2	1.1	1.1	1.0	0.8	0.4						
9000	**********	1.2	1.1	1.1	1.0	0.9	0.7	0.4						
10000	**********	1.1	1.0	1.0	0.9	0.7	0.4							
12500	**********	0.9	0.8	0.6	0.4									
15000	**********	0.8	0.7	0.6	0.3									

Les coefficients de variation (c.v.) sont calculés en employant la formule de la variance utilisée pour l'échantillonnage aléatoire simple et en y incorporant un facteur qui représente la structure en grappes à plusieurs degrés du plan d'échantillonnage. Pour obtenir ce facteur, appelé ***effet de plan***, on a d'abord calculé les effets de plan pour une vaste gamme de caractéristiques, puis pour chaque tableau, choisi une valeur conservatrice parmi tous les effets de plan relatifs à ce tableau. Cette valeur choisie a ensuite été utilisée pour générer le tableau qui peut alors s'appliquer à l'ensemble complet des caractéristiques.

Les tableaux de la variabilité d'échantillonnage approximative, de même que les effets de plan, les tailles d'échantillon et les comptes de population qui ont servi à les produire, sont disponibles pour

les utilisateurs du fichier partagé dans le document *Tableaux de la variabilité d'échantillonnage approximative*. Tous les coefficients de variation inclus dans les tables de variabilité d'échantillonnage approximative sont approximatifs et donc non officiels. Les possibilités concernant le calcul d'un coefficient de variation exact sont discutées dans la sous-section 11.6. Une analyse fondée sur l'utilisation de poids bootstrap est la méthode qui devrait être utilisée pour obtenir des résultats plus précis.

Rappel : Comme indiqué dans les « Lignes directrices pour la diffusion » à la section 10.4, si le nombre d'observations sur lesquelles une estimation est basée est inférieur à 10, l'estimation pondérée ne doit pas être diffusée, quelle que soit la valeur de son coefficient de variation. Les coefficients de variation basés sur des échantillons de petite taille sont trop imprévisibles pour être adéquatement représentés dans les tableaux. L'utilisation des tableaux pour estimer les coefficients de variation produit des résultats encore moins précis que l'utilisation de poids bootstrap de sorte que, dans ce cas, un minimum de 30 observations est requis.

11.1 Comment utiliser les tableaux de c.v. pour calculer les limites de confiance

Bien que les coefficients de variation soient beaucoup utilisés, l'intervalle de confiance d'une estimation est une mesure plus intuitivement significative de l'erreur d'échantillonnage. Il est considéré comme une pratique exemplaire à Statistique Canada de faire état de la qualité d'une estimation par son intervalle de confiance de 95 %. Un intervalle de confiance constitue une déclaration du niveau de confiance selon laquelle la valeur vraie pour la population se situe à l'intérieur d'une gamme précisée de valeurs. Par exemple, un intervalle de confiance de 95 % peut être décrit comme suit : si l'échantillonnage de la population se répète à l'infini, chacun des échantillons donnant un nouvel intervalle de confiance pour une estimation, l'intervalle contiendra la valeur vraie de la population dans 95 % des cas.

En utilisant l'erreur-type d'une estimation, des intervalles de confiance pour des estimations peuvent être obtenus en partant de l'hypothèse qu'aux termes d'un échantillonnage répété de la population, les diverses estimations obtenues pour une caractéristique donnée de la population se répartiront normalement autour de la valeur vraie de la population. Selon cette hypothèse, il y a environ 68 chances sur 100 que l'écart entre une estimation de l'échantillon et la valeur vraie pour la population soit inférieur à une erreur-type, environ 95 chances sur 100 que l'écart soit inférieur à deux erreurs-types et environ 99 chances sur 100 que l'écart soit inférieur à trois erreurs-types. Ces différents degrés de confiance sont désignés sous le nom de niveaux de confiance.

Des intervalles de confiance pour une estimation, $\hat{X}$, sont généralement exprimés sous forme de deux chiffres, un inférieur et un supérieur à l'estimation, comme étant $\left(\hat{X} - k,\ \hat{X} + k\right)$, où k est déterminé suivant le niveau de confiance désiré et l'erreur d'échantillonnage de l'estimation.

Des intervalles de confiance pour une estimation peuvent être calculés directement à partir des tables de variabilité d'échantillonnage approximative, en déterminant d'abord à partir de la table appropriée le coefficient de variation de l'estimation $\hat{X}$, puis en utilisant la formule suivante pour le convertir à un intervalle de confiance :

$$CI_X = [\ \hat{X} - z\ \hat{X}\ \alpha_{\hat{X}}\ ,\ \hat{X} + z\ \hat{X}\ \alpha_{\hat{X}}\ ]$$

Où $\alpha_{\hat{X}}$ est le coefficient de variation déterminé de $\hat{X}$, et

z = 1 si l'on désire un intervalle de confiance de 68 %
z = 1,6 si l'on désire un intervalle de confiance de 90 %
z = 2 si l'on désire un intervalle de confiance de 95 %
z = 3 si l'on désire un intervalle de confiance de 99 %

Note : Les lignes directrices concernant la diffusion des estimations de la section 10.4 s'appliquent aussi aux intervalles de confiance. S'il est impossible, par exemple, de diffuser une estimation, on ne peut alors pas non plus communiquer un intervalle de confiance.

11.2 Comment utiliser les tableaux de c.v. pour les estimations de type nominal

Les règles qui suivent devraient permettre à l'utilisateur de déterminer les coefficients de variation approximatifs à partir des tables de variabilité d'échantillonnage pour des estimations du nombre, de la proportion ou du pourcentage de membres de la population visée par l'enquête possédant une certaine caractéristique et pour des rapports et des différences entre de telles estimations.

Règle 1 : Estimations du nombre de personnes possédant une caractéristique donnée (agrégats)
Le coefficient de variation dépend uniquement de la taille de l'estimation elle-même. Dans le tableau de coefficients de variation approximatifs correspondant à la région appropriée, il faut repérer l'estimation calculée dans la colonne d'extrême gauche (intitulée « Numérateur du pourcentage ») et suivre les astérisques (s'il y en a) de gauche à droite jusqu'au premier nombre. Puisque toutes les valeurs possibles de l'estimation ne sont pas disponibles, il faut prendre la valeur la plus petite qui s'en rapproche le plus (p. ex. si l'estimation vaut 1 700 et que les deux valeurs disponibles sont 1 000 et 2 000, il faut choisir 1 000). Ce chiffre est le coefficient de variation approximatif.

Règle 2 : Estimations de proportions ou de pourcentages de personnes possédant une caractéristique donnée
Le coefficient de variation d'une proportion (ou d'un pourcentage) estimée dépend à la fois de l'ordre de grandeur de cette proportion et de l'ordre de grandeur du numérateur utilisé dans le calcul de la proportion. Les proportions estimées sont relativement plus fiables que les estimations correspondantes du numérateur de la proportion lorsque celle-ci est fondée sur un sous-ensemble de la population. Cela est dû au fait que les coefficients de variation des estimations du dernier type sont basés sur le chiffre le plus élevé dans une rangée d'un tableau particulier, tandis que les coefficients de variation des estimations du premier type sont basés sur un chiffre quelconque de cette même rangée (pas nécessairement le plus élevé). (Il convient de noter que dans les tableaux, la valeur des coefficients de variation décroît de gauche à droite sur une même ligne.) Par exemple, la <u>proportion</u> estimative de personnes qui fument tous les jours parmi les fumeurs est plus fiable que le <u>nombre</u> estimatif de personnes qui fument tous les jours.

Lorsque la proportion (ou le pourcentage) est fondée sur la population totale de la région géographique à laquelle le tableau s'applique, le coefficient de variation de la proportion est égal à celui du numérateur de la proportion. Dans ce cas-ci, cela équivaut à appliquer la règle 1.

Lorsque la proportion (ou le pourcentage) est fondée sur un sous-ensemble de la population totale (p. ex. les personnes qui fument), il faut se reporter à la proportion (haut du tableau) et au numérateur de la proportion ou du pourcentage (côté gauche du tableau). Puisque toutes les valeurs possibles de la proportion et du numérateur ne sont pas disponibles, il faut, dans les deux cas, prendre la valeur la plus petite qui s'en rapproche le plus (p. ex. si la proportion est de 23 % et que les deux valeurs disponibles dans la colonne s'en rapprochant le plus sont 20 % et 25 %, il faut choisir 20 %). L'intersection de la rangée et de la colonne appropriées donne le coefficient de variation.

Règle 3 : Estimations des différences entre des agrégats ou des pourcentages
L'erreur-type d'une différence entre deux estimations est approximativement égale à la racine carrée de la somme des carrés de chaque erreur-type considérée séparément. C'est-à-dire que l'erreur-type d'une différence ($\hat{d} = \hat{X}_2 - \hat{X}_1$) est :

$$\sigma_{\hat{d}} = \sqrt{(\hat{X}_1 \alpha_1)^2 + (\hat{X}_2 \alpha_2)^2}$$

où $\hat{X}_1$ est l'estimation 1, $\hat{X}_2$ est l'estimation 2 et α_1 et α_2 sont les coefficients de variation de $\hat{X}_1$ et $\hat{X}_2$ respectivement. Le coefficient de variation de $\hat{d}$ est donné par $\sigma_{\hat{d}} / \hat{d}$. Cette formule donne un résultat exact pour ce qui est de la différence entre des sous-populations indépendantes, mais n'est autrement qu'approximative. Elle tendra à surestimer l'erreur si $\hat{X}_1$ et $\hat{X}_2$ sont corrélés positivement et à la sous-estimer si $\hat{X}_1$ et $\hat{X}_2$ sont corrélés négativement.

Règle 4 : Estimations de rapports
Dans le cas où le numérateur est un sous-ensemble du dénominateur, le rapport devrait être converti en un pourcentage et la règle 2 appliquée. Ce serait le cas, par exemple, si le dénominateur est le nombre de personnes qui fument et le numérateur est le nombre de personnes qui fument tous les jours parmi celles qui fument.

Examinons une situation où le numérateur n'est pas un sous-ensemble du dénominateur (par exemple, le rapport du nombre de personnes qui fument tous les jours ou à l'occasion au nombre de personnes qui ne fument pas du tout). L'erreur-type du rapport entre les estimations est approximativement égale à la racine carrée de la somme des carrés de chaque coefficient de variation examiné séparément multipliée par $\hat{R}$, où $\hat{R}$ est le rapport des estimations ($\hat{R} = \hat{X}_1 / \hat{X}_2$). C'est-à-dire que l'erreur-type d'un rapport est :

$$\sigma_{\hat{R}} = \hat{R}\sqrt{\alpha_1^2 + \alpha_2^2}$$

où α_1 et α_2 sont les coefficients de variation de $\hat{X}_1$ et de $\hat{X}_2$ respectivement.

Le coefficient de variation de $\hat{R}$ est donné par $\sigma_{\hat{R}} / \hat{R} = \sqrt{\alpha_1^2 + \alpha_2^2}$. La formule tendra à surestimer l'erreur si $\hat{X}_1$ et $\hat{X}_2$ sont corrélés positivement et à la sous-estimer si $\hat{X}_1$ et $\hat{X}_2$ sont corrélés négativement.

Règle 5 : Estimations des différences entre des rapports
Dans ce cas, les règles 3 et 4 sont combinées. On détermine premièrement les c.v. pour les deux rapports à l'aide de la règle 4, puis on trouve le c.v. de leur différence au moyen de la règle 3.

11.3 Exemples d'utilisation des tableaux de c.v. pour des estimations de type nominal afin de calculer les intervalles de confiance

Les exemples réels suivants ont pour but d'aider les utilisateurs à appliquer les règles décrites ci-dessus. Les chiffres non arrondis sont utilisés dans les exemples pour faciliter les directives étape par étape. Ces exemples utilisent les tableaux de la variabilité d'échantillonnage approximative de l'ESCC de 2017 (Tableau 11.1). Les utilisateurs devraient toujours suivre les lignes directrices sur l'arrondissement comme mentionné dans la section 10.1 avant de publier des chiffres.

Exemple 1 : Estimations du nombre de personnes possédant une caractéristique donnée (agrégats)

Supposons qu'un utilisateur estime que 3 665 449 personnes fument quotidiennement au Canada et que le nombre non pondéré de répondants correspondant est de 6 789. Comment l'utilisateur détermine-t-il l'intervalle de confiance de 95 % de cette estimation?

1) Se reporter au tableau de c.v. pour le CANADA.
2) L'agrégat estimé (3 665 449) ne figure pas dans la colonne de gauche (la colonne « Numérateur du pourcentage »); il faut donc utiliser le nombre le plus petit qui s'en rapproche le plus, soit 3 000 000.
3) Le coefficient de variation d'un agrégat estimé (exprimé en pourcentage) est la première entrée sur cette ligne (à part les astérisques), soit 2,3 %.
4) En suivant les étapes de 11.1, nous obtenons ce qui suit :

   $\hat{X}$ = 3 665 449

   Z = 2

   $\alpha_{\hat{X}}$ = 0,023 est le coefficient de variation de cette estimation calculé en utilisant les tableaux.

   CI_X = {3 665 449 - (2) (3 665 449) (0.023), 3 665 449 + (2) (3 665 449) (0,023)}

   CI_X = {3 496 838, 3 834 060}

5) Comme le nombre non pondéré de répondants 6 789 est supérieur à 100, et que le coefficient de variation de 2.3% est inférieur à 25% selon le tableau 10.2, cette estimation peut être publiée sans mise en garde après avoir mis en oeuvre les règles d'arrondissement; les utilisateurs devraient utiliser l'IC comme indicateur de qualité.

Exemple 2 : Estimations de proportions ou de pourcentages de personnes possédant une caractéristique donnée

Supposons qu'un utilisateur estime à 3 665 449 / 5 151 237 = 71,2 % le pourcentage de personnes, parmi les fumeurs, qui fument tous les jours au Canada. Et que le nombre non pondéré de répondants est de 9 234. Comment l'utilisateur détermine-t-il l'intervalle de confiance de 95 % de cette estimation?

1) Se reporter au tableau de c.v. pour le CANADA.
2) Parce que l'estimation est un pourcentage basé sur un sous-ensemble de la population totale (c.-à-d. les personnes qui fument tous les jours ou à l'occasion), il faut utiliser à la fois le pourcentage (71,2 %) et la partie numérateur du pourcentage (3 665 449) pour déterminer le coefficient de variation.

3) Le numérateur (3 665 449) ne figure pas dans la colonne de gauche (la colonne « Numérateur du pourcentage »); il faut donc utiliser le nombre le plus petit qui s'en rapproche le plus, soit 3 000 000. De même, l'estimation du pourcentage ne figure pas parmi les en-têtes de colonnes; il faut donc utiliser le nombre le plus petit qui s'en rapproche le plus, soit 70,0 %.
4) Le nombre qui se trouve à l'intersection de la ligne et de la colonne utilisées, soit 1,3 %, est le coefficient de variation (exprimé en pourcentage) à utiliser.
5) En suivant les étapes de 11.1, nous obtenons ce qui suit :
   $\hat{X}$ = 71,2 %
   Z = 2
   $\alpha_{\hat{X}}$ = 0,013 est le coefficient de variation de cette estimation calculé en utilisant les tableaux.
   CI_X = {0,712 - (2) (0,712) (0,013), 0,712 + (2) (0,712) (0,023)}
   CI_X = {0,693, 0,731}

6) Comme le nombre non pondéré de répondants 9 234 est supérieure à 100 et que $\frac{(1-\hat{p})}{(\hat{p})CV^2} = \frac{1-0.712}{(0.712)(0.013^2)} = 2{,}393.46$ est supérieur à 60, selon le tableau 10.1, cette estimation peut être publiée sans mise en garde; les utilisateurs devraient utiliser l'IC comme indicateur de qualité.

Exemple 3 : Estimations des différences entre des agrégats ou des pourcentages

Supposons qu'un utilisateur estime que, parmi les hommes, 2 067 955 / 15 115 880 = 13,7 % fument quotidiennement (estimation 1), tandis que pour les femmes, ce pourcentage est estimé à 1 597 494 / 15 528 483 = 10,3 % (estimation 2). Pour l'estimation 1, la taille de l'échantillon du dénominateur est de 23 546 et pour l'estimation 2, la taille de l'échantillon du dénominateur est de 27 834. Comment l'utilisateur détermine-t-il l'intervalle de confiance de la différence entre ces deux estimations?

1) En utilisant le tableau de c.v. pour le CANADA de la même manière que dans l'exemple 2, on obtient un c.v. de 2,7 % (exprimé en pourcentage) pour l'estimation 1 et un c.v. de 3,1 % (exprimé en pourcentage) pour l'estimation 2.

2) En utilisant la règle 3, l'erreur-type d'une différence ($\hat{d} = \hat{X}_2 - \hat{X}_1$) est :
$$\sigma_{\hat{d}} = \sqrt{(\hat{X}_1 \alpha_1)^2 + (\hat{X}_2 \alpha_2)^2}$$
   où $\hat{X}_1$ est l'estimation 1, $\hat{X}_2$ est l'estimation 2 et α_1 et α_2 sont les coefficients de variation de $\hat{X}_1$ et $\hat{X}_2$ respectivement. L'erreur-type de la différence $\hat{d}$ = (0,137 - 0,103) = 0,034 est :
$$\sigma_{\hat{d}} = \sqrt{[(0.137)(0.027)]^2 + [(0.103)(0.031)]^2}$$
   = 0,00489

3) Le coefficient de variation de $\hat{d}$ est donné par $\sigma_{\hat{d}} / \hat{d}$ = 0,00489 / 0,034 = 0,144.
4) Le coefficient de variation approximatif de la différence entre les estimations est donc 14,4 % (exprimé en pourcentage).
5) En suivant les étapes de 11.1, nous obtenons ce qui suit :

$\hat{X} = 0{,}034$
$Z = 2$
$\alpha_{\hat{X}} = 0{,}144$ est le coefficient de variation de cette estimation calculé en utilisant les tableaux.
$CI_X = \{0{,}034 - (2)\ (0{,}034)\ (0{,}144),\ 0{,}034 + (2)\ (0{,}034)\ (0{,}144)\}$
$CI_X = \{0{,}0242,\ 0{,}0438\}$

6) Nous aurions également pu calculer l'intervalle de confiance en utilisant l'erreur-type de la différence :
$CI_X = \{0{,}034 - (2)\ (0{,}00489),\ 0{,}034 + (2)\ (0{,}00489)\}$

7) Selon les « Lignes directrices pour la diffusion » présentées à la section 10.4, cette estimation peut être diffusée sans mise en garde. Les deux tailles de l'échantillon du dénominateur sont supérieures à 100 (23,546 et 27,834), et les deux $\frac{(1-\hat{p})}{(\hat{p})CV^2}$ sont supérieurs à 60 (estimation 1:$\frac{(1-\hat{p})}{(\hat{p})CV^2} = \frac{1-0.137}{(0.137)(0.027^2)} = 8{,}640.97$ et estimation 2: $\frac{(1-\hat{p})}{(\hat{p})CV^2} = \frac{1-0.103}{(0.0.103)(0.031^2)} = 9{,}062.16$), Les deux estimations peuvent être publiées sans avertissement, comme indiqué dans le tableau 10.1 Compte tenu des règles de publication des différences énoncées à la section 10.4.4, la différence des estimations peut être publiée sans avertissement.

Exemple 4 : Estimations de rapports
Supposons que l'utilisateur estime que 3 665 449 personnes fument quotidiennement, et que le nombre non pondéré de répondants est de 6 789, tandis que 1 485 788 personnes fument occasionnellement, et que le nombre non pondéré correspondant est de 2 144. L'utilisateur veut comparer ces deux estimations sous la forme d'un rapport. Comment l'utilisateur détermine-t-il le coefficient de variation de cette estimation?

1) Tout d'abord, cette estimation est une estimation du rapport, où le numérateur de l'estimation ($= \hat{X}_1$) est le nombre de personnes qui fument occasionnellement. Le dénominateur de l'estimation ($= \hat{X}_2$) est le nombre de personnes qui fument quotidiennement.
2) Se reporter au tableau de c.v. pour le CANADA.
3) Le numérateur de cette estimation de rapport est 1 485 788. Le nombre le plus petit qui se rapproche le plus de ce nombre est 1 000 000. Le coefficient de variation de cette estimation (exprimé en pourcentage) est la première entrée sur cette ligne (à part les astérisques), soit 4,0 %.
4) Le dénominateur de cette estimation de rapport 3 665 449. Le nombre qui s'en rapproche le plus est 3 000 000. Le coefficient de variation de cette estimation (exprimé en pourcentage) est la première entrée sur cette ligne (à part les astérisques), soit 2,3 %.
5) Le coefficient de variation approximatif de l'estimation du rapport est donc donné par la règle 4 :

$$\alpha_{\hat{R}} = \sqrt{\alpha_1^{\ 2} + \alpha_2^{\ 2}},$$

C'est-à-dire

$$\alpha_{\hat{R}} = \sqrt{(0.040)^2 + (0.023)^2}$$

= 0,046

où α_1 et α_2 sont les coefficients de variation de $\hat{X}_1$ et de $\hat{X}_2$ respectivement. Le rapport des personnes qui fument occasionnellement à celles qui fument tous les jours est 1 485 788 / 3 665 449, soit 0,41:1. Le coefficient de variation de cette estimation est de 4,6 % (exprimé en pourcentage). L'intervalle de confiance à 95 % est (37,2 %, 44,8 %), ce qui fait qu'on peut la diffuser sans réserve, conformément aux « Lignes directrices pour la diffusion » présentées à la section 10.4, car pour chaque estimation, le nombre non pondéré de répondants est supérieure à 100 et chaque estimation a un coefficient de variation inférieur à 25%. Comme indiqué dans le tableau 10.2 le deux estimation peuvent être diffuser sans réserve, et étant donné les régles pour les rapports expliquées à la section 10.4.4, le rapport des estimations peut être diffusé sans réserve

11.4 Comment utiliser les tableaux de c.v. pour effectuer un test Z

Des erreurs-types peuvent aussi être utilisés pour effectuer des tests d'hypothèses, une procédure destinée à distinguer des paramètres d'une population à l'aide d'estimations d'un échantillon. Ces estimations peuvent être des chiffres, des moyennes, des pourcentages, des rapports, etc. Les tests peuvent être effectués à divers niveaux de signification, où un niveau de signification est la probabilité de conclure que les caractéristiques sont différentes quand, en fait, elles sont identiques.

Supposons que $\hat{X}_1$ et $\hat{X}_2$ sont des estimations d'un échantillon pour deux caractéristiques qui nous intéressent. Supposons également que l'erreur-type de la différence $\hat{X}_1 - \hat{X}_2$ est $\sigma_{\hat{d}}$. Si le rapport de $\hat{X}_1 - \hat{X}_2$ par rapport à $\sigma_{\hat{d}}$ se situe entre -2 et 2, aucune conclusion à propos de la différence entre les caractéristiques n'est alors justifiée au niveau de signification de 5 %. Toutefois, si ce rapport est inférieur à -2 ou supérieur à +2, la différence observée est significative au niveau de 5 %.

11.5 Exemple d'utilisation des tableaux de c.v. pour effectuer un test Z

Supposons que nous voulons tester, au niveau de signification de 5 %, l'hypothèse selon laquelle il n'y a pas de différence entre la proportion d'hommes qui fument tous les jours et cette même proportion chez les femmes. Dans l'exemple 3 de la sous-section 11.2, nous avons déterminé que l'erreur-type de la différence entre ces deux estimations = 0,00489. Par conséquent,

$$z = \frac{\hat{X}_1 - \hat{X}_2}{\sigma_{\hat{d}}} = \frac{0.137 - 0.103}{0.0048995} = \frac{0.034}{0.0048995} = 6.87$$

Puisque Z = 6,95 est supérieur à 2, il faut en conclure qu'il existe une différence significative entre les deux estimations au niveau de signification de 5 %. À noter que les deux sous-groupes comparés sont considérés comme étant indépendants, ce qui fait en sorte que le résultat du test est valide.

11.6 Variances ou coefficients de variation exacts

Tous les coefficients de variation qui figurent dans les tableaux de la variabilité d'échantillonnage approximative (tableaux de c.v.) sont effectivement approximatifs, donc, non officiels.

Le calcul de variance ou coefficient de variation exact n'est pas chose évidente puisqu'il n'existe pas de formule mathématique simple pouvant prendre en compte tous les aspects du plan d'échantillonnage et de la pondération de l'ESCC. On doit donc avoir recours à d'autres méthodes pour estimer ces mesures de précision, comme des méthodes par rééchantillonnage. Parmi celles-ci, la méthode du bootstrap est celle recommandée pour l'analyse des données de l'ESCC.

De nombreux progiciels statistiques permettent de réaliser des analyses à l'aide de poids bootstrap. De plus amples renseignements sont présentés à la section 10.3 et dans le document sur l'estimation de la variance bootstrap.

Les raisons pour lesquelles un utilisateur pourrait souhaiter connaître la variance avec exactitude sont diverses. En voici quelques-unes.
Premièrement, si un utilisateur désire obtenir des estimations à un niveau géographique autre que ceux présentés dans les tableaux (par exemple, au niveau urbain ou rural), l'utilisation des tableaux de c.v. publiés ne convient pas parfaitement. Néanmoins, on peut obtenir les coefficients de variation de ce type d'estimations en appliquant la méthode d'estimation par domaine, au moyen du programme de calcul de la variance exacte.

Deuxièmement, si un utilisateur demande des analyses plus complexes, telles que des estimations de paramètres de modèles de régression linéaire ou logistique, les tableaux de c.v. ne pourront pas fournir les coefficients de variation pour ceux-ci. Certains progiciels statistiques courants permettent d'incorporer les poids d'échantillonnage aux analyses, mais, souvent, les variances produites ne tiennent pas bien compte de la stratification et de la mise en grappe de l'échantillon, contrairement à celles obtenues grâce au programme de calcul de la variance exacte.

Troisièmement, dans le cas de l'estimation de variables quantitatives, il est nécessaire d'utiliser des tableaux distincts pour déterminer l'erreur d'échantillonnage. Or, la plupart des variables de l'ESCC étant de type catégorique, de tels tableaux n'ont pas été produits. Ainsi, les utilisateurs souhaitant obtenir des coefficients de variation et des intervalles de confiance pour des variables quantitatives peuvent le faire grâce au programme de calcul de la variance exacte.

Cette situation tient au fait que l'estimation des coefficients de variation au moyen des tableaux de la variabilité d'échantillonnage approximative est basée sur une vaste gamme de variables et est donc jugée brute, tandis que le programme de calcul de la variance réelle produit le coefficient de variation précis associé à la variable en question. Les intervalles de confiance calculés à l'aide des coefficients de variation produits par les tableaux ne sont donc pas considérés comme étant exacts.

12. FICHIERS DE MICRODONNÉES: DESCRIPTION, ACCÈS ET UTILISATION

L'ESCC produit trois types de fichiers de microdonnées : les fichiers maîtres, les fichiers de partage et les fichiers de microdonnées à grande diffusion (FMGD). Le tableau 12.1 comprend la liste de tous les fichiers de données disponibles pour la période de collecte de 2023.

12.1 Fichiers maîtres

Les fichiers maîtres contiennent toutes les variables et tous les enregistrements de l'enquête associés à une période spécifique. Ces fichiers sont accessibles à Statistique Canada pour usage interne, dans les Centres de données de recherche (CDR) de Statistique Canada et peuvent aussi faire l'objet de demandes de totalisations personnalisées.

12.1.1 Centre de données de recherche

Le Programme des CDR permet aux chercheurs d'utiliser les données d'enquête contenues dans les fichiers maîtres dans un environnement sécuritaire situé dans plusieurs universités au Canada. Les chercheurs doivent soumettre des propositions de recherche qui, une fois acceptées, leur donneront accès aux CDR. Pour obtenir plus de renseignements, consultez la page Web suivante : https://www.statcan.gc.ca/fra/cdr/index.

12.1.2 Totalisations personnalisées

Une autre méthode d'accès aux données consiste à utiliser les services de totalisation personnalisés offerts par les services à la clientèle du Centre de données sur la santé de la population. Ce service est offert selon le principe du recouvrement des coûts. Il permet aux utilisateurs qui ne connaissent pas les logiciels de totalisation d'obtenir des résultats personnalisés en fonction des données du fichier maître. Les résultats sont filtrés pour s'assurer qu'ils sont conformes aux normes de confidentialité et de fiabilité avant d'être diffusés. Pour plus d'information, veuillez communiquer avec les services à la clientèle au 613-951-1746 ou par courriel à l'adresse statcan.hd-ds.statcan@canada.ca.

12.1.3 Télé-accès

Le service d'accès à distance aux fichiers maîtres de l'enquête représente un autre moyen d'accéder à ces données si l'utilisateur ne peut avoir accès à un centre de données de recherche alors que l'un de ses projets de recherche est approuvé. On peut fournir au chercheur un fichier maître de données synthétiques ou fichier « fictif » et le plan des enregistrements correspondants. Grâce à ces outils, il pourra mettre au point son propre ensemble de programmes informatisés d'analyse. Le code des tableaux personnalisés est ensuite envoyé par courriel à statcan.hd-ds.statcan@statcan.gc.ca. Le code sera alors transmis au réseau interne sécurisé de Statistique Canada et traité en regard du fichier maître de données pertinentes de l'ESCC. Les estimations générées seront communiquées à l'utilisateur, sous réserve des directives sur l'analyse et la communication des données exposées à la section 10 du présent document. Les résultats sont filtrés pour vérifier qu'ils sont conformes aux normes de confidentialité et de fiabilité, puis les données de sortie sont renvoyées au client. Ce service est gratuit.

12.1.4 Système d'accès à distance en temps réel

Le système d'accès à distance en temps réel (ADTR) offre un accès rapide aux microdonnées de Statistique Canada. Le système d'ADTR est une installation d'accès à distance en ligne qui permet aux utilisateurs d'exécuter en temps réel des programmes SAS codés automatiquement (créé avec une interface graphique) portant sur des ensembles de microdonnées hébergés dans un emplacement central et sécurisé. Les chercheurs qui utilisent le système d'ADTR ne bénéficient pas d'un accès direct aux microdonnées et ne sont pas en mesure d'afficher le contenu du fichier de microdonnées. Au lieu de cela, les utilisateurs soumettent les programmes SAS générés pour

extraire les résultats sous la forme de tableaux statistiques. Étant donné que les chercheurs qui utilisent l'ADTR ne peuvent pas visualiser les microdonnées, il n'est plus nécessaire d'obtenir le statut de personne réputée être employée de Statistique Canada (comme pour l'accès aux CDR). Ce lien est l'élément clé qui permet à l'ADTR d'offrir rapidement des services à ses clients. Pour obtenir de plus amples renseignements, consultez la page https://www.statcan.gc.ca/fra/adtr/adtr.

12.2 Fichiers de partage

Les fichiers de partage contiennent toutes les variables et tous les enregistrements des répondants à l'ESCC qui ont accepté d'échanger leurs données avec les partenaires de Statistique Canada, à savoir Santé Canada et l'Agence de la santé publique du Canada, ainsi que la plupart des ministères provinciaux et territoriaux de la Santé et l'Institut de la statistique du Québec (ISQ). Les fichiers de partage sont diffusés uniquement à ces organisations. Les identificateurs personnels sont supprimés des fichiers partagés afin de respecter la confidentialité des répondants et ne sont fournis qu'aux partenaires provinciaux et territoriaux. Les utilisateurs de ces fichiers partagés doivent d'abord certifier qu'ils ne divulgueront jamais des renseignements susceptibles de permettre l'identification d'un répondant à l'enquête.

12.3 Fichiers de microdonnées à grande diffusion

Des fichiers de microdonnées à grande diffusion (FMGD) sont créés à partir des fichiers maîtres au moyen d'une technique établissant un équilibre entre le besoin d'assurer la confidentialité des répondants et le besoin de produire les données les plus utiles possible à l'échelle de la région sociosanitaire. Les FMGD doivent répondre à des normes sévères de sécurité et de confidentialité, conformément à la *Loi sur la statistique* avant qu'ils ne soient diffusés pour l'accès public. Pour s'assurer du respect de ces normes, chaque FMGD est soumis à un processus officiel d'examen et d'approbation par un comité formé de hauts gestionnaires de Statistique Canada.

Les variables les plus susceptibles de permettre l'identification d'une personne sont supprimées du fichier ou agrégées en catégories moins détaillées. Dû aux risques de divulgation, les poids des ménages ne sont pas inclus dans le FMGD.

L'accès au FMGD est gratuit dans un établissement d'enseignement postsecondaire participant à l'Initiative de démocratisation des données, un partenariat entre les établissements postsecondaire et Statistique Canada qui vise à améliorer l'accès aux sources de données canadiennes. Pour de plus amples renseignements sur l'Initiative de démocratisation des données, consulter le https://www.statcan.gc.ca/fra/idd/idd.

Les FMGD de l'ESCC sont également gratuits pour tout chercheur qui communique avec les services à la clientèle au 613-951-1746 ou par courriel à l'adresse statcan.hd-ds.statcan@canada.ca.

Tableau 12.1 Fichiers de données de l'ESCC de 2022

Période de référence	Fichiers	Type de fichiers	Nom du fichier	Poids d'échantillonnage	Bootstrap weights file	Fichiers des poids bootstrap	Variables incluses
2023	Fichier principal - provinces	Maître	HS.txt	WTS_M	bsw.txt	Tous les modules de base et tous les modules thématiques pour les provinces	Enregistrements de tous les répondants dans les 10 provinces
		Partage		WTS_S			Enregistrements de tous les répondants qui ont accepté de partager leurs données
		Revenu partage	HS_inc.txt	S/O	S/O	Contenu des revenus pour les partenaires de partage, conservé dans un fichier séparé	Données sur les revenus de tous les répondants qui ont accepté de partager leurs données
Janvier à Décembre 2023	Fichier de réponse rapide (SCH2TAL)	Maître	HS_SCH2TAL.txt	WTS_M	Bsw.txt	Tous les modules de base et questions de la réponse rapide SCH2 & TAL	Enregistrements de tous les répondants dans les 3 territoires
		Partage		WTS_S			Enregistrements de tous les répondants qui ont accepté de partager leurs données
		Revenu partage	HS_SCH2TAL_inc.txt	S/O	S/O	Contenu des revenus pour les partenaires de partage, conservé dans un fichier séparé	Données sur les revenus de tous les répondants qui ont accepté de partager leurs données
Juillet à Décembre 2023	Fichier de réponse rapide (WLB)	Maître	HS_WLB.txt	WTS_M	bsw.txt	Tous les modules de base et questions de la réponse rapide WLB	Enregistrements de tous les répondants dans les 10 provinces
		Partage		WTS_S			Enregistrements de tous les répondants qui ont accepté de partager leurs données
		Revenu partage	HS_WLB_INC.txt	S/O	S/O	Contenu des revenus pour les partenaires de partage, conservé dans un fichier séparé	Données sur les revenus de tous les répondants qui ont accepté de partager leurs données

12.4 Utilisation des fichiers de l'ESCC : fichier annuel ou fichier deux ans?

Les utilisateurs qui ont accès aux fichiers de partage ou aux fichiers maîtres ont normalement le choix d'utiliser des fichiers de données d'un an ou de deux ans, en fonction de leur disponibilité. Les décisions concernant la période à utiliser pour une analyse donnée devraient être guidées par le niveau de détail et de qualité requis. Avec un fichier d'un an, il n'y aura pas toujours d'estimations en raison de la qualité associée à des échantillons de taille limitée.

Avant d'interpréter et d'utiliser une estimation de l'ESCC, il est recommandé de s'assurer que l'estimation respecte les règles relatives à la taille minimale des échantillons énoncées au chapitre 10.

Cela ne sera pas possible pour toutes les caractéristiques rares et les domaines détaillés avec des fichiers d'un an. Au lieu de cela, les utilisateurs devront s'appuyer sur les fichiers de deux ans disponibles ou regrouper les données avec celles d'autres cycles de l'ESCC (le cas échéant, en fonction du plan) afin d'obtenir des fichiers pluriannuels. Pour de plus amples renseignements sur la combinaison des cycles de l'ESCC en un fichier de plusieurs années, veuillez consulter https://www150.statcan.gc.ca/n1/pub/82-003-x/2009001/article/10795-fra.pdf.

Lorsque l'utilisation d'un fichier d'un an ou de deux ans est possible, l'utilisateur devrait envisager un compromis entre l'exactitude et l'utilisation de données en temps opportun. S'il est important de rendre compte des caractéristiques courantes d'une population le plus précisément possible, les fichiers d'un an sont préférables. Toutefois, du fait de l'augmentation de la taille de l'échantillon, des estimations et des analyses plus détaillées peuvent être effectuées avec les fichiers de deux ans.

En raison des changements importants apportés au contenu et à la méthodologie de l'enquête entre 2021 et 2022, ainsi que du risque accru de biais résultant des taux de réponse très différents (2021 avait un taux de réponse de 24 %, tandis que 2022 a un taux de 43 %), les utilisateurs sont invités à faire preuve de prudence lorsqu'ils combinent les données de 2021 avec celles de 2022. Les utilisateurs qui choisissent de regrouper des données avec celles de 2021 doivent évaluer les différences de méthodologie et de contenu et déterminer si le regroupement est approprié pour leur analyse. Le cycle 2023 de l'ESCC (dont le plan est pratiquement identique à celui de 2022) sera publié au milieu de 2024, et les utilisateurs auront alors la possibilité de regrouper les données afin d'augmenter la taille de l'échantillon aux fins d'analyse avec une enquête dont le plan et la collecte sont uniformes.

12.5 Utilisation de la variable de pondération

La variable de pondération **WTS_M** représente le poids d'échantillonnage pour les fichiers principaux de l'enquête. Pour un répondant donné, ce poids d'échantillonnage peut être interprété comme étant le nombre de personnes que le répondant représente dans la population canadienne. Ce poids doit être utilisé en tout temps dans les calculs d'estimations statistiques, afin de permettre l'inférence à l'échelle de la population. La production de résultats non pondérés n'est pas recommandée. La répartition de l'échantillon, de même que les détails du plan de sondage, peuvent entraîner des résultats biaisés qui ne représentent pas correctement la population. Pour une description plus détaillée du calcul de ce poids, consulter la section 8 sur la pondération. La variable de pondération **WTS_M** doit être utilisée pour des analyses régionales.

Le module Sécurité alimentaire (FSC) inclus dans les fichiers de certaines périodes de référence, mesure des concepts qui s'appliquent non seulement à la situation du répondant, mais à celle de l'ensemble de son ménage. Le module « Services de soins de santé à domicile » (HMC) contient également du contenu au niveau des ménages. L'analyse des variables peut, selon le niveau d'analyse, nécessiter le recours à un poids calculé de manière à représenter le nombre de ménages au Canada, plutôt que le nombre de personnes. Cette variable de pondération **WTS_MHH** se trouve dans un fichier distinct (HS_HHWT.txt). Elle peut être utilisée à la place de la variable **WTS_M** pour les analyses de ménages aux niveaux national et provincial (pour le fichier de partage, c'est WTS_SHH qui remplace WTS_S pour les analyses au niveau des ménages).

12.6 Convention appliquée pour nommer les variables

Les conventions appliquées pour nommer des variables permettent aux utilisateurs des données de repérer et d'utiliser facilement les variables en fonction du module et du type de variable. La convention appliquée pour nommer les variables de l'ESCC respecte deux exigences : limiter les noms des variables à huit caractères au plus pour qu'il soit facile de les utiliser avec les logiciels d'analyse et permettre de repérer facilement les variables conceptuellement identiques d'une période de collecte à l'autre de l'enquête. Les questions auxquelles on a apporté des changements entre deux périodes de collecte, qui modifient le concept mesuré par la question, sont entièrement renommées pour éviter toute confusion dans l'analyse.

Une variable (REFPER, format = AAAAMM-AAAAMM) a été ajoutée aux fichiers de microdonnées afin d'indiquer le début et la fin de la période de référence au cours de laquelle les données ont été recueillies. Celle-ci s'avérera utile en particulier pour les utilisateurs désireux d'utiliser les données de plusieurs périodes de collecte à la fois. Ainsi, les noms des variables correspondant à des modules ou à des questions identiques entre une année de collecte et une autre (p. ex. 2015 et 2017) seront les mêmes. Cependant, quelques changements mineurs ont été apportés aux noms des variables depuis le remaniement de 2015.

Les règles d'affectation des noms utilisés pour désigner les variables dans l'ESCC de 2022 utilisent un maximum de huit caractères. Les noms des variables sont généralement structurés comme suit :

Positions 1 à 3 :	Nom du module/de la section du questionnaire
Position 4 :	Type de variable (sous-tiret, C, D, F ou G)
Positions 5 à 8 :	Numéro de la question et option de réponse par incréments de cinq (p. ex. 005, 010, 015)

CSS_005 est un exemple de la structure du nom de la variable pour la question 005, Usage actuel du tabac :

Positions 1 à 3 :	CSS	Module sur l'usage actuel du tabac
Position 4 :	_	(sous-tiret = données recueillies)
Position 5 à 8:	005	Numéro de la question

Les positions 1 à 3 contiennent généralement les acronymes de chacun des modules. Ces acronymes figurent à côté des noms de modules présentés dans le tableau de l'annexe A. Il est à noter que certains acronymes de modules sont composés de quatre caractères. Les noms des variables de ces modules sont toujours limités à un maximum de 8 caractères.

La position 4 désigne le type de variable selon qu'il s'agit d'une variable recueillie directement à partir d'une question du questionnaire (« _ »), d'une variable codée (« C »), dérivée (« D »), d'une variable indicatrice (« F ») ou groupée (« G »).
En général, les quatre dernières positions (5 à 8) correspondent à la numérotation de la variable qui figure sur le questionnaire.

On supprime la lettre « Q » utilisée pour représenter le mot « question » et on présente tous les numéros de question au moyen d'un groupe de deux ou trois chiffres. Par exemple, la question Q005A du questionnaire devient simplement 005A et la question Q010, simplement 010.

Tableau 12.2 Désignation des codes utilisés à la 4e position du nom des variables de l'ESCC

_	Variable recueillie	Variable qui figure directement sur le questionnaire
C	Variable codée	Variable codée à partir d'une ou de plusieurs variables recueillies (p. ex. code de la Classification type des industries [CTI])
D	Variable dérivée	Variable calculée d'après une ou plusieurs variables recueillies ou codées, ordinairement pendant le traitement au bureau central (p. ex. indice de l'état de santé)
F	Variable indicatrice	Variable calculée à partir d'une ou de plusieurs variables recueillies (comme variable dérivée), mais ordinairement par l'application informatique de collecte des données, aux fins de son utilisation ultérieure durant l'interview (p. ex. indicateur de travail)
G	Variable groupée	Variables recueillies, codées, supprimées ou dérivées, agrégées en un groupe (p. ex. groupes d'âge). Principalement utilisé pour les FMGD.

Dans le cas des questions pour lesquelles il existe plus d'une option de réponse, la position finale de la séquence dénommant la variable correspond à une lettre. Pour ce type de questions, on a créé de nouvelles variables pour faire la distinction entre une réponse « oui » ou « non » pour chaque option de réponse. Par exemple, si la question Q010 comporte quatre réponses possibles, les nouvelles questions seraient Q010A pour la première option, Q010B pour la deuxième, Q010C pour la troisième et Q010D pour la quatrième. Si seulement les options 2 et 3 sont choisies, alors Q010A = Non, Q010B = Oui, Q010C = Oui et Q010D = Non.

12.7 Dictionnaires de données

Des rapports distincts de dictionnaires de données, notamment les noms des variables, les concepts, les énoncés d'univers et les fréquences, sont fournis dans le fichier maître principal, les fichiers de partage et chacun des fichiers de réponse rapide (le cas échéant). Toutes les variables dans ces fichiers figureront dans le rapport du dictionnaire de données, mais certaines pourraient ne pas inclure une fréquence (SampleID par exemple).

Quand une variable inclut les fréquences des réponses, le rapport comportera quatre colonnes :

1. Contenu – Étiquette de texte de chacune des catégories de réponses.

2. Code – Valeur numérique associée à chaque catégorie.
3. Échantillon – Fréquence non pondérée du fichier des répondants avec chaque réponse.
4. Population – Fréquence pondérée de la réponse.

Dans le cas de chaque module des rapports de dictionnaire de données, un indicateur est utilisé afin d'indiquer la disponibilité d'un module pour chaque répondant. Lorsque l'indicateur est 2 (non), toutes les variables du module ont des valeurs « Sans objet ». Par exemple, la variable DOCCC indique si le module Conditions choniques s'applique à un répondant donné.

ANNEXE A -L'ENQUÊTE SUR LA SANTÉ DANS LES COLLECTIVITÉS CANADIENNES (ESCC) - APERÇU DU CONTENU - 2023

Annexe A - L'enquête sur la santé dans les collectivités canadiennes (ESCC)
Aperçu du contenu pour les provinces et territoires - 2023

		2023												
Acronyme	**Nom du module**	**NL (10)**	**PEI (11)**	**NS (12)**	**NB (13)**	**QC (24)**	**ON (35)**	**MB (46)**	**SK (47)**	**AB (48)**	**BC (59)**	**YK[1] (60)**	**NWT[1] (61)**	**NU[1] (62)**
ABM	Identité autochtone	C	C	C	C	C	C	C	C	C	C	C	C	C
ADL	Activités de la vie quotidienne	O		O		O			O				O	
ALC	Consommation d'alcool	C	C	C	C	C	C	C	C	C	C	C	C	C
ALW	Consommation d'alcool au cours de la dernière semaine	T	T	T	T	T	T	T	T	T	T	T	T	T
CAN	Consommation de cannabis	C	C	C	C	C	C	C	C	C	C	C	C	C
CCC	Conditions chroniques	C	C	C	C	C	C	C	C	C	C	C	C	C
CC1	Conditions chroniques 1			O		O	O	O	O			O	O	
CMH	Consultations en santé mentale			O	O	O		O	O	O		O	O	
COVA[2]	COVID-19	T	T	T	T	T	T	T	T	T	T	T	T	T
COVB[2]	COVID-19	T	T	T	T	T	T	T	T	T	T	T	T	T
COVC	COVID-19	T	T	T	T	T	T	T	T	T	T	T	T	T
COVD	COVID-19	T	T	T	T	T	T	T	T	T	T	T	T	T
COVE	COVID-19	T	T	T	T	T	T	T	T	T	T	T	T	T
COVF	COVID-19	T	T	T	T	T	T	T	T	T	T	T	T	T
CSS	Usage actuel de la cigarette	C	C	C	C	C	C	C	C	C	C	C	C	C
DEP	Santé mentale	O	O	O	O	O	O	O	O	O	O	O		O
EAH	Habitudes alimentaires											T	T	T
ECV	Cigarettes électroniques et vapotage	C	C	C	C	C	C	C	C	C	C	C	C	C
FLU	Vaccin contre la grippe	T	T	T	T	T	T	T	T	T	T	T	T	T
FSC	Sécurité alimentaire	C	C	C	C	C	C	C	C	C	C	C	C	C
GDRA	Sexe et le genre	C	C	C	C	C	C	C	C	C	C	C	C	C
GEN	Santé générale	C	C	C	C	C	C	C	C	C	C	C	C	C
HMC	Services de soins de santé à domicile	C	C	C	C	C	C	C	C	C	C	C	C	C
HWT	Taille et poids	C	C	C	C	C	C	C	C	C	C	C	C	C
HUI	Indice de l'état de santé	T	T	T	T	T	T	T	T	T	T	T	T	T
IM	Lieu de naissance, immigration et citoyenneté	C	C	C	C	C	C	C	C	C	C	C	C	C

INC³	Revenu total du ménage	C	C	C	C	C	C	C	C	C	C	C	C	C
ADMC	Renseignements administratifs	C	C	C	C	C	C	C	C	C	C	C	C	C
HN	Verification des numéros de carte santé	C	C	C	C	C	C	C	C	C	C	C	C	C
LAN	Langue	C	C	C	C	C	C	C	C	C	C	C	C	C
LBF	Activité sur le marché du travail	C	C	C	C	C	C	C	C	C	C	C	C	C
LM	Télétravail	T	T	T	T	T	T	T	T	T	T	T	T	T
LMAM	Activité sur le marché du travail	C	C	C	C	C	C	C	C	C	C	C	C	C
LMA3	Activité sur le marché du travail	C	C	C	C	C	C	C	C	C	C	C	C	C
LMA4	Activité sur le marché du travail	C	C	C	C	C	C	C	C	C	C	C	C	C
LMA5	Activité sur le marché du travail	C	C	C	C	C	C	C	C	C	C	C	C	C
LMA6	Activité sur le marché du travail	C	C	C	C	C	C	C	C	C	C	C	C	C
LSM	Mesures de la satisfaction à l'égard de la vie	C	C	C	C	C	C	C	C	C	C	C	C	C
LTC	Conditions à long terme	C	C	C	C	C	C	C	C	C	C	C	C	C
MA	Activité principale	C	C	C	C	C	C	C	C	C	C	C	C	C
EDC	Activité principale	C	C	C	C	C	C	C	C	C	C	C	C	C
MEX	Expérience de maternité	O	O	O		O		O	O	O	O	O	O	
MPA	Activité physique modérée	T	T	T	T	T	T	T	T	T	T	T	T	T
OPA	Autre activités physiques	T	T	T	T	T	T	T	T	T	T	T	T	T
PG	Groupe de population	C	C	C	C	C	C	C	C	C	C	C	C	C
PMS	Bien-être mental		O		O						O			O
PRS	Grossesse	C	C	C	C	C	C	C	C	C	C	C	C	C
RHC	Fournisseur habituel de soins de santé	C	C	C	C	C	C	C	C	C	C	C	C	C
SCH2	Usage du tabac - les étapes du changement 2	RR	RR	RR	RR	RR	RR	RR	RR	RR	RR			
SOR	Orientation sexuelle	C	C	C	C	C	C	C	C	C	C	C	C	C
SPS	Provisions sociales	O	O	O	O	O	O		O	O	O		O	
SPU	Usage antérieur du tabac	C	C	C	C	C	C	C	C	C	C	C	C	C
TAL	Produits de remplacement du tabac	RR	RR	RR	RR	RR	RR	RR	RR	RR	RR			
UPE	Utilisation d'équipement protecteur			O		O			O	O		O		
WLB	Équilibre travail-famille	RR	RR	RR	RR	RR	RR	RR	RR	RR	RR			

ANNEXE B - GÉOGRAPHIE DISPONIBLE SUR LE FICHIER MAÎTRE ET DE PARTAGE ET CODES CORRESPONDANTS: CANADA, PROVINCES, RÉGIONS SOCIOSANITAIRES ET GROUPES HOMOLOGUES

Annexe B - Géographie disponible sur le fichier maître et de partage et codes correspondants: Canada, provinces, régions sociosanitaires et groupes homologues

0	Canada
10	Terre-Neuve-et-Labrador
1020-G	Eastern Urban Zone
1021-B	Eastern Rural Zone
1022-B	Central Zone
1023-B	Western Zone
1024-E	Labrador-Grenfell Zone
11	Île-du-Prince-Édouard
1100-I	Île-du-Prince-Édouard
12	Nouvelle-Écosse
1201-B	Zone 1 - Western
1202-B	Zone 2 - Northern
1203-B	Zone 3 - Eastern
1204-G	Zone 4 - Central
13	Nouveau-Brunswick
1301-I	Zone 1 (région de Moncton)
1302-I	Zone 2 (région de Saint John)
1303-I	Zone 3 (région de Fredericton)
1304-B	Zone 4 (région de Edmundston)
1305-B	Zone 5 (région de Campbellton)
1306-B	Zone 6 (région de Bathurst)
1307-B	Zone 7 (région de Miramichi)
24	Québec
2401-F	Région du Bas-Saint-Laurent
2402-F	Région du Saguenay – Lac-Saint-Jean
2403F	Région de la Capitale-Nationale
2404-F	Région de la Mauricie et du Centre-du-Québec
2405-F	Région de l'Estrie
2406-C	Région de Montréal
2407-G	Région de l'Outaouais
2408-F	Région de l'Abitibi-Témiscamingue
2409-F	Région de la Côte-Nord
2410-F	Région du Nord-du-Québec
2411-B	Région de la Gaspésie – Îles-de-la-Madeleine
2412-F	Région de la Chaudière-Appalaches
2413-G	Région de Laval
2414-F	Région de Lanaudière
2415-I	Région des Laurentides
2416-F	Région de la Montérégie
2417-A	Région du Nunavik
2418-A	Région des Terres-Cries-de-la-Baie-James
35	Ontario par Régions de Santé
3501-C	Ouest
3502-B	Centre
3503-B	Toronto
3504-B	Est
3505-H	Nord-Est
3506-H	Nord-Ouest

35	Ontario par circonscription sanitaire
3526-B	Circonscription sanitaire du district d'Algoma
3527-I	Circonscription sanitaire du comté de Brant
3530-H	Circonscription sanitaire régionale de Durham
3533-I	Circonscription sanitaire de Grey Bruce
3534-I	Circonscription sanitaire de Haldimand-Norfolk
3535-I	Circonscription sanitaire du district de Haliburton, Kawartha et Pine Ridge
3536-D	Circonscription sanitaire régionale de Halton
3537-G	Circonscription sanitaire de la cité de Hamilton
3538-I	Circonscription sanitaire des comtés de Hastings et Prince Edward
3540-I	Circonscription sanitaire de Chatham-Kent
3541-I	Circonscription sanitaire de Kingston, Frontenac et Lennox et Addington
3542-I	Circonscription sanitaire de Lambton
3543-I	Circonscription sanitaire de Leeds, Grenville et Lanark
3544-G	Circonscription sanitaire de Middlesex-London
3546-I	Circonscription sanitaire régionale de Niagara
3547-I	Circonscription sanitaire du district de North Bay Parry Sound
3549-E	Circonscription sanitaire du Nord-Ouest
3550-I	Circonscription sanitaire du compté de Huron et du district de Perth
3551-D	Circonscription sanitaire de la cité d'Ottawa
3553-D	Circonscription sanitaire régionale de Peel
3555-I	Circonscription sanitaire du comté et de la cité de Peterborough
3556-E	Circonscription sanitaire de Porcupine
3557-D	Circonscription sanitaire du comté et du district de Renfrew
3558-C	Circonscription sanitaire de l'Est de l'Ontario
3560-D	Circonscription sanitaire du district de Simcoe Muskoka
3561-C	Circonscription sanitaire de Sudbury et son district
3562-C	Circonscription sanitaire du district de Thunder Bay
3563-C	Circonscription sanitaire de Timiskaming
3565-B	Circonscription sanitaire de Waterloo
3566-D	Circonscription sanitaire de Wellington-Dufferin-Guelph
3568-B	Circonscription sanitaire de Windsor-Comté d'Essex
3570-H	Circonscription sanitaire régionale de York
3575-D	Circonscription sanitaire d'Oxford, Elgin et St. Thomas
3595-G	Circonscription sanitaire de la cité de Toronto
46	Manitoba
4601-G	Région sanitaire de Winnipeg et de Churchill
4602-E	Région sanitaire de Prairie Mountain
4603-E	Région sanitaire d'Entre-les-Lacs et de L'Est
4604-A	Région sanitaire du Nord
4605-E	Région sanitaire du Sud
47	Saskatchewan

4721-A		Far North
4722-E		North Central West
4723-E		North Central East
4724-G		Saskatoon
4725-E		South West
4726-E		South East
4727-G		Regina
48	Alberta	
4831-E		South Zone
832-D		Calgary Zone
4833-D		Central Zone
4834-D		Edmonton Zone
4835-E		North Zone
59	Colombie-Britannique	
5911-I		East Kootenay Health Service Delivery Area
5912-I		Kootenay-Boundary Health Service Delivery Area
5913-I		Okanagan Health Service Delivery Area
5914-I		Thompson/Cariboo Health Service Delivery Area
5921-H		Fraser East Health Service Delivery Area
5922-H		Fraser North Health Service Delivery Area
5923-D		Fraser South Health Service Delivery Area
5931-C		Richmond Health Service Delivery Area
5932-C		Vancouver Health Service Delivery Area
5933-H		North Shore/Coast Garibaldi Health Service Delivery Area
5941-H		South Vancouver Island Health Service Delivery Area
5942-I		Central Vancouver Island Health Service Delivery Area
5943-I		North Vancouver Island Health Service Delivery Area
5951-E		Northwest Health Service Delivery Area
5952-E		Northern Interior Health Service Delivery Area
5953-E		Northeast Health Service Delivery Area
60	Yukon	
6001-E		Yukon
61	Territoires du Nord-Ouest	
6101-E		Territoires du Nord-Ouest
62	Nunavut	
6201-A		Nunavut

A	Groupe de régions homologues A
B	Groupe de régions homologues B
C	Groupe de régions homologues C
D	Groupe de régions homologues D
E	Groupe de régions homologues E
F	Groupe de régions homologues F
G	Groupe de régions homologues G
H	Groupe de régions homologues H

ANNEXE C - RÉPARTITION DE L'ÉCHANTILLON PAR PROVINCE (ESCC DE 2023)

Appendix C – Répartition de l'échantillon par province (ESCC de 2023)[11]

Province	ESCC		Total
	Base aréolaire	Base du PADD	
Total	100 375	32 838	133 213
T.-N.-L.	2 978	1 518	4 496
Î.-P.-É.	1 037	864	1 901
N.-É.	3 873	2 191	6 064
N.-B.	3 468	1 593	5 061
Qc	20 301	5 623	25 924
Ont.	30 839	6 207	37 046
Man.	5 003	3 026	8 029
Sask.	4 252	2 470	6 722
Alb.	13 130	4 634	17 764
C.-B.	15 494	4 712	20 206

[11] La taille d'échantillon correspond ici au nombre d'unités qui ont été envoyées à la collecte.

ANNEXE D - TAUX DE RÉPONSE PAR PROVINCE (ESCC DE 2023)

Annexe D – Taux de réponse par province (ESCC de 2023)

Province	Base aréolaire			PADD			Combiné
	# champ de l'enquête	# répondants	Taux de réponse	# champ de l'enquête	# répondants	Taux de réponse	Taux de réponse
Total	95,281	38,952	40.9	32,051	12,688	39.6	40.6
T.-N.-L.	2,776	994	35.8	1,486	559	37.6	36.4
Î.-P.-É.	919	313	34.1	831	368	44.3	38.9
N.-É.	3,601	1,574	43.7	2,133	973	45.6	44.4
N.-B.	3,192	1,175	36.8	1,544	726	47.0	40.1
Qc	19,060	8,335	43.7	5,433	2,330	42.9	43.5
Ont.	29,484	12,593	42.7	6,087	2,337	38.4	42.0
Man.	4,760	1,856	39.0	2,947	1,215	41.2	39.8
Sask.	4,046	1,370	33.9	2,414	899	37.2	35.1
Alb.	12,608	4,627	36.7	4,554	1,539	33.8	35.9
C.B.	14,835	6,115	41.2	4,622	1,742	37.7	40.4