Estimation de la variance par la méthode bootstrap à partir des données d'enquêtes de Statistique Canada

Décembre 2015

Division des méthodes d'enquêtes auprès des ménages

Estimation de la variance par la méthode bootstrap

La méthode bootstrap appartient à une famille de méthodes d'estimation de la variance dites « par réplication ». On trouvera un traitement détaillé des méthodes fondées sur la réplication dans les ouvrages de Wolter (2007), Rust et Rao (1996) ou Lohr (1999). Ces méthodes consistent à extraire des sous-échantillons répétés (appelés répliques) des données pour recalculer l'estimation pondérée d'après les données d'enquête pour chaque réplique et pour l'échantillon complet, et pour ensuite calculer la variance en tant que fonction de l'estimation résultante. Les autres méthodes fondées sur la réplication comprennent la méthode jackknife et la méthode des répliques répétées équilibrées (Balanced Repeated Replication ou BRR).

Plusieurs enquêtes de Statistique Canada utilisent la méthode bootstrap pour estimer la variance d'échantillonnage. La méthode est mise en œuvre grâce à un ensemble de poids bootstrap propre l'enquête qui est souvent fournie avec les microdonnées de l'enquête.

Logiciels utilisés

Plusieurs logiciels disponibles sur le marché permettent d'estimer correctement la variance d'une estimation donnée au moyen de méthodes fondées sur la réplication, notamment SAS, Stata, SUDAAN, WesVar et Bootvar[1]. Bien que souvent la méthode bootstrap ne soit pas directement prise en charge, la méthode BRR est prise en charge et on peut utiliser sa fonctionnalité pour estimer la variance dans les enquêtes au moyen de la méthode bootstrap. Les méthodes bootstrap et BRR diffèrent selon la façon dont les répliques sont produites, cependant le processus d'estimation de la variance est identique pour les deux méthodes. La documentation de certains logiciels ne mentionne pas ce fait en détail (Phillips, 2004).

On trouvera de plus amples informations sur ces logiciels sur les sites Web suivants :

SAS : http://www.sas.com

SAS 9.2 est la toute première version de SAS qui offre des approches fondées sur la réplication pour l'estimation de la variance dans ses quatre procédures d'analyse des enquêtes. On peut utiliser l'option BRR avec des poids bootstrap fournis par l'utilisateur pour obtenir des estimations de la variance par la méthode bootstrap (Phillips, 2004).

Stata : http://www.stata.com

---

[1]Bootvar est une application d'estimation de la variance par la méthode bootstrap développée par Statistique Canada. Elle avait été élaborée à une époque où aucune autre solution informatique n'était disponible. Bien qu'elle puisse encore maintenant être employée par certains utilisateurs, elle n'est plus tenue à jour par Statistique Canada.

Stata 12 offre un éventail exhaustif d'options d'estimation de la variance avec les commandes svy – série de Taylor, jackknife, BRR et bootstrap. On peut utiliser l'option bootstrap avec des poids d'enquête bootstrap fournis par l'utilisateur, comme ceux fournis avec de nombreuses enquêtes de Statistique Canada, afin d'obtenir des estimations de la variance par la méthode bootstrap.

SUDAAN : http://www.rti.org/sudaan
SUDAAN 10 offre trois méthodes d'estimation de la variance – série de Taylor, jackknife et BRR. On peut utiliser l'option BRR en combinaison avec des poids bootstrap fournis par l'utilisateur pour obtenir des estimations de la variance par la méthode bootstrap (Phillips, 2004).

WesVar : http://www.westat.com
WesVar exécute diverses analyses de données d'enquête en utilisant exclusivement des méthodes de répliques pour calculer l'estimation de la variance. L'une de ces méthodes, celle des répliques répétées équilibrées avec un ajustement de Fay, tel que détaillé dans Phillips (2004), peut être utilisée pour obtenir des estimations de la variance bootstrap si les poids bootstrap sont fournis par le chercheur.

En outre, pour calculer la variance par la méthode bootstrap, on peut utiliser de manière itérative tout logiciel qui offre une commande ou une procédure analytique pouvant produire des estimations pondérées des paramètres d'intérêt et qui offre également la souplesse d'un langage de programmation.

La méthode Bootstrap dans la pratique

On trouvera une explication détaillée (avec des exemples) de la mise en œuvre de la méthode bootstrap avec le logiciel voulu dans le Bulletin technique et d'information des Centres de données de recherche de Statistique Canada – « Estimation pondérée et estimation de la variance bootstrap pour analyser des données d'enquête : Comment les effectuer dans certains logiciels choisis » (Gagné, 2014).
http://www.statcan.gc.ca/pub/12-002-x/2014001/article/11901-fra.htm

Pour chaque option logicielle permettant d'estimer la variance selon la méthode bootstrap, certains fichiers, variables et paramètres sont requis. Puisque cette information diffère d'une enquête à l'autre, il faut consulter le guide de l'utilisateur de l'enquête pour obtenir les détails spécifiques. L'information requise comprend :

Fichiers[2] :

- **Fichier de données –** Ce fichier contient l'ensemble des observations et leurs caractéristiques recueillies par l'enquête

[2] La plupart des progiciels nécessitent de fusionner les deux fichiers en un fichier analytique unique. À cette fin l'utilisateur pourra utiliser les variables d'identification uniques contenues dans les deux fichiers.

- **Fichier de poids bootstrap –** Ce fichier contient les poids ajustés pour chacune des répliques bootstrap

Variables :

- **Variable(s) d'identification –** Identificateurs uniques pour chaque observation incluse dans le fichier de données
- **Poids de sondage** – Poids à utiliser pour calculer les estimations d'enquête, p. ex. WTS_M, WTS_S, etc.
- **Poids répliques –** Poids correspondant au poids de sondage. Il doit y avoir une pondération pour chaque réplique bootstrap
- **Variables d'analyse –** Ces variables sont utilisées par le chercheur pour son analyse spécifique. Elles peuvent être directement accessibles dans les fichiers de données ou encore dérivées pour une étude spécifique.

Paramètres :

- Les noms ou préfixes des poids répliques (p. ex. BSW1-BSW1000)
- Le nombre de poids répliques propres à l'enquête
- Un paramètre bootstrap moyen (ajustement de Fay, aussi appelé facteur de Fay) si l'enquête avait utilisé la méthode « bootstrap moyen »

Références

Gagné, C. R. (2014, August). Weighted estimation and bootstrap variance estimation for analyzing survey data. *The Research Data Centres Information and Technical Bulletin*.

Lohr, S. (1999). *Sampling: Design and Analysis.* USA: Duxbury Press.

Phillips, O. (2004). Comment utiliser les poids bootstrap avec WesVar et SUDAAN. *Bulletin technique et d'information des Centres de données de recherche 1 (2)*, pages 6-15.

Rust, K., & Rao, J. (1996). Variance estimation for complex surveys using replication techniques. *Statistical Methods in Medical Research 5*, pp. 283-310.

Wolter, K. (2007). *Introduction to Variance Estimation* (2nd ed.). New York: Springer-Verlag.